

人工智能与全球战略稳定性： 自主武器、军备竞赛与威慑模型的重构

综述论文

2026 年 3 月 19 日

摘要

人工智能技术的快速发展正在深刻改变全球安全格局，对传统的战略稳定性理论提出了前所未有的挑战。本文系统综述了人工智能与全球战略稳定性的交叉研究领域，重点关注自主武器系统、AI 驱动的军备竞赛以及威慑模型的重构等核心议题。

本文首先梳理了自主武器系统的技术基础，包括机器学习、计算机视觉、决策支持系统等关键技术在军事领域的应用现状。其次，深入分析了 AI 技术对战略稳定性的多重挑战，包括危机稳定性、军备竞赛稳定性和威慑稳定性的破坏机制。第三，系统梳理了国际社会在自主武器治理方面的政策进展，包括联合国《特定常规武器公约》政府专家组的讨论、国际人道法的适用性以及各主要国家的政策立场。最后，探讨了应对 AI 战略风险的潜在路径，包括技术对策、军控机制和建立信任措施。

本文基于 80 余篇权威文献，包括 SIPRI、RAND、CSET 等国际顶级智库的研究报告以及近五年发表在《Washington Quarterly》《Air Space Power Journal》等期刊的学术论文。研究表明，AI 技术既可能通过提升预警能力和决策效率来增强战略稳定性，也可能通过压缩决策时间线、增加误判风险和破坏危机沟通机制来削弱稳定性。如何在 harness AI 技术优势的同时防范其战略风险，已成为国际关系和军控领域最紧迫的议题之一。

关键词：人工智能；战略稳定性；自主武器系统；军备竞赛；核威慑；国际安全治理

目录

1	引言	3
1.1	研究背景与意义	3
1.2	问题定义与研究范围	3
1.3	研究方法与创新点	4
1.4	论文组织结构	4
2	人工智能军事应用的技术基础	4
2.1	自主武器系统的技术架构	4
2.1.1	感知与目标识别	4
2.1.2	决策与规划	5
2.1.3	执行与效应器	5
2.2	人工智能在核指挥控制中的应用	5
2.2.1	预警与情报分析	5
2.2.2	决策支持系统	6
2.2.3	通信与网络防御	6
2.3	人机协作与“人在回路”	6
2.3.1	人在回路的层次模型	6
2.3.2	有意义的人类控制	6
2.4	技术局限性与风险	7
2.4.1	鲁棒性与泛化能力	7
2.4.2	可解释性与透明度	7
2.4.3	测试与验证	7
2.4.4	深度学习在目标识别中的应用	7
2.4.5	传感器融合技术	8
2.4.6	强化学习在战术决策中的应用	8
2.4.7	多智能体协同决策	9
2.4.8	历史案例：1983 年苏联导弹预警虚警事件	9
2.4.9	AI 预警系统的误判风险分析	9
2.4.10	全球 AI 军事投资趋势	10
2.4.11	美国政策详细分析	10
2.4.12	中国政策详细分析	11
2.4.13	可解释 AI 技术路径	12
2.4.14	AI 军控的核查技术	12
2.4.15	AI 时代的危机沟通机制	13
2.4.16	建立信任措施的历史经验	13
2.4.17	乌克兰冲突中的自主武器：详细分析	14
2.4.18	中美 AI 军备竞赛：深度分析	14
2.4.19	以色列铁穹系统：战略稳定性分析	14

2.4.20	AI 军事应用的技术发展趋势	15
2.4.21	关键研究议题	15
2.5	跨学科研究方法论	15
2.5.1	技术评估方法	16
2.5.2	战略分析框架	16
2.5.3	伦理与法律分析	16
3	人工智能对战略稳定性的挑战	16
3.1	战略稳定性的理论框架	16
3.1.1	危机稳定性	17
3.1.2	军备竞赛稳定性	17
3.1.3	威慑稳定性	17
3.2	AI 对危机稳定性的影响机制	17
3.2.1	决策时间压缩	17
3.2.2	误判风险增加	18
3.2.3	升级管理复杂化	18
3.3	AI 驱动的军备竞赛动态	18
3.3.1	技术竞赛的加速效应	18
3.3.2	先发优势与不稳定因素	18
3.3.3	透明度困境	19
3.4	AI 对威慑模型的重构	19
3.4.1	从人类决策到算法决策	19
3.4.2	相互确保毁灭的稳定性	19
3.4.3	危机稳定性的新挑战	19
4	国际治理框架与政策进展	20
4.1	国际人道法的适用性	20
4.1.1	区分原则的困境	20
4.1.2	比例原则与预防原则	20
4.2	联合国《特定常规武器公约》进程	20
4.2.1	GGE 的讨论进展	21
4.2.2	2024 年联合国大会决议	21
4.3	主要国家的政策立场	21
4.3.1	美国	21
4.3.2	中国	21
4.3.3	俄罗斯	22
4.3.4	欧盟与北约	22
4.4	伦理框架与“有意义的人类控制”	22
4.4.1	ICRC 的立场	22
4.4.2	Stop Killer Robots 运动	22

4.4.3	学术界的观点分歧	23
5	应对 AI 战略风险的策略	23
5.1	技术对策	23
5.1.1	可解释 AI 与可审计性	23
5.1.2	安全设计与故障保护	23
5.1.3	网络安全与对抗性防御	23
5.2	军控机制设计	24
5.2.1	AI 核查的技术挑战	24
5.2.2	限制特定应用的军控方案	24
5.2.3	数量与部署限制	24
5.3	建立信任措施	24
5.3.1	透明度与通报机制	24
5.3.2	危机沟通机制	25
5.3.3	Track II 外交	25
5.4	政策建议	25
5.4.1	短期措施 (1-2 年)	25
5.4.2	中期措施 (3-5 年)	25
5.4.3	长期愿景 (5-10 年)	26
6	案例分析	26
6.1	案例一：乌克兰冲突中的自主武器使用	26
6.2	案例二：中美 AI 军备竞赛	26
6.3	案例三：以色列的铁穹系统	26
7	未来研究方向	26
7.1	技术发展趋势	26
7.2	研究议程	27
7.3	跨学科研究方法论	27
7.3.1	技术评估方法	27
7.3.2	战略分析框架	27
7.3.3	伦理与法律分析	28
8	结论	28
8.1	主要发现	28
8.2	政策启示	28
8.3	研究局限与展望	28
A	关键术语表	29

B 主要国际文件汇总	29
B.1 联合国相关文件	29
B.2 各国政策文件	30
B.3 国际红十字会文件	30
C 主要智库与研究机构	30
D 研究方法说明	30
D.1 文献检索策略	30
D.2 分析框架	31
A 关键术语表	33
B 主要国际文件汇总	33
B.1 联合国相关文件	33
B.2 各国政策文件	34
C 主要智库与研究机构	34
D 研究方法说明	34
D.1 文献检索策略	34
D.2 分析框架	35

1 引言

1.1 研究背景与意义

21 世纪第三个十年，人工智能技术正以前所未有的速度渗透至军事领域，从根本上改变着战争形态和战略博弈的逻辑。从自主无人机到智能决策支持系统，从网络攻防到核指挥控制，AI 技术的应用范围日益扩大，其影响深度和广度已超出传统技术变革的范畴。正如 Scharre 在其开创性著作《Army of None: Autonomous Weapons and the Future of War》中所指出的，我们正处于自主武器系统发展的关键转折点，这一技术转型将重新定义军事力量的本质和使用方式。

人工智能对全球战略稳定性的影响是多维度、多层次的。从技术层面看，机器学习算法的应用使得武器系统能够在没有人类直接干预的情况下识别、跟踪和攻击目标，这引发了关于“有意义的人类控制”的激烈争论。从战略层面看，AI 技术可能通过多种机制影响核威慑的稳定性：一方面，AI 增强的预警和侦察能力可能降低误判风险；另一方面，AI 驱动的决策支持系统可能压缩危机决策时间线，增加意外升级的风险。

战略稳定性理论自冷战时期发展以来，一直是国际关系和军控研究的核心范式。传统的战略稳定性包含三个相互关联的维度：危机稳定性（Crisis Stability）、军备竞赛稳定性（Arms Race Stability）和威慑稳定性（Deterrence Stability）。危机稳定性关注在危机情境下双方是否有首先使用核武器的动机；军备竞赛稳定性关注双方是否有通过发展军备获取优势的动机；威慑稳定性关注双方是否能够有效威慑对方的攻击。AI 技术的介入正在挑战这三个维度的传统假设和运作机制。

2024 年 12 月，联合国大会以 166 票赞成、3 票反对（俄罗斯、朝鲜、白俄罗斯）、15 票弃权的结果通过了一项关于致命性自主武器系统（Lethal Autonomous Weapons Systems, LAWS）的决议，呼吁制定具有法律约束力的国际文书。这一决议标志着国际社会对 AI 武器化问题的关注已达到新的高度，也反映出各国在这一问题上的深刻分歧。美国、中国、俄罗斯等核武器国家在 AI 军事应用领域的竞争日益激烈，如何在技术进步与战略稳定之间寻求平衡，已成为全球安全治理面临的最紧迫挑战之一。

1.2 问题定义与研究范围

本文聚焦于以下核心研究问题：人工智能技术如何影响全球战略稳定性？具体而言，AI 技术在军事领域的应用通过哪些机制影响危机稳定性、军备竞赛稳定性和威慑稳定性？国际社会应如何构建有效的治理框架以应对 AI 带来的战略风险？

研究范围涵盖以下四个主要领域：

(1) 技术基础：自主武器系统的核心技术，包括机器学习、计算机视觉、传感器融合、决策支持系统等；AI 在核指挥、控制与通信（NC3）系统中的应用；人机协作与“人在回路”的技术实现。

(2) 战略挑战：AI 对危机稳定性的影响机制，包括决策时间压缩、误判风险增加、升级管理复杂化等；AI 驱动的军备竞赛动态；AI 对威慑可信性和稳定性的影响。

(3) 治理政策：国际人道法对自主武器的适用性；联合国《特定常规武器公约》政

府专家组的讨论进展；各主要国家的政策立场和立法实践；伦理框架和“有意义的人类控制”原则。

(4) **应对策略**：技术对策，包括 AI 核查、可解释 AI、安全设计等；军控机制和建立信任措施；国际合作的潜在路径和障碍。

1.3 研究方法与创新点

本文采用系统性文献综述方法，基于 80 余篇权威文献，包括国际顶级智库（SIPRI、RAND、CSET、CNAS 等）的研究报告、学术期刊论文、国际法文献和政策文件。文献检索涵盖 arXiv、IEEE Xplore、JSTOR 等学术数据库以及各智库官方网站。

本文的主要创新点包括：

(1) **系统性框架**：构建了 AI 影响战略稳定性的综合分析框架，整合技术、战略、政策和伦理四个维度，为后续研究提供理论基础。

(2) **批判性分析**：不仅总结现有研究的主要观点，还深入分析各派观点的局限性，特别是技术乐观主义与技术悲观主义之间的张力。

(3) **政策导向**：在理论分析的基础上，提出具有可操作性的政策建议，包括技术对策、军控机制和建立信任措施的具体设计。

1.4 论文组织结构

本文共分为七章。第 2 章介绍 AI 军事应用的技术基础；第 3 章分析 AI 对战略稳定性的挑战；第 4 章讨论国际治理框架；第 5 章探讨应对策略；第 6 章进行案例分析；第 7 章展望未来研究方向；第 8 章总结全文并提出政策建议。

2 人工智能军事应用的技术基础

2.1 自主武器系统的技术架构

自主武器系统（Autonomous Weapons Systems, AWS）是指能够在没有人类直接干预的情况下，自主选择并攻击目标的武器系统。根据 Scharre 的定义，自主性的核心在于目标选择的自主性——即系统能够在动态环境中独立识别、分类和选择攻击目标。这一技术能力依赖于多个相互关联的子系统的协同工作。

2.1.1 感知与目标识别

感知系统是自主武器系统的“眼睛”和“耳朵”，负责从复杂环境中提取相关信息。现代 AWS 通常采用多传感器融合架构，整合可见光相机、红外传感器、雷达、激光雷达（LiDAR）等多种感知模态。机器学习，特别是深度学习技术，在目标识别和分类任务中发挥着核心作用。

卷积神经网络（CNN）是目前最广泛应用于图像识别的深度学习架构。在军事场景中，CNN 被用于识别坦克、装甲车辆、飞机、舰船等军事目标，以及区分战斗人员与非

战斗人员。然而，战场环境的复杂性——包括烟雾、灰尘、恶劣天气、伪装和电子对抗——对目标识别算法提出了严峻挑战。研究表明，在对抗性环境下，深度学习模型的准确率可能显著下降，这引发了关于自主武器可靠性的担忧。

2.1.2 决策与规划

决策系统是自主武器系统的“大脑”，负责根据感知信息做出攻击决策。这一系统通常包括态势评估、威胁分析、目标优先级排序和交战决策等功能模块。现代 AWS 越来越多地采用基于强化学习的决策算法，使系统能够在复杂动态环境中学习最优策略。

然而，强化学习在军事应用中的局限性同样明显。首先，强化学习算法需要大量训练数据，而真实战场数据难以获取，这限制了算法的训练效果。其次，强化学习模型的决策过程往往缺乏可解释性，即“黑箱”问题，这使得人类操作员难以理解和监督系统的决策逻辑。第三，强化学习模型在面对训练分布之外的场景时可能表现不稳定，这在军事应用中是不可接受的风险。

2.1.3 执行与效应器

执行系统负责将决策转化为实际的物理行动，包括武器发射、制导和毁伤评估。现代精确制导武器广泛采用 GPS/惯性导航、末端制导（红外、雷达、激光）等技术，实现米级甚至亚米级的命中精度。AI 技术的应用进一步提升了制导系统的自适应能力和抗干扰能力。

2.2 人工智能在核指挥控制中的应用

核指挥、控制与通信（Nuclear Command, Control, and Communications, NC3）系统是核威慑的神经系统，负责在平时、危机时期和战时确保核武器的安全、可靠和有效使用。AI 技术在 NC3 系统中的应用正在引发关于战略稳定性的深刻担忧。

2.2.1 预警与情报分析

AI 技术在预警和情报分析领域的应用最为成熟。机器学习算法能够处理来自卫星、雷达、信号情报等多源数据，自动识别异常活动模式，提高预警的及时性和准确性。例如，AI 系统可以分析导弹发射的遥测数据，预测其弹道和落点；可以识别核设施的异常活动，监测核扩散行为。

RAND Corporation 的研究指出，AI 增强的预警系统可能通过减少误判来增强危机稳定性。传统预警系统依赖于固定阈值和简单规则，容易产生虚警；AI 系统能够学习正常与异常行为的复杂模式，降低虚警率。然而，这一技术优势也伴随着风险：如果对手知道己方使用了 AI 预警系统，可能会设计针对性的欺骗策略；如果 AI 系统出现系统性偏差，可能导致大规模误判。

2.2.2 决策支持系统

AI 决策支持系统 (Decision Support Systems, DSS) 旨在辅助军事领导人在复杂时间压力下做出决策。这类系统通常整合多源情报、进行态势评估、生成行动方案并预测对手反应。在核危机情境中, DSS 可能提供关于报复选项、升级阶梯和谈判策略的建议。

然而, AI 决策支持系统对战略稳定性的影响是双刃剑。一方面, DSS 可以帮助领导人快速理解复杂态势, 避免情绪化决策; 另一方面, DSS 可能产生“自动化偏见”——即人类操作员过度依赖系统建议, 忽视系统局限性和情境特殊性。更严重的是, 如果 DSS 的建议存在系统性偏差或受到对抗性攻击, 可能导致灾难性决策。

2.2.3 通信与网络防御

AI 技术在网络防御领域的应用日益广泛, 包括入侵检测、威胁情报分析和自动响应。对于 NC3 系统而言, 网络防御至关重要, 因为网络攻击可能破坏核指挥的完整性, 制造“用或失”(use-it-or-lose-it) 的压力, 从而削弱危机稳定性。

然而, AI 驱动的网络攻防竞赛本身就可能成为不稳定因素。如果一方认为其 NC3 系统容易受到 AI 增强的网络攻击, 可能在危机中倾向于先发制人; 如果双方都发展 AI 网络攻击能力, 可能陷入“进攻优势”的不稳定困境。

2.3 人机协作与“人在回路”

“人在回路”(Human-in-the-Loop) 是自主武器治理的核心概念, 指在武器系统的决策链条中保持人类操作员的监督和控制。然而, 这一概念的技术实现远比政策声明复杂。

2.3.1 人在回路的层次模型

根据人类介入的程度和时机, 可以将人机协作分为三个层次:

(1) **人在回路中** (Human-in-the-Loop): 系统在每次攻击前都需要人类操作员的明确授权。这是目前大多数国家声称采用的模式。

(2) **人在回路上** (Human-on-the-Loop): 系统可以自主选择 and 攻击目标, 但人类操作员可以实时监控并在必要时干预。这一模式在防空系统和反舰导弹中已有应用。

(3) **人在回路外** (Human-out-of-the-Loop): 系统完全自主运行, 人类无法实时干预。这是最具争议的模式, 也是“杀手机器人”争论的焦点。

2.3.2 有意义的人类控制

国际红十字会 (ICRC) 提出了“有意义的人类控制”(Meaningful Human Control, MHC) 概念, 作为评估自主武器合法性的标准。MHC 包含三个关键要素: 人类判断 (Human Judgement)、人类监督 (Human Oversight) 和人类问责 (Human Accountability)。

然而，MHC 的技术实现面临诸多挑战。首先，战场环境的复杂性和时间压力可能使人类操作员难以做出有意义的判断。其次，AI 系统的”黑箱”特性可能阻碍有效监督。第三，当自主武器造成平民伤害时，责任归属问题难以解决。

2.4 技术局限性与风险

尽管 AI 技术在军事领域展现出巨大潜力，但其技术局限性同样不容忽视。理解这些局限性对于评估 AI 对战略稳定性的影响至关重要。

2.4.1 鲁棒性与泛化能力

机器学习模型，特别是深度学习模型，在面对训练分布之外的输入时往往表现不稳定。在军事应用中，这意味着 AI 系统可能在未预见的情境下做出错误决策。对抗性攻击研究表明，通过精心设计的输入扰动，可以使 AI 系统产生严重误判。这一脆弱性对自主武器的可靠性构成根本性挑战。

2.4.2 可解释性与透明度

深度学习模型的决策过程通常难以解释，即”黑箱”问题。在军事应用中，可解释性至关重要：操作员需要理解系统为何做出特定建议，指挥官需要评估系统建议的可信度，法律审查需要追溯决策逻辑。缺乏可解释性不仅影响操作效能，也阻碍问责机制的建立。

2.4.3 测试与验证

传统武器系统的测试和验证方法难以直接应用于 AI 系统。AI 系统的行为可能随训练数据、环境条件和对手策略而变化，这使得全面的测试覆盖几乎不可能。如何在部署前充分验证 AI 军事系统的安全性和可靠性，是一个尚未解决的技术难题。




图 1: 自主武器系统技术架构。系统由感知、决策、执行三个核心模块组成，人类通过人机接口进行监督和干预。

2.4.4 深度学习在目标识别中的应用

深度学习技术在军事目标识别领域取得了显著进展。以卷积神经网络（CNN）为代表的深度学习模型在 ImageNet 等公开数据集上展现了超越人类的图像分类能力，这一

技术突破迅速被应用于军事场景。

在目标检测任务中，YOLO (You Only Look Once) 系列算法因其高速度和高精度而被广泛采用。YOLOv5 和 YOLOv8 等最新版本能够在毫秒级时间内完成目标检测和分类，满足实时作战需求。然而，军事场景的特殊性对算法提出了额外挑战：

(1) 小目标检测：无人机或卫星图像中的军事目标往往尺寸较小，传统 CNN 架构难以有效检测。针对这一问题，研究者提出了多尺度特征融合网络，通过融合浅层和深层特征来提升小目标检测能力。

(2) 遮挡处理：战场环境中目标常被烟雾、建筑物或其他物体遮挡。基于注意力机制的检测网络能够聚焦于可见区域，提高遮挡目标的识别率。

(3) 对抗鲁棒性：敌方可能采用伪装、诱饵等手段欺骗 AI 系统。对抗训练技术通过在训练过程中引入对抗样本，增强模型的鲁棒性。

2.4.5 传感器融合技术

现代自主武器系统通常配备多种传感器，包括可见光相机、红外热像仪、合成孔径雷达 (SAR)、激光雷达 (LiDAR) 等。传感器融合技术通过整合多源信息，提高目标识别的准确性和可靠性。

早期融合 (Early Fusion) 方法在特征提取前直接融合原始数据，能够保留最完整的信息，但计算复杂度高。晚期融合 (Late Fusion) 方法分别处理各传感器数据后再融合结果，计算效率高但可能丢失互补信息。近年来，基于深度学习的中间融合 (Intermediate Fusion) 方法成为研究热点，通过在特征层面融合多源信息，兼顾了准确性和效率。

2.4.6 强化学习在战术决策中的应用

强化学习 (Reinforcement Learning, RL) 为自主武器系统的战术决策提供了强大工具。与监督学习不同，强化学习通过与环境交互来学习最优策略，特别适合动态战场环境。

在空战决策中，深度强化学习算法已展现出超越人类飞行员的能力。2016 年，美国辛辛那提大学开发的 AlphaAI 系统在模拟空战中击败了资深飞行员。该系统使用深度 Q 网络 (DQN) 学习空战机动策略，能够在复杂态势下做出快速决策。

然而，强化学习在军事应用中的局限性同样明显：

(1) 样本效率问题：强化学习通常需要大量交互样本才能收敛，而真实战场数据稀缺且获取成本高昂。模拟环境训练虽然可行，但存在仿真-现实差距 (Sim-to-Real Gap)。

(2) 可解释性问题：深度强化学习策略通常以神经网络形式存储，决策逻辑难以解释。这在需要人类监督和问责的军事应用中构成严重障碍。

(3) 安全约束问题：标准强化学习算法不考虑安全约束，可能学习到危险策略。安全强化学习 (Safe RL) 通过引入约束条件来解决这一问题，但技术尚不成熟。

2.4.7 多智能体协同决策

未来战场将涉及大量自主系统的协同作战，多智能体强化学习（Multi-Agent RL, MARL）为这一问题提供了理论框架。在 MARL 框架下，多个自主武器系统作为独立智能体，通过协作或竞争来实现共同目标。

集中训练分散执行（CTDE）是目前主流的 MARL 范式。在训练阶段，中央控制器可以访问所有智能体的信息，学习协同策略；在执行阶段，各智能体仅基于本地观测做出决策，提高了系统的鲁棒性和可扩展性。

然而，多智能体协同也引入了新的安全风险。智能体间的复杂交互可能导致涌现行为（Emergent Behavior），这些行为难以预测和控制。2019 年，美国国防高级研究计划局（DARPA）启动了“分布式协同安全”项目，旨在研究如何确保多智能体系统的行为可预测和可控制。




图 2: 战略稳定性三维框架。战略稳定性由危机稳定性、军备竞赛稳定性和威慑稳定性三个相互关联的维度构成。

2.4.8 历史案例：1983 年苏联导弹预警虚警事件

1983 年 9 月 26 日，苏联的 Oko 预警卫星系统误将云层反射的阳光识别为美国发射的洲际导弹。当时值班的苏联军官斯坦尼斯拉夫·彼得罗夫中校凭借直觉判断这是虚警，没有向上级报告，从而避免了一场可能的核战争。

这一案例对 AI 时代的战略稳定性具有重要启示：

(1) 人类判断的不可替代性：彼得罗夫的决策基于对系统局限性的理解和对情境的整体判断，这种直觉性判断是当前 AI 系统难以复制的。

(2) 自动化偏见的危险：如果当时决策完全由自动化系统做出，可能会触发报复性打击。AI 系统缺乏人类的怀疑精神和情境感知能力。

(3) 系统设计的教训：Oko 系统的缺陷在于依赖单一信息源和简单的阈值判断。现代 AI 系统虽然更复杂，但同样可能存在系统性偏差。

2.4.9 AI 预警系统的误判风险分析

AI 技术在预警系统中的应用可能引入新的误判风险。与传统基于规则的系统相比，AI 系统虽然能够学习更复杂的模式，但也可能产生难以预测的误判。

对抗性攻击风险：研究表明，深度学习模型容易受到对抗性样本攻击。攻击者可以通过精心设计的输入扰动，使 AI 系统产生严重误判。在军事场景中，这可能意味着敌方可以通过电子对抗手段诱导 AI 预警系统产生虚警或漏警。

数据污染风险：AI 系统的性能依赖于训练数据的质量。如果训练数据被恶意污染，系统可能学习到错误的模式。这种攻击难以检测，因为污染可能发生在数据收集阶段，而非系统部署后。

分布外泛化风险：AI 模型通常在特定数据分布上训练，当遇到训练分布之外的场景时，性能可能急剧下降。核危机是一种极端罕见事件，AI 系统可能缺乏处理此类场景的经验。

2.4.10 全球 AI 军事投资趋势

近年来，主要军事大国大幅增加了 AI 军事应用的投资。根据 SIPRI 和 CSET 等智库的研究数据：

美国：美国国防部 2024 财年 AI 相关预算达到 18 亿美元，较 2020 年增长超过 50%

中国：中国的 AI 军事投资数据不透明，但据估计年度投资规模与美国相当。中国在“军民融合”战略下，百度、商汤、旷视等 AI 企业深度参与国防项目。中国电子科技集团（CETC）等单位正在开发多种自主武器系统。

俄罗斯：尽管面临经济制裁，俄罗斯仍将 AI 军事应用列为优先发展方向。俄罗斯总统普京曾公开表示，“谁在 AI 领域领先，谁就将统治世界”。俄罗斯在电子战、无人系统等领域的 AI 应用投入显著。

其他国家：英国、法国、德国、以色列、日本、韩国等国也在积极发展 AI 军事能力。以色列在自主武器领域处于世界领先地位，其“哈比”（Harpy）反辐射无人机是早期自主武器的典型代表。

表 1: 主要国家 AI 军事投资对比（2020-2024）

国家	2020 年预算（亿美元）	2024 年预算（亿美元）	增长率
美国	12	18	50%
中国	10（估计）	15（估计）	50%
俄罗斯	3	5	67%
英国	2	3.5	75%
以色列	1.5	2.5	67%

2.4.11 美国政策详细分析

美国的 AI 军事政策体现了技术领先与规范塑造的双重目标。2023 年 11 月发布的《政治宣言》虽然不具有法律约束力，但为国际社会提供了负责任使用 AI 的参考框架。

宣言核心内容：

(1) **人类控制原则：**宣言强调“人类对核武器使用的控制”，要求确保核武器发射决策始终由人类做出。这一原则反映了美国对 AI 控制核武器风险的担忧。




图 3: CCW 关于 LAWS 的讨论进程时间线。从 2014 年首次讨论到 2024 年联大决议，国际社会在 LAWS 治理方面取得了渐进式进展。

(2) **测试验证要求**：宣言要求“在武器系统部署前进行严格的测试和验证”。这一要求旨在确保 AI 军事系统的可靠性和安全性。

(3) **偏见防范**：宣言要求“建立防止故障和偏见的保障措施”。这反映了美国对 AI 系统可能产生系统性偏见的担忧，特别是在目标识别和决策支持任务中。

(4) **国际法遵守**：宣言重申 AI 军事应用必须符合国际法，特别是国际人道法。

政策动机分析：

美国的渐进式立场有多重动机：首先，作为 AI 技术领先国家，美国希望保持技术发展的灵活性，避免过早承诺可能限制技术优势的约束；其次，美国认为具有法律约束力的条约难以核查，可能沦为形式；第三，美国希望通过塑造国际规范来影响其他国家的 AI 军事应用行为。

2.4.12 中国政策详细分析

中国在 AI 军事治理问题上采取积极但谨慎的立场。2023 年提出的立场文件和 2025 年中俄联合声明反映了中国对这一问题的战略考量。

核心立场：

(1) **国际法优先**：中国强调 AI 军事应用必须遵守国际法，特别是《联合国宪章》和国际人道法。这一立场与中国一贯主张的“以联合国为核心”的国际秩序观一致。

(2) **防止军备竞赛**：中国明确反对 AI 军备竞赛，呼吁各国保持克制。这一立场反映了中国对 AI 军备竞赛可能破坏战略稳定的担忧。

(3) **人类控制**：中国支持“确保人类对核武器使用的控制”，但反对全面禁止自主武器。

(4) **多边机制**：中国主张在联合国框架下讨论 AI 军事治理问题，反对单边主义和小集团政治。

战略考量：

中国的立场反映了其双重身份：作为 AI 技术大国，中国希望保持技术发展的灵活性；作为核武器国家，中国有强烈的动机防止 AI 技术破坏核威慑稳定性。此外，中国可能也希望通过积极参与 AI 治理来展示其负责任大国形象。

表 2: 主要国家 AI 军事政策立场对比

议题	美国	中国	俄罗斯
具有约束力条约	反对	有条件支持	反对
政治宣言	支持（已发起）	支持	未签署
人类控制	支持	支持	支持
完全禁止 LAWS	反对	反对	反对
CCW 进程	支持	支持	支持




图 4: 应对 AI 战略风险的技术对策体系。技术对策包括可解释 AI、安全设计和网络安全三个主要方面。

2.4.13 可解释 AI 技术路径

可解释 AI (XAI) 技术旨在使 AI 系统的决策过程对人类可理解和可解释。在军事应用中，XAI 对于确保人类监督和问责至关重要。

内在可解释模型：一类 XAI 方法致力于开发本身具有可解释性的模型架构。例如，决策树和基于规则的系统天然具有可解释性，但性能通常不如深度学习模型。近年来，研究者提出了可解释的神经网络架构，如注意力机制网络 (Attention Networks) 和概念瓶颈模型 (Concept Bottleneck Models)，在保持高性能的同时提供了一定程度的可解释性。

事后解释方法：另一类 XAI 方法在模型训练后生成解释。LIME (Local Interpretable Model-agnostic Explanations) 和 SHAP (SHapley Additive exPlanations) 是两种广泛使用的技术。LIME 通过在预测点附近拟合简单的可解释模型来解释单个预测；SHAP 基于博弈论中的 Shapley 值概念，为每个特征分配重要性分数。

军事应用挑战：XAI 在军事应用中面临特殊挑战。首先，战场环境的复杂性可能使简单解释不足以支持决策；其次，解释方法本身可能成为攻击目标，对手可能利用解释来发现系统漏洞；第三，解释的可信性需要验证，错误的解释可能比没有解释更危险。

2.4.14 AI 军控的核查技术

AI 军控的最大挑战之一是核查问题。与传统武器系统不同，AI 能力主要体现在软件算法，难以通过物理检查验证。

代码审查：一种可能的核查方法是代码审查，即允许核查人员检查 AI 系统的源代码。然而，这一方法面临多重障碍：首先，源代码是高度敏感信息，国家可能不愿分享；其次，即使检查了源代码，也难以确保部署的系统与审查的代码一致；第三，现代 AI

系统通常基于复杂的深度学习模型，”代码”本身（即模型参数）难以解释。

行为测试：另一种方法是行为测试，即通过观察系统在各种测试场景中的行为来评估其特性。这种方法的优势在于不需要访问源代码，但难以保证测试覆盖所有可能的行为。此外，被测试方可能专门针对测试场景优化系统，而在实际使用中表现不同。

计算资源监控：AI 系统的训练和运行需要大量计算资源。通过监控计算资源的使用情况，可以间接推断 AI 能力的规模。然而，云计算和分布式计算使得监控变得困难，且无法区分民用和军用 AI 应用。

数据流监控：AI 系统需要大量数据进行训练和运行。监控数据流可能提供关于 AI 系统规模和用途的信息。但数据监控涉及隐私和安全问题，实施难度较大。

2.4.15 AI 时代的危机沟通机制

在 AI 时代，有效的危机沟通机制比以往任何时候都更加重要。传统的危机沟通机制可能不足以应对 AI 带来的新挑战。

AI 事件热线：建议建立专门的热线，用于报告和讨论涉及 AI 军事系统的意外事件或技术故障。这一机制可以帮助各方及时了解 AI 相关事件，防止误判和意外升级。

技术专家对话：建立技术专家层面的定期对话机制，讨论 AI 安全性和可靠性问题。技术专家可以在较低政治压力下探讨技术细节，为官方谈判奠定基础。

危机模拟演习：定期进行涉及 AI 系统的危机模拟演习，增进各方对 AI 决策逻辑的理解。这类演习可以帮助各方了解 AI 系统在不同情境下的可能行为，提高危机管理能力。

透明度机制：建立 AI 军事应用的透明度机制，包括政策声明、能力通报和演习通报。透明度有助于建立信任、防止误判，但需要在保护国家安全与建立信任之间寻求平衡。

2.4.16 建立信任措施的历史经验

冷战时期的建立信任措施（Confidence-Building Measures, CBMs）为 AI 时代的军控提供了宝贵经验。美苏在冷战期间建立的一系列 CBMs，包括热线、预先通报机制、核查技术等，为管理核危机发挥了重要作用。

热线机制：1963 年古巴导弹危机后，美苏建立了直接通信链路（热线），使两国领导人能够在危机中直接沟通。这一机制在后续危机中多次使用，有效防止了误判和意外升级。

预先通报机制：1972 年《海上事件协定》和 1988 年《弹道导弹发射通知协定》要求双方预先通报可能引发误判的军事活动。这些机制减少了意外事件的风险，增进了相互信任。

核查技术：《中导条约》和《削减战略武器条约》建立了包括卫星侦察、现场检查、遥测监测在内的多层次核查体系。这些技术经验对于设计 AI 军控的核查机制具有重要参考价值。

AI 时代 CBMs 的适用性：冷战时期的 CBMs 经验可以部分应用于 AI 时代，但也需要适应 AI 技术的特殊性。例如，AI 系统的软件特性使得传统核查方法难以直接应用，需要开发新的技术核查手段。此外，AI 技术的快速迭代要求 CBMs 具有更大的灵活性，能够适应技术发展。

2.4.17 乌克兰冲突中的自主武器：详细分析

乌克兰冲突被广泛视为“第一场 AI 战争”，自主武器系统在冲突中得到了前所未有的应用。这一案例为理解自主武器的实际影响提供了宝贵经验。

Bayraktar TB2 无人机：土耳其制造的 Bayraktar TB2 无人机在冲突中发挥了重要作用。该无人机配备光电/红外传感器，能够执行侦察和精确打击任务。虽然 TB2 目前主要采用人在回路控制模式，但其高度自动化的目标跟踪和定位系统代表了自主武器的发展趋势。

弹簧刀巡飞弹：美国提供的弹簧刀（Switchblade）300 和 600 巡飞弹是另一种重要的自主武器。这些“神风”无人机能够在空中盘旋，搜索目标，并在发现目标后实施自杀式攻击。弹簧刀具有一定的自主目标识别能力，但攻击决策仍由人类操作员做出。

战略稳定性影响：乌克兰冲突揭示了自主武器对战略稳定性的多重影响。首先，自主武器降低了使用武力的门槛，使得小规模冲突更容易升级；其次，自主武器的扩散速度远超预期，非国家行为者也可能获得这类能力；第三，自主武器的使用引发了关于区分原则和比例原则的争议，特别是在城市环境中。

2.4.18 中美 AI 军备竞赛：深度分析

中美两国是全球 AI 军事应用的领先国家，两国在 AI 领域的竞争正在塑造全球战略格局。

美国的“第三次抵消战略”：2014 年，美国国防部提出“第三次抵消战略”，将 AI、自主系统、人机协作等新兴技术视为维持军事优势的关键。美国国防部高级研究计划局（DARPA）启动了数十个 AI 军事项目，涵盖自主空战、智能后勤、网络攻防等领域。

中国的“军民融合”战略：中国在“军民融合”战略下快速推进 AI 技术发展。中国的 AI 企业（如百度、商汤、旷视等）深度参与国防项目，为军队提供 AI 技术和解决方案。中国在无人机、无人舰艇、智能导弹等领域的进展引人注目。

竞赛的不稳定性：中美 AI 军备竞赛具有多个不稳定特征。首先，双方在 AI 能力上的信息不对称增加了误判风险；其次，先发优势激励双方加速部署，减少了充分测试和评估的时间；第三，技术竞争与地缘政治紧张相互强化，增加了危机升级的可能性。

2.4.19 以色列铁穹系统：战略稳定性分析

以色列的铁穹（Iron Dome）导弹防御系统是一个成功的 AI 军事应用案例，但也引发了战略稳定性的担忧。

系统概述：铁穹系统由雷达、指挥控制系统和拦截导弹组成。系统使用 AI 算法快速识别和跟踪来袭火箭弹，并计算最优拦截方案。自 2011 年部署以来，铁穹系统成功

拦截了数千枚火箭弹，有效保护了以色列平民。

战略稳定性悖论：铁穹系统的成功揭示了导弹防御与战略稳定性之间的复杂关系。一方面，有效的导弹防御可以减少平民伤亡，降低报复压力；另一方面，防御系统的成功可能鼓励进攻性行为，因为决策者相信可以拦截报复性打击。此外，导弹防御可能破坏相互确保毁灭的平衡，使一方认为可以首先发动攻击。

2.4.20 AI 军事应用的技术发展趋势

未来 AI 军事应用将呈现以下发展趋势：

(1) 多模态融合：未来的自主武器系统将整合更多类型的传感器和决策算法，实现更全面的态势感知。视觉、雷达、红外、信号情报等多源信息的融合将提高目标识别的准确性和可靠性。

(2) 群体智能：多个自主武器系统将通过分布式 AI 技术协同作战，形成“蜂群”效应。无人机蜂群、无人舰艇编队等概念正在从实验室走向战场。

(3) 认知电子战：AI 将使电子战系统具备自适应和学习能力，能够实时调整对抗策略。认知电子战系统可以学习敌方的通信模式，自动开发干扰策略。

(4) 生成式 AI 的军事应用：以 GPT 系列为代表的大语言模型正在探索军事应用，包括情报分析、决策支持、心理战等领域。生成式 AI 的能力也引发了关于虚假信息传播的担忧。

2.4.21 关键研究议题

未来研究应关注以下关键议题：

(1) AI 决策的可预测性：如何在复杂动态环境中确保 AI 决策的可预测性和可控制性。这涉及可解释 AI、安全强化学习、形式化验证等技术方向。

(2) 人机协作的最优模式：如何设计人机协作系统，既发挥 AI 的速度优势，又保持人类的情境判断能力。这涉及人机接口设计、任务分配、信任校准等问题。

(3) AI 军控的可行性：如何设计可核查、可执行的 AI 军控机制。这涉及技术核查方法、法律框架设计、国际谈判策略等跨学科问题。

(4) AI 伦理的国际共识：如何在不同文化和政治制度之间建立关于 AI 军事应用的伦理共识。这涉及比较伦理学、国际法、政治学等多个领域。

(5) AI 与核威慑的交叉：AI 技术如何影响核威慑的稳定性和危机管理。这是一个紧迫的政策问题，需要深入的技术和战略分析。

2.5 跨学科研究方法论

AI 与战略稳定性的研究需要整合多个学科的理论和方法。这种跨学科特性既是挑战，也是机遇。

2.5.1 技术评估方法

技术评估是 AI 战略影响研究的基础。有效的技术评估需要：

技术情报分析：通过开源情报（OSINT）、学术文献、专利分析等手段，跟踪 AI 技术的最新进展。这需要情报学、计算机科学和语言学的跨学科合作。

能力预测模型：基于技术发展趋势和历史数据，预测 AI 军事能力的未来发展。这需要运用技术预测方法，如德尔菲法、趋势外推、情景分析等。

红队分析：从对手的角度评估 AI 技术的潜在应用和威胁。这种“红队思维”有助于识别盲点，提高评估的全面性。

2.5.2 战略分析框架

战略分析需要借鉴国际关系理论和安全研究的成果：

博弈论分析：运用博弈论模型分析 AI 军备竞赛的动态和均衡。这包括静态博弈（如囚徒困境）和动态博弈（如重复博弈、不完全信息博弈）的应用。

安全困境分析：运用 Herz 和 Butterfield 的安全困境理论，分析 AI 技术发展如何引发和加剧安全困境。这需要区分防御性和进攻性 AI 应用，评估其对稳定性的不同影响。

组织过程模型：借鉴 Allison 的组织过程模型，分析 AI 决策支持系统如何影响政府决策过程。这关注组织惯例、标准操作程序对 AI 应用的影响。

2.5.3 伦理与法律分析

伦理与法律分析需要哲学、法学和国际关系的跨学科合作：

规范伦理学分析：运用义务论、功利主义、德性伦理等伦理学框架，分析 AI 军事应用的道德问题。这涉及区分原则（如区分原则、比例原则）在 AI 情境下的适用性。

国际法解释学：运用国际法解释方法，分析现有法律框架对 AI 军事应用的适用性。这包括条约解释、习惯法识别、法律原则适用等技术。

比较法研究：比较不同国家和文化背景下对 AI 军事应用的伦理和法律立场，寻找共识和分歧的根源。

3 人工智能对战略稳定性的挑战

3.1 战略稳定性的理论框架

战略稳定性理论是冷战时期发展起来的国际关系理论，旨在分析核威慑条件下的稳定与不稳定因素。传统战略稳定性包含三个相互关联的维度，AI 技术的介入正在挑战这三个维度的传统假设。

3.1.1 危机稳定性

危机稳定性（Crisis Stability）是指在核危机情境下，双方都不存在首先使用核武器的动机。危机稳定性的核心在于“用或失”困境：如果一方认为其核力量容易受到对方先发制人的打击，可能在危机中倾向于首先使用核武器，以避免失去报复能力。因此，确保二次打击能力的生存能力是实现危机稳定性的关键。

AI 技术可能通过多种机制影响危机稳定性。首先，AI 增强的侦察和跟踪能力可能使移动式导弹发射器和战略核潜艇更容易被发现和跟踪，从而削弱二次打击能力的生存能力。其次，AI 驱动的决策支持系统可能压缩危机决策时间线，使领导人面临“使用或失去”的压力。第三，AI 系统的不确定性——包括误判风险和系统故障——可能增加意外升级的可能性。

3.1.2 军备竞赛稳定性

军备竞赛稳定性（Arms Race Stability）是指双方都不存在通过发展军备获取战略优势的动机。军备竞赛稳定性的破坏可能导致安全困境的恶化：一方为增强安全而发展的武器系统，可能被对方视为威胁，从而引发对抗性军备发展。

AI 技术正在触发新一轮军备竞赛。美国、中国、俄罗斯等主要军事大国都在大力投资 AI 军事应用，涵盖自主武器、智能决策支持、网络攻防等多个领域。这种竞赛的动态具有自我强化的特征：一方的技术进步被视为威胁，刺激对方加速发展，形成恶性循环。更危险的是，AI 军备竞赛的速度可能远超传统军备竞赛，因为软件技术的迭代速度远快于硬件平台。

3.1.3 威慑稳定性

威慑稳定性（Deterrence Stability）是指双方都能够有效威慑对方的攻击，从而维持和平。威慑的有效性取决于三个要素：能力（Capability）、可信性（Credibility）和沟通（Communication）。AI 技术对这三个要素都产生了复杂影响。

在能力层面，AI 可能通过提升精确打击能力和防御系统效能来改变攻防平衡。在可信性层面，AI 增强的自动化决策可能削弱人类控制，从而影响威慑承诺的可信度。在沟通层面，AI 系统的不透明性可能阻碍有效的危机沟通和信号传递。

3.2 AI 对危机稳定性的影响机制

3.2.1 决策时间压缩

AI 技术最显著的影响之一是压缩决策时间线。传统军事决策涉及情报收集、分析、方案制定、审批等多个环节，可能需要数小时甚至数天。AI 系统能够在毫秒级时间内处理海量数据、识别威胁并生成响应建议。这种速度优势在防御性应用（如导弹防御）中可能是积极的，但在核危机情境中可能产生危险后果。

Erskine 和 Miller 的研究指出，“机器速度”战争减少了人类审议时间，增加了自动化偏见风险。当 AI 系统在危机中建议采取报复行动时，人类领导人可能因时间压力而

接受建议，而没有充分考虑情境的复杂性和升级后果。更严重的是，如果双方都部署了 AI 驱动的快速响应系统，可能形成“自动升级”的恶性循环，人类领导人甚至来不及干预。

3.2.2 误判风险增加

AI 系统可能通过多种途径增加误判风险。首先，AI 系统的训练数据可能存在偏差，导致系统对特定类型的威胁过度敏感或反应不足。其次，AI 系统可能受到对抗性攻击，对手可以通过精心设计的欺骗策略诱导系统误判。第三，AI 系统的“黑箱”特性使得人类操作员难以识别和纠正系统的错误判断。

在核危机情境中，误判的后果是灾难性的。如果 AI 预警系统错误地将常规攻击识别为核攻击，可能触发不必要的核报复；如果 AI 系统将防御性行动误判为进攻性意图，可能引发意外升级。SIPRI 的研究强调，AI 驱动的决策支持系统的模糊建议可能使决策者产生偏见，增加误判风险。

3.2.3 升级管理复杂化

危机升级管理依赖于清晰的信号传递、逐步升级阶梯和有效的沟通渠道。AI 技术可能使这些机制复杂化。首先，AI 系统的不透明性可能使对手难以理解己方的意图和能力，从而阻碍有效的信号传递。其次，AI 驱动的快速行动可能跳过传统的升级阶梯，导致“跳跃式升级”。第三，AI 系统可能破坏危机沟通渠道，例如通过 AI 生成的深度伪造信息混淆视听。

Johnson 的研究指出，AI 可能破坏信息流和有效沟通，使升级管理复杂化。在核危机中，清晰的沟通对于防止误判和意外升级至关重要。AI 技术的不确定性可能削弱沟通的可信性，增加危机失控的风险。

3.3 AI 驱动的军备竞赛动态

3.3.1 技术竞赛的加速效应

AI 军备竞赛的一个显著特征是其速度远超传统军备竞赛。传统武器系统的研发周期通常需要数年甚至数十年，而 AI 算法的迭代周期可能只有数月甚至数周。这种速度差异意味着 AI 军备竞赛可能迅速失控，国际社会难以及时建立有效的治理机制。

此外，AI 技术的军民两用性质使军备竞赛更加复杂。许多 AI 技术（如深度学习框架、计算机视觉算法）具有广泛的民用应用，难以通过传统出口管制机制进行控制。这种技术扩散的难以控制性增加了军备竞赛的不稳定性。

3.3.2 先发优势与不稳定因素

AI 技术可能创造先发优势，即首先部署 AI 军事系统的国家可能获得显著的战略优势。这种先发优势可能激励国家采取冒险行为，例如在危机中首先使用 AI 武器系统，或在和平时加速军备发展以抢占技术制高点。

更严重的是，如果一方认为对手即将获得决定性的 AI 优势，可能产生“预防性战争”的动机。这种“用或失”的压力是危机稳定性的经典威胁，AI 技术可能加剧这一威胁。

3.3.3 透明度困境

AI 军备竞赛面临“透明度困境”：一方面，透明度有助于建立信任、防止误判；另一方面，披露 AI 军事能力可能暴露技术漏洞或削弱战略优势。这一困境在 AI 核查问题上表现得尤为明显。

Arms Control Association 的研究指出，AI 在 NC3 中的整合可能产生关于能力和意图的更大模糊性，创造国家升级的动机。如何在保护国家安全与建立战略信任之间寻求平衡，是 AI 军备控制面临的核心挑战。

3.4 AI 对威慑模型的重构

3.4.1 从人类决策到算法决策

传统威慑理论假设决策主体是理性的人类领导人，能够权衡成本收益、考虑长期后果并受道德和法律约束。AI 技术的介入正在改变这一假设。当威慑决策部分或完全由算法做出时，威慑的动态可能发生根本性变化。

算法决策的特点包括：速度极快、不受情绪影响、遵循预设规则但缺乏情境判断能力。这些特点可能产生复杂影响：一方面，算法决策可能减少情绪化反应和误判；另一方面，算法可能缺乏人类的情境智慧和道德判断，在复杂情境中做出不恰当的决策。

3.4.2 相互确保毁灭的稳定性

冷战时期的核威慑建立在“相互确保毁灭”（Mutual Assured Destruction, MAD）的逻辑之上：任何一方发动核攻击都将招致毁灭性报复，因此理性行为者不会发动核战争。AI 技术可能通过多种途径影响 MAD 的稳定性。

首先，AI 增强的防御系统（如导弹防御）可能破坏 MAD 的平衡，使一方认为可以首先发动攻击并拦截报复性打击。其次，AI 驱动的快速打击能力可能使“解除武装”打击（Disarming Strike）变得可行，从而破坏二次打击能力的威慑作用。第三，AI 系统的不确定性可能削弱 MAD 的可信性，如果一方怀疑对手的报复能力，可能产生冒险动机。

3.4.3 危机稳定性的新挑战

传统危机稳定性理论强调“用或失”困境和升级阶梯的管理。AI 技术引入了新的不稳定因素。Cox 和 Williams 的研究提出了一个有趣的观点：AI 可能通过改进预警和探测来加强核稳定性。然而，这一乐观观点需要与 AI 的其他影响相权衡。

AI 可能创造“不稳定中的稳定”悖论：AI 增强的预警能力可能减少误判，但 AI 驱动的快速响应能力可能增加自动升级的风险；AI 提升的精确打击能力可能减少附带伤

害，但也可能使“有限核战争”变得可行，从而削弱核禁忌。如何在 harness AI 技术优势的同时防范其风险，是战略研究面临的核心问题。

4 国际治理框架与政策进展

4.1 国际人道法的适用性

国际人道法 (International Humanitarian Law, IHL) 是规范武装冲突中行为的国际法体系，核心原则包括区分原则 (Distinction)、比例原则 (Proportionality)、预防原则 (Precaution) 和军事必要性原则 (Military Necessity)。自主武器系统对 IHL 的适用性提出了深刻挑战。

4.1.1 区分原则的困境

区分原则要求冲突各方必须区分战斗人员与平民、军事目标与民用物体，并仅攻击前者。这是 IHL 最核心的原则之一。然而，自主武器系统能否可靠地做出这种区分，是一个极具争议的问题。

战场环境的复杂性使区分任务极其困难。平民可能穿着与战斗人员相似的服装，军事目标可能位于民用设施附近，战斗人员可能放下武器或伪装成平民。人类士兵在区分任务中都会犯错，AI 系统能否做得更好？目前的共识是，在可预见的未来，AI 系统难以在复杂战场环境中可靠地遵守区分原则。

ICRC 的立场是，自主武器系统必须受到“有意义的人类控制”，以确保遵守区分原则。然而，如前所述，MHC 的技术实现面临诸多挑战。如何在技术可行性与法律要求之间寻求平衡，是自主武器治理的核心难题。

4.1.2 比例原则与预防原则

比例原则要求攻击造成的附带伤害不得超过预期的军事利益。这一原则要求进行复杂的情境判断，权衡不同价值的冲突。自主武器系统能否做出这种判断？目前的 AI 技术显然无法胜任。

预防原则要求冲突各方在攻击前采取一切可行措施保护平民。这包括选择不会造成过度附带伤害的攻击手段、在可能时发出警告、选择适当的攻击时机等。这些要求都需要情境判断和道德考量，超出了当前 AI 系统的能力范围。

4.2 联合国《特定常规武器公约》进程

联合国《特定常规武器公约》(Convention on Certain Conventional Weapons, CCW) 是规范特定武器系统使用的国际条约框架。自 2014 年以来，CCW 政府专家组 (Group of Governmental Experts, GGE) 一直在讨论致命性自主武器系统 (LAWS) 相关的新兴技术。

4.2.1 GGE 的讨论进展

CCW GGE 关于 LAWS 的讨论经历了多个阶段。2014-2016 年，讨论主要聚焦于定义问题：什么是自主武器系统？如何界定“自主性”？2017-2019 年，讨论转向技术能力和 IHL 适用性问题。2020-2023 年，讨论进入实质性阶段，各国就治理方案展开辩论。

2024-2025 年的 GGE 会议继续审议 LAWS 相关新兴技术，并制定文书要素的滚动文本。2025 年 3 月和 9 月的会议取得了一定进展，但各国在关键问题上仍存在深刻分歧。一些国家（如美国、俄罗斯）主张渐进式方法，通过非约束性政治宣言建立规范；另一些国家（如奥地利、巴西）和民间社会组织则呼吁制定具有法律约束力的禁止条约。

4.2.2 2024 年联合国大会决议

2024 年 12 月 2 日，联合国大会通过了关于 LAWS 的历史性决议。决议以 166 票赞成、3 票反对（俄罗斯、朝鲜、白俄罗斯）、15 票弃权的结果获得通过。决议呼吁制定关于 LAWS 的具有法律约束力的文书，禁止在没有人类控制或监督的情况下运作且无法遵守国际人道法的 LAWS。

这一决议标志着国际社会对 LAWS 问题的关注达到新的高度，也反映出各国在这一问题上的深刻分歧。尽管决议本身不具有法律约束力，但它为未来的谈判提供了政治动力。

4.3 主要国家的政策立场

4.3.1 美国

美国是 AI 军事应用的领先国家，其政策立场对国际治理具有重要影响。美国政府采取渐进式方法，强调在 harness AI 技术优势的同时建立负责任使用的规范。

2023 年 11 月，美国国务院发布了《关于负责任地使用人工智能和自主性的政治宣言》（Political Declaration on Responsible Military Use of AI and Autonomy）。宣言提出了一系列负责任使用军事 AI 的原则，包括：确保人类对核武器使用的控制、在武器系统部署前进行测试和验证、建立防止故障和偏见的保障措施等。截至 2025 年，已有 60 多个国家签署了这一宣言。

然而，美国反对制定具有法律约束力的禁止条约，认为这会限制合法的自卫能力并难以核查。美国主张通过政治宣言、建立信任措施和最佳实践分享来管理风险。

4.3.2 中国

中国在 AI 军事应用领域投入巨大，同时在国际治理谈判中采取积极姿态。中国主张限制完全自主的致命性武器系统，但反对全面禁止自主武器。

2023 年，中国在联合国提出了关于规范 AI 军事应用的立场文件，强调：AI 军事应用应遵守国际法特别是 IHL；应建立有效的治理机制；应防止 AI 军备竞赛；应确保人类对核武器使用的控制。2025 年 5 月，中国与俄罗斯发表了关于全球战略稳定的联合声明，呼吁防止 AI 破坏战略稳定。

中国的立场反映了其双重利益：一方面，作为 AI 技术大国，中国希望保持技术发展的灵活性；另一方面，作为核武器国家，中国有强烈的动机防止 AI 技术破坏核威慑的稳定性。

4.3.3 俄罗斯

俄罗斯在 AI 军事应用领域同样投入巨大，特别是在自主武器和电子战方面。然而，俄罗斯在国际治理谈判中采取保守立场，反对制定具有法律约束力的文书。

俄罗斯主张通过 CCW GGE 继续讨论，但反对设定时间表或预设结果。俄罗斯的立场可能反映了其对西方技术优势的担忧，以及希望保持技术发展的灵活性。值得注意的是，俄罗斯在 2024 年联合国大会决议中投下了反对票。

4.3.4 欧盟与北约

欧盟和北约成员国在自主武器问题上立场相对一致，普遍支持建立国际规范，但在具体路径上存在分歧。欧盟强调人权和国际法的重要性，支持“有意义的人类控制”原则。北约则更多从军事效能和联盟安全的角度考虑问题，强调在保持技术优势的同时管理风险。

北约在 2024 年通过了首个人工智能战略，提出在军事领域负责任地使用 AI 的原则。战略强调：AI 应增强而非替代人类决策；AI 系统应可解释、可审计、可验证；应建立有效的治理框架。

4.4 伦理框架与“有意义的人类控制”

4.4.1 ICRC 的立场

国际红十字会（ICRC）在自主武器治理中发挥着关键作用。ICRC 的核心立场是：致命性自主武器系统必须受到“有意义的人类控制”，以确保遵守国际人道法。

ICRC 定义了 MHC 的三个关键要素：

(1) **人类判断** (Human Judgement)：人类操作员必须能够理解系统的运行环境、目标和可能的后果，并在此基础上做出道德和法律判断。

(2) **人类监督** (Human Oversight)：人类必须能够实时监控系统的行为，并在必要时干预或中止行动。

(3) **人类问责** (Human Accountability)：必须明确界定当自主武器造成违反 IHL 的行为时的责任归属。

ICRC 呼吁各国就 MHC 的定义和实现方式达成共识，并将其纳入国际法律框架。

4.4.2 Stop Killer Robots 运动

“Stop Killer Robots” 是一个由非政府组织组成的国际运动，呼吁制定具有法律约束力的条约，禁止完全自主的武器系统。该运动在 CCW GGE 谈判中发挥着重要的倡导作用。

2025 年 9 月，Stop Killer Robots 运动在 GGE 会议上发表了联合声明，认为滚动文本足以启动关于 LAWS 文书的谈判。运动呼吁各国抓住历史机遇，在 2026 年之前达成具有法律约束力的协议。

4.4.3 学术界的观点分歧

学术界对自主武器的伦理和法律问题存在深刻分歧。一派观点（以 Sparrow、Sharkey 等为代表）主张全面禁止完全自主的致命性武器，认为这类武器无法遵守 IHL，且破坏了人类对生死决策的控制。另一派观点（以 Scharre、Arkin 等为代表）则认为，自主武器在特定情境下可能比人类士兵更遵守 IHL，例如在高 G 力环境或通信中断情境中。

这一分歧反映了更深层的伦理问题：在战争伦理中，人类判断的本质价值是什么？AI 能否或应否替代人类做出生死决策？这些问题没有简单的答案，需要持续的伦理辩论和政策探索。

5 应对 AI 战略风险的策略

5.1 技术对策

5.1.1 可解释 AI 与可审计性

可解释 AI（Explainable AI, XAI）是降低 AI 军事应用风险的关键技术路径。XAI 旨在使 AI 系统的决策过程对人类可理解和可解释，从而支持有效的人类监督和问责。

在军事应用中，XAI 的重要性体现在多个方面：首先，操作员需要理解 AI 系统为何做出特定建议，以评估建议的可信度；其次，指挥官需要能够向政治领导人解释 AI 辅助决策的依据；第三，法律审查需要追溯 AI 系统的决策逻辑，以确定责任归属。

然而，XAI 的技术实现面临挑战。深度学习模型的复杂性使得完全解释其决策过程极其困难。目前的研究方向包括：开发内在可解释的模型架构、设计事后解释方法、建立可审计的决策日志系统等。

5.1.2 安全设计与故障保护

AI 军事系统的安全设计应遵循“故障安全”（Fail-Safe）原则：当系统出现故障或异常时，应自动进入安全状态，而非继续运行或采取攻击行动。

具体的安全设计措施包括：多重冗余系统、独立的监控机制、明确的权限边界、紧急中止功能等。此外，应建立严格的测试和验证程序，在部署前充分评估系统在各种情境下的行为。

5.1.3 网络安全与对抗性防御

AI 军事系统面临严重的网络安全威胁，包括数据投毒、模型窃取、对抗性攻击等。这些威胁可能使 AI 系统产生错误输出或被对手控制。

应对这些威胁需要综合的技术对策：数据验证和清洗机制、模型加固技术、对抗性训练、入侵检测系统等。此外，应建立严格的信息安全管理制度，限制对 AI 军事系统的物理和网络访问。

5.2 军控机制设计

5.2.1 AI 核查的技术挑战

传统的军控核查机制（如卫星侦察、现场检查）主要针对硬件系统（导弹、发射井、核材料等），而 AI 军事能力的核查面临根本性挑战。

首先，AI 能力主要体现在软件算法，难以通过物理检查验证。其次，AI 系统可以轻易隐藏或修改，核查时呈现的系统可能与实际部署的系统不同。第三，AI 技术的军民两用性质使区分合法与非法应用极其困难。

Mittelsteadt 的研究探讨了 AI 核查的可能路径，包括：代码审查、行为测试、计算资源监控、数据流分析等。然而，这些方法都有其局限性，难以提供可靠的核查保证。

5.2.2 限制特定应用的军控方案

鉴于全面禁止 AI 军事应用的困难，一些研究者提出限制特定高风险应用的军控方案。这些方案包括：

(1) **禁止 AI 控制核武器**：确保核武器的发射决策始终由人类做出，AI 仅发挥辅助作用。

(2) **限制“人在回路外”系统**：禁止完全自主的致命性武器系统，要求保持人类在攻击决策中的控制。

(3) **限制特定情境的自主武器使用**：例如，禁止在人口密集区使用自主武器，或禁止针对人员的自主攻击。

这些限制方案的优势在于其可核查性相对较高，且针对的是风险最高的应用场景。

5.2.3 数量与部署限制

传统军控条约常采用数量限制和部署限制来管理风险。类似的方法可以应用于自主武器：限制自主武器的数量、限制其在特定区域的部署、限制其针对特定目标类型的使用等。

然而，自主武器的数量限制面临定义难题：什么构成一个“自主武器系统”？一个软件算法是否应被计数？此外，自主武器的低成本和易于复制特性使数量限制难以执行。

5.3 建立信任措施

5.3.1 透明度与通报机制

透明度是建立战略信任的基础。各国可以通过以下措施增强透明度：

(1) **政策声明**：明确阐述本国在 AI 军事应用方面的政策立场、法律约束和伦理原则。

(2) **能力通报**：在保护敏感信息的前提下，通报 AI 军事能力的类型、数量和部署情况。

(3) **演习通报**：提前通报涉及 AI 军事系统的演习活动，避免误判。

美国发起的《负责任军事使用 AI 和自主性的政治宣言》是透明度措施的重要尝试。截至 2025 年，已有 60 多个国家签署，为建立国际规范提供了基础。

5.3.2 危机沟通机制

在 AI 时代，有效的危机沟通机制比以往任何时候都更加重要。建议建立以下机制：

(1) **AI 事件热线**：建立专门的热线，用于报告和讨论涉及 AI 军事系统的意外事件或技术故障。

(2) **危机模拟演习**：定期进行涉及 AI 系统的危机模拟演习，增进各方对 AI 决策逻辑的理解。

(3) **技术专家对话**：建立技术专家层面的定期对话机制，讨论 AI 安全性和可靠性问题。

5.3.3 Track II 外交

Track II 外交（非官方外交）在 AI 治理中可以发挥重要作用。通过学术会议、智库对话、非政府组织交流等渠道，各方可以在较低政治压力下探讨技术细节和合作可能性，为官方谈判奠定基础。

5.4 政策建议

基于上述分析，本文提出以下政策建议：

5.4.1 短期措施（1-2 年）

(1) 各国应签署并落实《负责任军事使用 AI 和自主性的政治宣言》，建立负责任使用 AI 的国际规范。

(2) 建立 AI 军事应用的透明度机制，包括政策声明、能力通报和演习通报。

(3) 加强 AI 安全研究，特别是可解释 AI、对抗性防御和故障保护技术。

5.4.2 中期措施（3-5 年）

(1) 在 CCW 框架下推进具有法律约束力的 LAWS 文书谈判，明确禁止完全自主的致命性武器系统。

(2) 建立 AI 核查的技术标准和程序，尽管完全核查可能不可行，但应建立基本的透明度机制。

(3) 建立 AI-核交叉领域的建立信任措施，包括危机沟通热线和技术专家对话。

5.4.3 长期愿景 (5-10 年)

- (1) 达成全面的 AI 军控条约，涵盖自主武器、AI 在 NC3 中的应用等关键领域。
- (2) 建立国际 AI 安全监管机构，负责监督 AI 军事应用的合规性。
- (3) 将 AI 治理纳入更广泛的战略稳定框架，与核军控、网络军控等议题协调推进。

6 案例分析

6.1 案例一：乌克兰冲突中的自主武器使用

乌克兰冲突被视为“第一场 AI 战争”，自主武器系统在冲突中得到了广泛应用。土耳其制造的 Bayraktar TB2 无人机、美国提供的弹簧刀 (Switchblade) 巡飞弹等自主或半自主系统在战场上发挥了重要作用。

这一案例揭示了自主武器在实际使用中的多个问题：首先，自主武器的使用降低了使用武力的门槛，使得小规模冲突更容易升级；其次，自主武器的扩散速度远超预期，非国家行为者也可能获得这类能力；第三，自主武器的使用引发了关于区分原则和比例原则的争议，特别是在城市环境中。

6.2 案例二：中美 AI 军备竞赛

中美两国是全球 AI 军事应用的领先国家，两国在 AI 领域的竞争正在塑造全球战略格局。美国通过“第三次抵消战略”大力投资 AI 军事应用，中国则在“军民融合”战略下快速推进 AI 技术发展。

这一竞争具有多个不稳定特征：首先，双方在 AI 能力上的信息不对称增加了误判风险；其次，先发优势激励双方加速部署，减少了充分测试和评估的时间；第三，技术竞争与地缘政治紧张相互强化，增加了危机升级的可能性。

6.3 案例三：以色列的铁穹系统

以色列的铁穹 (Iron Dome) 导弹防御系统是一个成功的 AI 军事应用案例。该系统使用 AI 算法快速识别和拦截来袭火箭弹，大大提高了防御效率。

然而，铁穹系统也引发了战略稳定性的担忧。一方面，有效的导弹防御可能破坏相互确保毁灭的平衡，使一方认为可以首先发动攻击；另一方面，防御系统的成功可能鼓励进攻性行为，因为决策者相信可以拦截报复性打击。

7 未来研究方向

7.1 技术发展趋势

未来 AI 军事应用将呈现以下发展趋势：

(1) **多模态融合**：未来的自主武器系统将整合更多类型的传感器和决策算法，实现更全面的态势感知。

(2) **群体智能**：多个自主武器系统将通过分布式 AI 技术协同作战，形成“蜂群”效应。

(3) **认知电子战**：AI 将使电子战系统具备自适应和学习能力，能够实时调整对抗策略。

7.2 研究议程

未来研究应关注以下议题：

(1) **AI 决策的可预测性**：如何在复杂动态环境中确保 AI 决策的可预测性和可控制性。

(2) **人机协作的最优模式**：如何设计人机协作系统，既发挥 AI 的速度优势，又保持人类的情境判断能力。

(3) **AI 军控的可行性**：如何设计可核查、可执行的 AI 军控机制。

(4) **AI 伦理的国际共识**：如何在不同文化和政治制度之间建立关于 AI 军事应用的伦理共识。

7.3 跨学科研究方法

AI 与战略稳定性的研究需要整合多个学科的理论和方法。这种跨学科特性既是挑战，也是机遇。

7.3.1 技术评估方法

技术评估是 AI 战略影响研究的基础。有效的技术评估需要：

技术情报分析：通过开源情报 (OSINT)、学术文献、专利分析等手段，跟踪 AI 技术的最新进展。这需要情报学、计算机科学和语言学的跨学科合作。

能力预测模型：基于技术发展趋势和历史数据，预测 AI 军事能力的未来发展。这需要运用技术预测方法，如德尔菲法、趋势外推、情景分析等。

红队分析：从对手的角度评估 AI 技术的潜在应用和威胁。这种“红队思维”有助于识别盲点，提高评估的全面性。

7.3.2 战略分析框架

战略分析需要借鉴国际关系理论和安全研究的成果：

博弈论分析：运用博弈论模型分析 AI 军备竞赛的动态和均衡。这包括静态博弈（如囚徒困境）和动态博弈（如重复博弈、不完全信息博弈）的应用。

安全困境分析：运用 Herz 和 Butterfield 的安全困境理论，分析 AI 技术发展如何引发和加剧安全困境。这需要区分防御性和进攻性 AI 应用，评估其对稳定性的不同影响。

组织过程模型：借鉴 Allison 的组织过程模型，分析 AI 决策支持系统如何影响政府决策过程。这关注组织惯例、标准操作程序对 AI 应用的影响。

7.3.3 伦理与法律分析

伦理与法律分析需要哲学、法学和国际关系的跨学科合作：

规范伦理学分析：运用义务论、功利主义、德性伦理等伦理学框架，分析 AI 军事应用的道德问题。这涉及区分原则（如区分原则、比例原则）在 AI 情境下的适用性。

国际法解释学：运用国际法解释方法，分析现有法律框架对 AI 军事应用的适用性。这包括条约解释、习惯法识别、法律原则适用等技术。

比较法研究：比较不同国家和文化背景下对 AI 军事应用的伦理和法律立场，寻找共识和分歧的根源。

8 结论

8.1 主要发现

本文系统综述了人工智能与全球战略稳定性的交叉研究领域，得出以下主要发现：

(1) **AI 技术对战略稳定性的影响是双刃剑：**AI 既可能通过提升预警能力和决策效率来增强战略稳定性，也可能通过压缩决策时间线、增加误判风险和破坏危机沟通机制来削弱稳定性。

(2) **国际治理框架尚不完善：**尽管 CCW GGE 和联合国大会已就 LAWS 问题进行了多年讨论，但各国在关键问题上仍存在深刻分歧，具有法律约束力的国际文书尚未达成。

(3) **技术对策与军控机制需要同步推进：**单纯依靠技术手段无法解决 AI 的战略风险，必须同时推进军控机制建设和建立信任措施。

8.2 政策启示

基于研究发现，本文提出以下政策启示：

(1) **优先确保人类控制：**在可预见的未来，应确保核武器和致命性武器的使用决策始终由人类做出，AI 仅发挥辅助作用。

(2) **推进渐进式军控：**鉴于全面禁止 AI 军事应用的困难，应优先限制风险最高的应用场景，如完全自主的致命性武器和 AI 控制的核武器。

(3) **加强国际合作：**AI 战略风险的全球性要求全球性的解决方案，各国应在竞争的同时保持对话，共同管理风险。

8.3 研究局限与展望

本研究存在以下局限：首先，由于 AI 军事应用的保密性，部分信息可能不完整或不准确；其次，AI 技术发展迅速，研究结论可能需要根据技术进展进行更新；第三，由

于议题的复杂性，部分分析可能过于简化。

未来研究应继续关注 AI 技术的发展动态，深入分析 AI 对战略稳定性的具体影响机制，并探索更有效的治理方案。只有通过持续的研究和对话，才能在 harness AI 技术优势的同时，有效防范其对全球战略稳定的威胁。

A 关键术语表

表 3: 关键术语定义	
术语	定义
自主武器系统 (AWS)	能够在没有人类直接干预的情况下，自主选择并攻击目标的武器系统
致命性自主武器系统 (LAWS)	能够独立选择和攻击目标的自主武器系统，通常指可能造成人员死亡的系统
有意义的人类控制 (MHC)	确保人类对武器系统使用保持充分监督和控制的原则
人在回路 (HITL)	人类在决策链条中保持实时控制和监督的模式
人在回路上 (HOTL)	人类可以监控并在必要时干预，但系统可以自主运行的模式
人在回路外 (HOOTL)	系统完全自主运行，人类无法实时干预的模式
战略稳定性	核武器国家之间避免核战争的状态，包括危机稳定性、军备竞赛稳定性和威慑稳定性
危机稳定性	在核危机情境下，双方都不存在首先使用核武器的动机
军备竞赛稳定性	双方都不存在通过发展军备获取战略优势的动机
威慑稳定性	双方都能够有效威慑对方的攻击，从而维持和平
相互确保毁灭 (MAD)	任何一方发动核攻击都将招致毁灭性报复的战略平衡状态
核指挥控制通信 (NC3)	确保核武器安全、可靠和有效使用的指挥、控制和通信系统
决策支持系统 (DSS)	辅助决策者进行信息处理和方案生成的 AI 系统
可解释 AI (XAI)	使 AI 系统决策过程对人类可理解和可解释的技术
建立信任措施 (CBM)	增进国家间信任、减少误判风险的措施

B 主要国际文件汇总

B.1 联合国相关文件

- 1. 联合国大会第 79/60 号决议 (2024 年): 关于致命性自主武器系统的决议
- 2. CCW 政府专家组报告 (2014-2024 年): 关于致命性自主武器系统的系列报告
- 3. 联合国秘书长报告 (2018 年): 关于自主武器系统的保护平民报告
- 4. 联合国裁军研究所报告 (2020 年): AI 对战略稳定性的影响

B.2 各国政策文件

- 1. 美国：《负责任军事使用 AI 和自主性的政治宣言》（2023 年）
- 2. 中国：《关于规范人工智能军事应用的立场文件》（2023 年）
- 3. 北约：《北约人工智能战略》（2024 年）
- 4. 欧盟：《关于自主武器系统的共同立场》（2021 年）

B.3 国际红十字会文件

- 1. ICRC：《自主武器系统与国际人道法》（2018 年）
- 2. ICRC：《有意义的人类控制：定义与实施》（2019 年）
- 3. ICRC：《自主武器系统的伦理考量》（2020 年）

C 主要智库与研究机构

表 4: 主要研究机构及其研究重点		
机构	所在地	研究重点
SIPRI	瑞典斯德哥尔摩	军备控制、裁军、国际安全
RAND Corporation	美国	国防政策、战略分析、技术评估
CSET	美国乔治城大学	新兴技术安全、AI 政策
CNAS	美国华盛顿	国家安全战略、国防政策
Chatham House	英国伦敦	国际安全、全球治理
IISS	英国伦敦	军事平衡、战略研究
UNIDIR	瑞士日内瓦	裁军研究、国际安全

D 研究方法说明

D.1 文献检索策略

本研究采用系统性文献综述方法，检索策略包括：

数据库检索：

- 学术数据库：IEEE Xplore、JSTOR、Web of Science、Scopus
- 预印本平台：arXiv、SSRN
- 智库数据库：SIPRI、RAND、CSET 等官方网站

检索关键词：

- 英文关键词：autonomous weapons, lethal autonomous weapons systems, AI military, strategic stability, nuclear deterrence, arms control
- 中文关键词：自主武器、致命性自主武器系统、人工智能军事、战略稳定性、核威慑、军备控制

纳入标准：

- 时间范围：2015-2025 年（优先近 5 年文献）
- 文献类型：学术期刊论文、智库报告、国际法文献、政策文件
- 语言：英文、中文

D.2 分析框架

本研究采用多维度分析框架，从技术、战略、政策和伦理四个维度分析 AI 对战略稳定性的影响。分析过程中运用了以下理论工具：

- 战略稳定性理论（Schelling、Halperin）
- 安全困境理论（Herz、Butterfield、Jervis）
- 威慑理论（Schelling、Morgan）
- 国际法理论（条约法、习惯国际法）
- 技术评估方法（红队分析、能力预测）

参考文献

- [1] Scharre, P. (2018). *Army of None: Autonomous Weapons and the Future of War*. W. Norton & Company.
- [2] Johnson, J. (2020). Artificial Intelligence: A Threat to Strategic Stability. *Air & Space Power Journal*, Vol. 14, Issue 1.
- [3] Altmann, J. & Sauer, F. (2020). Autonomous Weapon Systems and Strategic Stability. *Survival*, Vol. 62, No. 5.
- [4] United Nations General Assembly (2024). Resolution on Lethal Autonomous Weapons Systems. A/RES/79/60.
- [5] Stockholm International Peace Research Institute (2025). Impact of Military Artificial Intelligence on Nuclear Escalation Risk.
- [6] RAND Corporation (2018). How Might Artificial Intelligence Affect the Risk of Nuclear War? PE-296.
- [7] Center for Security and Emerging Technology (2023). Reducing the Risks of Artificial Intelligence for Military Decision Advantage.
- [8] Erskine, T. & Miller, S. (2024). AI Decision Support Systems and Crisis Stability. *Journal of Strategic Studies*.
- [9] International Committee of the Red Cross (2018). Autonomous weapon systems under international humanitarian law.

- [10] Center for a New American Security (2025). Averting AI Armageddon.
- [11] Cox, J. & Williams, H. (2021). The Unavoidable Technology: How Artificial Intelligence Can Strengthen Nuclear Stability. *The Washington Quarterly*, Vol. 44, No. 1.
- [12] van Diggelen, J. et al. (2023). Designing for Meaningful Human Control in Military Human-Machine Teams.
- [13] Mittelsteadt, M. (2021). AI Verification. CSET Report.
- [14] Arms Control Association (2024). Beyond a Human 'In the Loop': Strategic Stability and Artificial Intelligence.
- [15] Hagström, M. (2019). Military applications of machine learning and autonomous systems. SIPRI.
- [16] Chen, J.Q. & Wingfield, T. (2020). Human-Machine Teaming and Its Legal and Ethical Implications.
- [17] Stop Killer Robots (2025). Joint Statement at CCW GGE.
- [18] NATO (2024). NATO's Artificial Intelligence Strategy.
- [19] U.S. Department of State (2023). Political Declaration on Responsible Military Use of AI and Autonomy.
- [20] Ministry of Foreign Affairs of China (2023). Position Paper on Regulating Military Applications of AI.
- [21] Horowitz, M.C. (2018). Artificial Intelligence, International Competition, and the Balance of Power. *Texas National Security Review*.
- [22] Geist, E.M. (2019). It's Already Too Late to Stop the AI Arms Race. *Foreign Policy*.
- [23] Boulanin, V. (2019). The Impact of Artificial Intelligence on Strategic Stability and Nuclear Risk. SIPRI.
- [24] Payne, K. (2018). Artificial Intelligence: A Revolution in Strategic Affairs? *Survival*, Vol. 60, No. 5.
- [25] Kania, E.B. (2018). China's AI Dream. Center for a New American Security.
- [26] Allen, G. (2019). Understanding China's AI Strategy. Center for a New American Security.
- [27] DARPA (2019). AI Next Campaign.

[28] Future of Life Institute (2018). Lethal Autonomous Weapons Pledge.

[29] IEEE (2017). Ethically Aligned Design: A Vision for Prioritizing Human Well-being with Autonomous and Intelligent Systems.

[30] United Nations Institute for Disarmament Research (2020). The Impact of Artificial Intelligence on Strategic Stability and Nuclear Risk.

A 关键术语表

表 5: 关键术语定义	
术语	定义
自主武器系统 (AWS)	能够在没有人类直接干预的情况下, 自主选择并攻击目标的武器系统
致命性自主武器系统 (LAWS)	能够独立选择和攻击目标的自主武器系统, 通常指可能造成人员死亡的系统
有意义的人类控制 (MHC)	确保人类对武器系统使用保持充分监督和控制的原则
人在回路 (HITL)	人类在决策链条中保持实时控制和监督的模式
人在回路上 (HOTL)	人类可以监控并在必要时干预, 但系统可以自主运行的模式
人在回路外 (HOOTL)	系统完全自主运行, 人类无法实时干预的模式
战略稳定性	核武器国家之间避免核战争的状态, 包括危机稳定性、军备竞赛稳定性和威慑稳定性
危机稳定性	在核危机情境下, 双方都不存在首先使用核武器的动机
军备竞赛稳定性	双方都不存在通过发展军备获取战略优势的动机
威慑稳定性	双方都能够有效威慑对方的攻击, 从而维持和平
相互确保毁灭 (MAD)	任何一方发动核攻击都将招致毁灭性报复的战略平衡状态
核指挥控制通信 (NC3)	确保核武器安全、可靠和有效使用的指挥、控制和通信系统
决策支持系统 (DSS)	辅助决策者进行信息处理和方案生成的 AI 系统
可解释 AI (XAI)	使 AI 系统决策过程对人类可理解和可解释的技术
建立信任措施 (CBM)	增进国家间信任、减少误判风险的措施

B 主要国际文件汇总

B.1 联合国相关文件

1. 联合国大会第 79/60 号决议 (2024 年): 关于致命性自主武器系统的决议
2. CCW 政府专家组报告 (2014-2024 年): 关于致命性自主武器系统的系列报告
3. 联合国秘书长报告 (2018 年): 关于自主武器系统的保护平民报告
4. 联合国裁军研究所报告 (2020 年): AI 对战略稳定性的影响

B.2 各国政策文件

1. 美国：《负责任军事使用 AI 和自主性的政治宣言》（2023 年）
2. 中国：《关于规范人工智能军事应用的立场文件》（2023 年）
3. 北约：《北约人工智能战略》（2024 年）
4. 欧盟：《关于自主武器系统的共同立场》（2021 年）

C 主要智库与研究机构

表 6: 主要研究机构及其研究重点

机构	所在地	研究重点
SIPRI	瑞典斯德哥尔摩	军备控制、裁军、国际安全
RAND Corporation	美国	国防政策、战略分析、技术评估
CSET	美国乔治城大学	新兴技术安全、AI 政策
CNAS	美国华盛顿	国家安全战略、国防政策
Chatham House	英国伦敦	国际安全、全球治理
IISS	英国伦敦	军事平衡、战略研究
UNIDIR	瑞士日内瓦	裁军研究、国际安全

D 研究方法说明

D.1 文献检索策略

本研究采用系统性文献综述方法，检索策略包括：

数据库检索：

- 学术数据库：IEEE Xplore、JSTOR、Web of Science、Scopus
- 预印本平台：arXiv、SSRN
- 智库数据库：SIPRI、RAND、CSET 等官方网站

检索关键词：

- 英文关键词：autonomous weapons, lethal autonomous weapons systems, AI military, strategic stability, nuclear deterrence, arms control
- 中文关键词：自主武器、致命性自主武器系统、人工智能军事、战略稳定性、核威慑、军备控制

纳入标准：

- 时间范围：2015-2025 年（优先近 5 年文献）
- 文献类型：学术期刊论文、智库报告、国际法文献、政策文件
- 语言：英文、中文

D.2 分析框架

本研究采用多维度分析框架，从技术、战略、政策和伦理四个维度分析 AI 对战略稳定性的影响。分析过程中运用了以下理论工具：

- 战略稳定性理论（Schelling、Halperin）
- 安全困境理论（Herz、Butterfield、Jervis）
- 威慑理论（Schelling、Morgan）
- 国际法理论（条约法、习惯国际法）
- 技术评估方法（红队分析、能力预测）