

强化学习飞行控制综述

——单旋翼/多旋翼、固定翼与 VTOL 平台的发展历程、主流方法与最新进展

文档类型：长篇技术综述

语言：中文

版本：2026 年 3 月整理版

撰写说明：面向飞行控制与智能控制研究人员，重点突出强化学习在不同飞行平台中的控制定位、算法选择逻辑、可迁移经验与研究空白。

摘要

强化学习 (Reinforcement Learning, RL) 在飞行控制中的角色, 已经从早期“能否学会基本稳定控制”的概念验证, 逐步演化为“能否在复杂非线性、强耦合、受约束、带扰动、可迁移到真实系统的条件下, 形成可部署、可验证、可扩展的控制器”这一更高层级的问题。飞行器平台之间的差异极大: 单旋翼/多旋翼平台具有欠驱动、快时标、姿态耦合强与对执行器延迟敏感等特点; 固定翼平台具有包线约束更强、气动模型更复杂、失速与高迎角工况更具挑战的特点; VTOL 平台则同时继承了旋翼悬停与固定翼巡航的双重特征, 并在模式切换与过渡飞行阶段表现出最显著的多模态非线性。因而, RL 在三类平台上的发展路径并不完全一致: 旋翼类平台最早成为低层控制与敏捷机动的主要试验田, 固定翼平台更多围绕姿态/轨迹/着陆/机动展开, VTOL 研究则高度聚焦于悬停—巡航转换、甲板/平台着陆以及分阶段混合控制。

本文系统综述 RL 飞行控制的发展历程、算法谱系与最新研究动态, 并将问题划分为单旋翼/多旋翼、固定翼以及 VTOL 三类飞行平台进行比较分析。全文首先讨论 RL 在飞行控制中的问题建模方式, 包括状态构造、动作表示、奖励函数、安全约束、训练—部署闭环、仿真环境与 sim-to-real 迁移。随后分别梳理三类平台在不同阶段的代表性研究: 在单旋翼/多旋翼方向, 早期真实直升机模型学习与学徒学习工作奠定了 RL 航空控制的原型, 之后以 PPO、DDPG、SAC、TD3 等为核心的深度 RL 推动了四旋翼姿态控制、轨迹跟踪、鲁棒控制、零样本迁移与高速竞速; 在固定翼方向, 研究从离散动作的姿态控制与自动着陆, 发展到样本高效的真实飞行部署、特技机动、高迎角控制、视觉避障与模型学习辅助控制; 在 VTOL 方向, 研究重点集中于过渡飞行、甲板着陆、模式切换、分层/多智能体控制以及带先验约束的奖励设计。

本文重点总结三类平台各自的主流算法与方法选择逻辑：多旋翼平台主流方法已由早期的 DQN/TRPO/PPO 过渡到基于连续动作的 actor-critic 家族，尤其是 PPO、SAC、TD3 及其鲁棒变体；固定翼平台中，PPO 与 SAC 常用于姿态/轨迹学习，结合递归结构、延迟建模、域随机化与系统辨识的策略在真实飞行中更具优势；VTOL 平台则更强调分阶段设计、混合专家结构、模型辅助奖励与多智能体 SAC/PPO。对于最新进展，本文特别讨论 2024–2026 年期间围绕零样本 sim-to-real、故障容错、模型—数据融合、数字孪生、轻量化网络、物理先验稀疏 RL 以及部署就绪性评估等方向的工作，并据此分析当前领域的共识：单纯追求仿真回报已不再足够，真正的前沿正转向“安全、可信、样本高效、可解释、可认证”的部署级 RL 飞行控制。

关键词：强化学习；飞行控制；四旋翼；直升机；固定翼；VTOL；深度强化学习；sim-to-real；安全强化学习；自主飞行

目录说明

本文按照“共性方法层—平台层—综合比较层—展望层”组织。由于用户要求篇幅不少于 50 页，文稿采用长篇综述体例：每个平台均包含发展历程、任务类型、主流算法、代表性工作、最新进展、优缺点与未来方向，并辅以总结表格，便于后续扩展为学位论文绪论或期刊综述初稿。

1 引言

飞行控制长期以来主要建立在模型驱动范式之上：小扰动线性化、增益调度、PID、LQR/LQG、 H_∞ 、反步、滑模、模型预测控制（MPC）以及自适应控制构成了现代飞行器控制的主干。它们在工程上成熟、可解释、便于分析稳定性与鲁棒性，但面对强非线性、多工况包线、复杂耦合、执行器饱和与环境不确定性时，传统模型驱

动方法的设计与调参成本会显著增加。尤其是在小型无人飞行器、敏捷机动、高迎角飞行、甲板起降与强扰动环境中，精确建模的边际收益下降，而数据驱动优化策略的吸引力逐渐上升。

RL 的吸引力在于其“从交互中学习控制律”的能力。与监督学习相比，RL 不要求给定每个状态的标签动作；与传统最优控制相比，RL 在理论上可以直接面向长期累积回报优化，而无需显式求解复杂的高维 Hamilton-Jacobi-Bellman 方程。对于飞行控制来说，RL 允许研究者把跟踪误差、能耗、平滑性、姿态约束、速度包线、着陆成功率等多个目标统一纳入奖励函数，在统一框架下学习状态到动作的映射。

然而，飞行控制也是 RL 最难落地的领域之一。原因并不只是“安全要求高”，还包括：其一，飞行系统通常处于连续状态—连续动作空间，许多早期离散动作 RL 方法在控制精度上天然受限；其二，飞行器动力学时标快、噪声强、延迟显著，策略对输入表示、观测历史、执行器建模极为敏感；其三，真实飞行实验成本高、失败代价大，使得大规模在线探索几乎不可接受；其四，从仿真到现实存在复杂的 reality gap，包含结构参数误差、气动模型误差、传感器噪声、通信延迟、未建模扰动与地面效应等。

因此，飞行控制中的 RL 研究并不是简单地把通用算法“套到飞行器上”，而是形成了一条独立演化的技术路线：先在高保真仿真中学习，再借助系统辨识、域随机化、奖励重设计、动作平滑、观测扩展、课程学习、残差控制、混合专家或模型辅助等方法实现策略的稳定训练与真实部署。对于不同平台，路线又呈现出明显差异。多旋翼平台具备结构相对标准化、室内试验便利、机体系控制直接等优势，因而成为低层

RL 控制最活跃的平台；固定翼平台由于气动更复杂、动态包线更强、外场实验门槛高，研究数量相对少但更强调数据效率与真实可飞；VTOL 平台则面对典型的多模态控制切换问题，是检验 RL 分层化与混合控制思想的重要场景。

从时间线上看，RL 飞行控制经历了几个阶段。第一阶段可以追溯到 2000 年代初真实无人直升机上的模型学习与学徒学习工作，这些研究证明了“RL/模仿学习可直接生成飞行控制策略”。第二阶段大致出现在 2015–2019 年，伴随深度 RL 在机器人领域爆发，四旋翼成为主要验证平台，PPO、TRPO、DDPG 等开始被用于姿态与轨迹控制。第三阶段为 2020–2023 年，研究重心转向 sim-to-real、高机动飞行和更复杂任务，例如固定翼特技机动、四旋翼敏捷竞速、样本高效真实部署。第四阶段则是 2024 年以来逐步显现的“部署就绪”阶段，特点是更加关注零样本迁移、故障容错、物理先验融合、模型辅助与安全认证。

本文的核心目标不是简单罗列文献，而是回答以下问题：第一，RL 为什么会在不同平台上呈现不同的主流算法选择？第二，各平台从“能学会”走向“能部署”的关键瓶颈是什么？第三，2024–2026 年最新进展相较过去真正改变了什么？第四，如果将来要为某一类飞行器设计 RL 控制器，应优先采用什么样的技术组合？

2 强化学习飞行控制的共性问题与算法谱系

2.1 控制问题的强化学习建模

在飞行控制中，状态通常不是“全状态”而是“可观测代理状态”。对四旋翼而言，常用状态包含位置、速度、姿态矩阵/四元数、角速度、目标误差、历史动作以及参考轨迹局部窗口；对固定翼而言，还常需加入空速、迎角、侧滑角、升降舵/副翼/方向舵状态、推力与气动相关量；对 VTOL 来说，模式变量、倾转角、推力分配、过渡相

位指标以及风场估计常常不可忽略。由于真实平台存在部分可观测性，仅用瞬时状态往往不足以支撑稳定控制，因此很多工作引入帧堆叠、延迟状态、LSTM/GRU 或时间编码。

2.2 动作空间设计

动作空间设计几乎决定了可学性上限。早期工作常将动作离散化为“增减舵量/油门”或“预定义 PWM 档位”，便于使用 DQN 类算法，但会引入量化误差、振荡和控制不连续。随着 actor-critic 方法成熟，连续动作成为主流：多旋翼多采用总推力加机体角速度、单电机推力、PWM 增量或姿态参考；固定翼则多采用三舵面加油门、姿态参考率或外回路参考量；VTOL 还可能同时输出螺旋桨推力、倾转机构角度和模式切换参数。为保证平滑性，近年常在奖励中加入动作变化惩罚，或在策略后级加低通滤波、动作约束层、参考跟踪内环。

2.3 奖励函数的设计哲学

飞行控制的奖励函数通常由任务误差项、稳定性项、能量/控制 effort 项、约束惩罚项和终止项构成。以轨迹跟踪为例，位置误差、速度误差、姿态误差和角速度误差构成主项，动作平方与动作增量用于抑制高频抖振，越界、碰撞、失速、倒扣过载等触发大额终止惩罚。值得注意的是，奖励不是越复杂越好。许多近年工作指出，过多手工 shaping 虽有助于早期训练，但也可能固化次优行为。部署级控制更需要“足够稀疏但物理意义明确”的奖励，并结合课程学习逐步增加任务难度。

2.4 值函数方法、策略梯度与 actor-critic

从算法谱系看，飞行控制早期一部分研究沿用 Q-learning 或 DQN 的离散框架，适合自动着陆、决策切换等离散动作问题；但对低层连续控制而言，DDPG、TD3、

PPO、TRPO、SAC 更加主流。PPO 因更新稳定、实现简单、对超参数相对不太敏感，在学术文献和工程原型中极为常见；SAC 则凭借最大熵机制带来较好的探索与鲁棒性，在连续控制和 sim-to-real 中越来越受重视；TD3 通过双评论家与延迟更新缓解 DDPG 的过估计问题；TRPO 在早期因策略更新有理论约束而常见，但工程使用频率已被 PPO 大幅取代。

2.5 模型辅助与模型基础强化学习

模型辅助 RL 在飞行控制中意义尤其重大，因为真实数据昂贵。基于学习动力学模型的 MPC、世界模型、MBPO、Dreamer、弱模型辅助控制、残差模型校正以及数字孪生框架，都试图降低样本复杂度并提高部署可解释性。飞行器不同于一般地面机器人，其动力学结构先验较强，因此完全抛弃模型并不经济。近年来更有潜力的路线其实是“灰箱化”：保留刚体运动学、主要气动/推力结构与控制分配模型，再用学习方法补偿未建模项。

2.6 安全强化学习与约束处理

飞行控制必须把安全约束前置，而不能仅靠训练后测试筛选。常见做法包括：动作裁剪、控制屏障函数（CBF）或可行集投影、安全过滤器、基于 Lyapunov/Barrier 的 RL、shielding、基于 MPC 的外层安全监督以及失败恢复控制器。对固定翼与 VTOL 而言，包线约束如失速迎角、最大滚转/俯仰、最小空速、切换高度等尤为重要。对多旋翼而言，电机饱和、姿态角限制与地面接触安全同样关键。

2.7 sim-to-real 与部署链路

过去几年最重要的共识之一是：策略网络本身并不是 sim-to-real 成功的决定因素，输入输出接口、系统辨识、随机化范围、延迟与噪声建模、参考轨迹分布、动作

平滑和硬件计算约束反而更重要。成功的部署级方案往往采用高保真模拟器（如 Gazebo、AirSim、Flightmare、JSBSim、FlightGear 等）配合系统辨识，再通过 selective domain randomization、延迟注入、观测噪声、风扰建模、控制频率匹配和安全保护逻辑实现迁移。

2.8 评估指标

飞行 RL 不能只看 episodic return。更有解释力的指标包括：稳态误差、RMSE、上升/调节时间、超调量、控制能耗、动作频谱、失效率、恢复时间、包线违例率、着陆成功率、仿真-现实性能偏差、训练样本量、推理时延、板载计算占用和对参数扰动的灵敏度。对于竞速/机动任务，还需加入圈速、门洞通过率、最小距离与轨迹鲁棒性。

2.9 飞行控制常用 RL 方法的适配性比较

方法	动作空间	优点	局限	典型适用平台/任务
DQN/Double DQN	离散	实现简单，适合模式切换与离散决策	不适合精细连续控制，动作量化明显	自动着陆阶段决策、离散航迹控制、部分固定翼任务
TRPO/PPO	连续/离散	训练稳定，工程使用广，易并行采样	样本效率一般，需较多仿真	四旋翼姿态/轨迹、固定翼姿态、VTOL 着陆
DDPG	连续	可直接输出连续动作，适合低层控制	对超参数和噪声敏感，易过估计	早期四旋翼与固定翼连续控制
TD3	连续	比 DDPG 更稳，缓解 Q 值过估计	仍依赖高质量经验回放	四旋翼轨迹、鲁棒控制
SAC	连续	探索强、鲁棒性较好、适合连续控制	温度与奖励尺度敏感，训练代价较高	四旋翼/固定翼/VTOL 的主流候选
模型辅助 RL	连续/离散	样本效率高，易融入先验	模型偏差可能误导策略	固定翼真实部署、VTOL 过渡控制

层次化/多智能体 RL	混合	适合复杂任务分解 和多通道耦合	训练复杂，信用分 配困难	VTOL 过渡、编 队、多旋翼协同
安全 RL/屏蔽式 RL	连续/离散	更适合安全关键场 景	实现复杂，可能压 制探索	真实飞行部署、故 障容错、包线保护

表 2-1 反映了一个非常重要的现实：飞行控制中的“主流算法”并不是某单一最优解，而是由平台物理特性、动作定义、部署约束和训练资源共同决定。多旋翼低层控制最常见的是 PPO 与 SAC；固定翼更看重样本效率与延迟建模，PPO/SAC/模型辅助方案更占优势；VTOL 往往需要分阶段或多智能体结构。

3 单旋翼/多旋翼平台：从真实直升机先驱到零样本四旋翼控制

旋翼平台是 RL 飞行控制最活跃的试验场，但“单旋翼”和“多旋翼”并不应简单合并。单旋翼直升机具有旋翼—机身耦合、尾桨反扭矩、气动非线性更强、建模复杂度更高等特征；多旋翼尤其是四旋翼，虽然同样欠驱动，但结构标准化程度高、动力学形式相对统一、实验与仿真工具成熟，因此成为深度 RL 低层控制研究的主阵地。

从历史上看，真正意义上的 RL 飞行控制先驱并不是四旋翼，而是无人直升机。2003 年 Ng、Kim、Jordan 与 Sastry 团队在真实直升机上开展了“自主直升机飞行 via RL”的工作，采用先学习随机非线性动力学模型、再进行策略优化的思路，证明 RL 可以在强噪声、高不确定的飞行系统中产生可用控制策略。此后 Abbeel 等于 2006 年进一步结合学徒学习，实现了真实 RC 直升机的翻滚、漏斗等特技机动，成为航空学习控制的里程碑。2008 年左右还有针对直升机自转下滑（autorotation）等高度非线性机动的 RL 尝试。

这些早期工作尽管与当今“深度 RL 端到端低层控制”并不完全相同，但它们奠定了三个影响深远的观点：第一，复杂飞行器可以通过数据驱动学习高性能控制器；第

二，仅靠离线专家演示或少量真实数据也可能获得可部署策略；第三，飞行控制中的学习器必须与高质量动态模型、专家先验和安全试飞流程强绑定。后来四旋翼上的许多成功经验，本质上都可以看作这三点原则在更现代算法上的延续。

3.1 发展历程分期

(1) 先驱阶段：真实直升机与模型学习/学徒学习（约 2003–2010）。这一阶段的关键词不是“深度网络”，而是“飞行器学习控制是否可行”。代表工作以真实无人直升机为对象，使用模型学习、策略搜索和模仿/学徒学习，让系统完成悬停、机动甚至倒飞和特技。受制于计算资源与传感器条件，这一阶段更强调小数据、强先验与安全试飞，而非大规模端到端训练。

(2) 深度 RL 导入阶段：仿真四旋翼姿态控制（约 2015–2019）。随着 DDPG、TRPO、PPO 等算法兴起，研究者开始在 Gazebo、RotorS、AirSim 等环境中训练四旋翼姿态控制器。2018/2019 年前后，Koch 等工作系统比较了 DDPG、TRPO、PPO 在四旋翼内环姿态控制中的表现，并构建开源高保真环境，推动该方向形成可复现实验基线。此时研究目标主要是悬停、姿态跟踪和简单轨迹。

(3) 任务扩展阶段：轨迹跟踪、鲁棒控制与视觉控制（约 2020–2023）。在这一阶段，四旋翼 RL 从纯姿态控制扩展到位置控制、轨迹跟踪、视觉伺服、编队包围、故障鲁棒性与复杂环境导航。算法上，PPO、SAC、TD3 逐渐取代早期 DDPG 成为主流；方法上，域随机化、课程学习、专家初始化与混合控制器开始普及。

(4) 部署突破阶段：高敏捷与零样本 sim-to-real（约 2023–至今）。Nature 2023 的冠军级无人机竞速工作显示，深度 RL 可在高机动竞速场景达到甚至超越人类冠军

水平，标志着 RL 从“可控制”向“可高性能机动”迈进。2024–2025 年的一系列工作则围绕零样本 sim-to-real、选择性随机化、时间向量、动作平滑正则、变换器动力学模型与故障容错展开，说明多旋翼 RL 的核心问题已从控制能力转向部署可靠性。

3.2 单旋翼直升机方向：早期里程碑与近期回潮

单旋翼直升机研究虽然数量不如四旋翼庞大，但其学术地位非常高，因为很多早期里程碑都出自这一平台。真实直升机的飞行控制难点在于：旋翼挥舞、尾桨配平、耦合强、低速悬停和特技机动均高度不稳定，而且传感与估计噪声显著。Ng 等 2003 年工作采用先学习动态模型再做策略搜索；Abbeel 等 2006 年进一步利用学徒学习获得专家级特技机动能力，这些成果使“用学习方法做飞行控制”从概念走向现实。

进入深度 RL 时代后，单旋翼研究相对沉寂，原因在于实验门槛高、开源平台少、仿真环境不如四旋翼统一。但近两年出现了一种“回潮”：研究者开始将自适应评论家设计（adaptive critic design）、在线最优控制、输入饱和与状态约束处理引入直升机系统。2024 年有工作面向直升机在输入饱和和状态约束下的鲁棒跟踪控制，说明直升机方向正从历史性的演示案例，逐渐重新进入现代 RL 控制的研究视野。

从方法上看，单旋翼方向更偏好“带结构先验的 RL”而非完全黑箱端到端方法。原因在于其气动复杂、试飞风险高，任何可利用的刚体动力学、配平关系、包线边界与专家演示都具有很高价值。因此，模仿学习 + RL、模型辅助 RL、约束最优控制 + RL 以及可解释的自适应动态规划，都比纯 SAC/PPO 黑箱端到端更容易被接受。

3.3 多旋翼平台：主流算法为何集中在 PPO、SAC 与 TD3

四旋翼等多旋翼平台之所以成为深度 RL 控制的主战场，根本原因在于其“工程可重复性”优于其他平台：机构相对统一，状态估计成熟，仿真器和控制栈丰富，且大

量任务可以在室内或小尺度外场完成。与此同时，多旋翼又足够具有挑战性：欠驱动、姿态与平移耦合、电机动力学和推力饱和明显、对延迟极其敏感，因此非常适合作为 RL 算法的试金石。

PPO 在四旋翼研究中长期占据高频地位，原因并非其样本效率最好，而是它对奖励噪声、并行采样和超参数的鲁棒性较强，适合快速建立工作基线。对于使用矢量化仿真环境批量并行训练的研究来说，PPO 往往能在相对可控的代价下学出平稳策略。其缺点在于需要大量仿真样本，且在动作连续且控制频率高时，若奖励设计不当容易出现“平稳但保守”的策略。

SAC 近年在多旋翼上越来越受重视，主要由于其最大熵框架在复杂连续动作控制中提供了更好的探索与鲁棒性，并且经验回放提升了样本利用率。很多部署工作发现，在加入动作平滑、系统辨识和适当的随机化后，SAC 更容易训练出在真实飞行中表现自然、鲁棒且不抖振的控制器。TD3 则常作为比 DDPG 更稳定的连续控制基线，尤其适用于轨迹跟踪与鲁棒控制。

相反，DDPG 在文献中虽然历史地位重要，但已经不再是首选：其过估计与对噪声敏感的问题，在高频飞行控制中会被放大。TRPO 则因实现成本高、与 PPO 相比性价比不再突出而逐渐淡出。DQN 类方法依然存在于离散动作着陆、视觉决策与模式切换场景，但不再适合高精度内环控制。

3.4 多旋翼典型任务与主流方法

任务类型	控制层级	典型状态	典型动作	主流方法
姿态稳定/内环控制	低层	姿态、角速度、参考姿态	角速度命令或电机推力/PWM	PPO、SAC、TD3、残差 RL

悬停与位置控制	中低层	位置、速度、姿态、目标误差	总推力+姿态参考	PPO、SAC、层次化 RL
轨迹跟踪	中层	轨迹局部窗口、速度、姿态、历史动作	机体系推力/角速率	PPO、TD3、SAC、模型辅助 RL
视觉伺服/避障	中高层	图像、深度、IMU、目标信息	速度/姿态命令	PPO、A2C、视觉 DRL、模仿学习 +RL
编队/围捕/协同	高层或分布式	自身/邻机/目标相对状态	速度或航向/推力参考	多智能体 RL、CTDE、SAC/PPO
故障容错/强扰动恢复	低中层	、故障指示、历史动作	冗余推力或控制增益	鲁棒 RL、残差 RL、安全 RL
敏捷竞速/高机动飞行	全栈	门洞几何、姿态、速度、未来轨迹	推力与角速度	深度 RL、模仿学习+RL、模型辅助

从表 3-1 可以看到，多旋翼的 RL 应用已经覆盖从内环到高层任务的几乎全链路。其中真正推动领域边界的，是那些把“低层控制稳定性”和“高层任务激进性”同时纳入设计的研究。

3.5 代表性研究脉络

Koch 等在 2018/2019 年关于 UAV attitude control 的研究，重要性不只是比较了 DDPG、TRPO、PPO 的性能，更在于它将 RL 四旋翼控制转化为可复现的工程问题：明确了状态、动作、控制频率、仿真噪声与评价指标。这类工作让后续研究能建立统一基线，而不再停留在“训练出一个会飞的策略”的展示层面。

2022 年前后，一类典型工作开始尝试将 RL 直接映射到四个电机 PWM，追求更端到端的控制链路。这种方法的意义在于减少中间控制器的先验假设，但同时也对奖励、动作平滑和执行器模型提出更高要求。相较之下，许多更成功的真实部署方案会

选择输出总推力与机体角速度命令，再由底层混控器进行分配，这是一种在性能与可部署性之间更稳健的折中。

2023 年的冠军级无人机竞速工作把 RL 推向新高度。该工作采用深度 RL 学习高敏捷竞速策略，在真实比赛中达到甚至超过人类顶尖飞手水平，显示 RL 不只是能稳定控制，还能在极端高速和复杂轨迹条件下形成高性能闭环行为。这一结果对领域影响巨大：它证明了在合适的观测、动作定义与训练流程下，RL 可以在飞行控制中体现出超越传统局部最优控制的优势。

2024 年以来，更细致的研究开始追问：零样本 sim-to-real 到底依赖什么？一项系统性研究指出，速度与旋转矩阵进入 actor、时间向量进入 critic、动作差分正则、选择性域随机化以及大 batch 训练，是实现可零样本部署多旋翼控制的重要因素。与此同时，也有工作通过变换器动力学模型减少 sim-to-real 调参与附加微调成本；另一些工作则把故障容错与在线适应模块结合，使策略能对未见机型或故障模式进行泛化。

3.6 2024-2026 年最新进展

第一类进展是“零样本迁移条件的机制化总结”。过去很多 sim-to-real 成功案例高度依赖经验与隐式技巧，难以复现。近期工作尝试把这些技巧从经验总结上升为可操作原则：不是无差别地扩大随机化范围，而是围绕与部署最相关的参数进行选择性的随机化；不是一味加复杂奖励，而是优先确保观测足够、动作平滑、延迟匹配和参考分布覆盖真实任务。

第二类进展是“故障容错与在线适应”。2025 年有研究提出将 RL 飞控与基于 Transformer 的在线适应模块结合，用潜在表示实时推断未知系统模型，以应对执行

器故障或机体变化。这类工作说明，纯静态策略已不足以满足复杂平台部署要求，未来飞控 RL 很可能是“基础策略 + 在线识别/适配器”的组合。

第三类进展是“从单一性能到部署就绪性评估”。2026 年关于 UAV control 的综述型工作开始把 PPO、DQN、DDPG、TD3、SAC 的比较，扩展到训练稳定性、样本效率、控制平滑性、仿真器支持、硬件适配与部署成熟度。这意味着研究社区开始以更工程化的指标看待 RL 飞控，而不再只比较最终回报。

第四类进展是“高保真数字孪生与模型融合”。对于多旋翼来说，系统辨识与随机化已经是常规做法，但新的趋势是把更准确的数字孪生环境、传感器时延链路和实际控制器软件栈直接纳入训练回路，以缩短仿真—真实之间的实现差异。

3.7 单旋翼/多旋翼方向的阶段性结论

总体而言，旋翼平台的主线已经非常清晰：若目标是构建稳健基线，PPO 仍然是最省心的选择；若目标是连续控制性能与部署鲁棒性的平衡，SAC 往往更具吸引力；若强调样本效率与可解释性，则模型辅助/残差 RL 更值得考虑。对于真实平台部署，不建议直接从离散 DQN 或完全黑箱电机级控制开始，而更适合采用“参考命令级输出 + 动作平滑 + 延迟建模 + 系统辨识 + 安全屏蔽”的组合。

单旋翼方向未来的增量空间很大，尤其是在把早期直升机学习控制传统与现代深度 RL 结合方面。多旋翼方向则已经从“有没有可能”进入“怎样部署得更稳、更安全、更可复现”的阶段。

4 固定翼平台：从姿态控制到特技机动、着陆与复杂任务

固定翼飞行器与多旋翼平台在 RL 控制上的差异，首先体现在动力学与约束层面。固定翼依赖气动升力维持飞行，空速、迎角、侧滑角与控制面偏转之间存在更强的非线性耦合；同时，固定翼通常必须满足最小空速、失速边界、过载限制和更严格的飞行包线约束。与四旋翼“理论上可以原地悬停并缓慢试错”不同，固定翼的许多失败不可逆，真实试飞风险更高。

这使得固定翼 RL 发展明显慢于多旋翼，但并不意味着其研究价值较低。恰恰相反，固定翼是检验 RL 是否真正具备“控制学意义”的关键平台：因为许多经典控制难点——如高迎角机动、耦合姿态-速度控制、自动着陆、复杂风场下跟踪、特技飞行——在这里更突出。若 RL 能在固定翼上取得真实部署突破，其学术说服力通常高于在多旋翼上的类似结果。

4.1 发展历程分期

(1) 探索阶段：离散控制与局部任务学习。较早的固定翼 RL 工作多聚焦于简化任务，例如基于 Q-learning 的姿态控制、离散动作航迹控制或局部空战决策。其主要价值是验证 RL 在固定翼这个强约束平台上的可用性。

(2) 深度 RL 引入阶段：姿态控制、路径跟踪与自动着陆。随着深度 RL 普及，固定翼研究开始采用 DQN、DDPG、PPO、SAC 进行姿态控制、路径跟踪与自动着陆，尤其是将自动着陆拆分为纵向下滑道控制、横向对准与 flare 阶段控制。

(3) 真实部署和样本高效阶段：约 2021–2024 年间，出现了样本高效的固定翼姿态控制工作，通过系统辨识、延迟建模、域随机化与少量仿真数据，完成真实固定翼

外场飞行实验。这一阶段的重要性在于首次较清晰地证明：RL 可以不仅在固定翼仿真中有效，而且能在真实外场与工业 autopilot 基线竞争。

(4) 复杂机动与任务扩展阶段：2023–至今。研究开始向高迎角特技、六自由度耦合、空战机动、视觉避障、动态目标截获和更强的模型—数据融合方向扩展。固定翼 RL 逐渐从“替代传统姿态环”转向“扩展飞行包线、提升复杂任务自主性”。

4.2 为什么固定翼主流方法更强调样本效率与时延建模

固定翼平台最显著的特征是：真实飞行数据昂贵，而仿真器与现实之间的偏差对策略影响更严重。这直接导致算法选择逻辑不同于多旋翼。对固定翼来说，PPO 虽然稳定，但如果没有高质量仿真和充分随机化，训练出的策略很可能只在某一包线内有效；SAC 虽然连续控制性能好，但若观测不充分或延迟未建模，也可能在真实部署中变得激进。

因此，固定翼成功案例往往不是“某个算法本身特别强”，而是把系统辨识、执行器延迟、气动参数扰动、风场、传感器偏差和参考轨迹分布都纳入训练设计。NTNU 团队的样本高效真实部署工作就是典型代表：其使用少量飞行/风洞数据建立模型，在仿真中加入显著执行器延迟和多样化动态扰动，再通过数据效率较高的训练流程，最终把 RL 控制器部署到真实固定翼外场飞行中。

这说明固定翼 RL 的第一关键字不是“更深的网络”，而是“更诚实的训练接口”。如果观测、时延、控制频率和推理链路与真实机载计算条件不匹配，那么即便仿真回报再高，也难以保证真实可飞。

4.3 固定翼的主流任务

任务	难点	主流状态/动作	主流方法	说明
姿态控制	气动耦合、延迟、外场扰动	姿态/角速率/空速 -> 舵面+油门	PPO、SAC、ADP、模型辅助 RL	最接近传统内环替代问题
路径/航迹跟踪	风场与包线约束	位置/速度/航点误差 -> 滚转/俯仰/油门参考	DDPG、PPO、SAC	常与外回路耦合
自动着陆	下滑道、对准、flare、地效	相对跑道状态 -> 舵面/油门或阶段命令	DQN、DDPG、PPO、混合控制	离散阶段决策较常见
高迎角/特技机动	强非线性、高攻角失速风险	全 6DoF 状态 -> 舵面+油门	NAF、PPO、模型辅助 RL	用于扩展包线
空战/机动决策	对抗、长时序、部分可观测	相对态势信息 -> 机动指令	深度 RL、层次化 RL	偏高层但影响控制
视觉避障/感知控制	高速感知约束	图像/深度/状态 -> 机动命令	PPO、轻量视觉 DRL	近年来增长快

4.4 代表性工作脉络

固定翼姿态控制方面，研究者逐步从离散的 Q-learning/简单 actor-critic 过渡到连续动作的 PPO、SAC 与自适应动态规划。一些工作关注“弱模型”场景下的姿态控制，把不完全准确的飞行动力学模型与 RL 结合，说明模型误差并不必然阻断学习控制的有效性。

2020 年 AIAA 关于敏捷固定翼特技机动的深度 RL 工作具有代表性。该研究采用 Normalized Advantage Function（NAF）控制器进行特技机动控制，强调在高维状态与动作空间下直接优化机动性能。这表明固定翼 RL 不应只局限于常规包线内姿态环，也可以向高机动、高迎角和复杂特技扩展。随后 2023 年关于高迎角特技动作的工作进一步显示，RL 可用于处理传统气动模型高度非线性的包线边缘飞行。

2021/2022 年前后，NTNU 团队提出数据高效的固定翼姿态控制方案，并在真实 Skywalker X8 平台上进行外场实验。该工作说明只需极少量仿真交互（文中强调仅数分钟级训练数据），在高质量系统辨识与充分 sim-to-real 处理下，RL 控制器即可达到与 ArduPlane PID 姿态控制器相当的水平。此类成果改变了研究社区对固定翼 RL “只能在仿真里工作”的印象。

自动着陆是另一条重要分支。2024 年 NTU 的固定翼自动着陆研究将 PID 与 DQN 结合，用 RL 自动整定或辅助着陆控制，使落点和姿态控制更具适应性。这类“传统控制 + RL 调参与决策”的混合范式，比完全端到端直接输出舵面命令更容易在工程上被接受。

2024–2025 年间，还有研究从模型自由与模型基础的角度直接比较固定翼姿态控制，考察在风扰和动态变化下两类 RL 范式的优劣；另一些工作则面向视觉避障、动态目标拦截、空战机动与六自由度双操纵面飞机的近最优控制，说明固定翼方向正在从基础内环向复杂综合任务扩散。

4.5 主流算法/方法的选择逻辑

对于常规姿态/轨迹控制，PPO 是固定翼领域最稳妥的起点。它适合在并行仿真中大规模采样，且可较平滑地输出连续动作。若研究目标是更高的样本效率和更强的随机扰动鲁棒性，SAC 常比 PPO 更具吸引力，尤其是在外回路或参考命令级控制中。

如果重点是现实部署与样本高效，模型辅助 RL、残差 RL 或“系统辨识 + actor-critic”往往更值得优先考虑。固定翼的气动先验远比多旋翼丰富，完全忽略它们在数

据效率上往往不划算。对于自动着陆等阶段清晰的任务，混合控制（传统控制负责稳定段，RL 负责策略选择或参数自整定）会显著降低风险。

固定翼方向并不存在像多旋翼那样“一家独大”的算法格局，原因在于任务差异更大。姿态控制、自动着陆、高迎角特技、视觉避障、空战机动对观测与决策时域的需求差异显著，因此更合理的思路是先按任务结构选范式，再选算法，而不是先选算法再强行套任务。

4.6 2024-2026 年最新进展

第一，固定翼 RL 正从“是否优于 PID”转向“在哪些复杂工况下明显优于传统方法”。近年的对比研究更关注风扰、包线变化、模型不确定性和复杂机动，而不是在某一标称工况下比较 RMSE。

第二，真实部署的关键经验被逐步显性化。数据高效固定翼研究指出，显著执行器延迟建模、系统辨识与动态随机化是成功迁移的关键。这与多旋翼近年的零样本迁移结论相呼应，说明 sim-to-real 的核心并不由平台差异完全决定。

第三，固定翼 RL 的任务边界正在扩张。2025 年 ICLR 论文提出 VVC-GYM 这一固定翼 UAV RL benchmark 环境，意味着社区开始重视统一评测基准；而视觉避障、动态拦截和高迎角机动的持续出现，则说明 RL 已不再只扮演 autopilot parameter tuner 的角色。

第四，固定翼方向越来越重视“弱模型 + 学习补偿”而非纯黑箱。对于一个必须考虑气动包线、结构限制和飞行安全的系统，这种灰箱路线更符合工程发展方向。

4.7 固定翼方向的阶段性结论

固定翼 RL 的最大价值不在于替代成熟 autopilot 的日常巡航控制，而在于：扩展飞行包线、提升复杂环境适应性、降低手工调参与复杂控制器设计成本，以及为自动着陆、高迎角机动、复杂目标跟踪和新构型飞行器提供更强的适配能力。

从方法论上看，固定翼方向的主流路线可概括为“PPO/SAC 作为核心学习器，系统辨识与时延建模作为迁移前提，必要时以模型辅助或混合控制提升可靠性”。未来若想实现更大规模突破，关键不在于堆砌更大网络，而在于建立更可信的 benchmark、真实飞行测试协议与安全验证路径。

5 VTOL 平台：多模态飞行、过渡控制与分阶段强化学习

VTOL (Vertical Take-Off and Landing) 平台兼具旋翼悬停和固定翼巡航能力，是目前最具工程吸引力的新型飞行平台之一。它既希望拥有多旋翼的起降灵活性，又希望具有固定翼的航时和航程优势。然而从控制角度看，VTOL 也是最复杂的平台之一：在悬停、过渡与巡航三个阶段，动力学特性、主导控制量和约束条件都发生明显变化。

这种“多模态飞行”特征使 VTOL 天然适合采用分层、混合和阶段化 RL。与多旋翼或固定翼相比，VTOL 的关键问题往往不是某一单一模式内如何做最优控制，而是模式转换时如何保持稳定、效率和安全，尤其是在倾转角变化、升力来源切换、重心/气动中心变化和外部扰动耦合的条件下。

5.1 VTOL RL 研究的主要问题域

第一类问题是过渡飞行控制，即从悬停到前飞、从前飞到悬停的平滑切换。此时传统线性分段控制常常需要复杂的增益调度与模式逻辑，而 RL 有潜力在统一奖励下学习跨模式策略。

第二类问题是复杂着陆，特别是舰船/海上平台/移动甲板着陆。该问题兼具多旋翼着陆和外界扰动的不确定性，通常需要同时处理平台运动、风浪扰动、视觉/状态估计误差和能量受限等因素。

第三类问题是推力分配与多通道协同控制。对于倾转旋翼或复合翼 VTOL，多个推力器、舵面和倾转机构之间存在耦合，多智能体或分通道 RL 容易成为可行选择。

第四类问题是数字孪生与混合控制。由于真实 VTOL 试飞成本更高，很多研究倾向采用 model-based 外层 + RL 内层、或 approach phase 由传统控制负责、landing/transition phase 由 RL 负责的结构。

5.2 发展历程与代表性工作

相较于多旋翼和固定翼，VTOL RL 文献数量较少，但近两年增长明显。2022 年 AIAA 已有“固定翼 VTOL 过渡飞行控制系统设计：一种强化学习方法”的工作，表明研究者很早就意识到过渡段是 RL 最可能发挥优势的场景。

2024 年一项重要工作聚焦于 VTOL-UAV 海上平台自主着陆的 sim-to-real 策略迁移。该研究将任务拆分为 approach phase 和 landing phase，其中 approach 使用模型基础控制，landing 使用 DRL，并用 JONSWAP 波浪谱生成随机海况扰动。实验比较了 DQN 和 PPO 等多类 DRL agent，结果显示 PPO 更擅长学习复杂、不确定环境下的着

陆策略。这一工作非常具有代表性，因为它体现了 VTOL 研究中最成功的一条路线：不是让 RL 独自包办全部控制，而是在最不确定、最难建模的阶段发挥其优势。

2025 年关于倾转旋翼 VTOL 的多智能体 SAC 研究进一步把 RL 与结构先验结合。该工作将不同控制输入交由多个 SAC 模块分别负责，并引入基于动态参考响应区间的奖励设计，据称在无风与 20 m/s 定常风条件下，相对 AC NN、PPO、终端滑模和 PID 等方法取得更好的瞬态指标，并显著缩短训练时间。这表明对多通道耦合强的 VTOL，分解式多智能体 RL 可能比单策略端到端更有效。

2025 年末和 2026 年初出现的一些新工作，则尝试把物理信息稀疏 RL、混合动力/复合构型数字孪生以及过渡段方法学总结纳入统一框架，说明 VTOL RL 正在从“针对单一平台的案例论文”转向“可泛化的方法学探索”。

5.3 VTOL 的主流方法为何以分阶段、混合式和多智能体为主

VTOL 最不适合采用单一黑箱策略“一把梭”的原因在于：不同飞行阶段的控制目标和主导动力学差异太大。悬停段更像多旋翼问题，巡航段更像固定翼问题，而过渡段则具有最强的模式切换与耦合特性。若用一个策略覆盖所有阶段，往往需要极大网络容量、极多训练样本以及极精细的课程设计，训练与验证成本都非常高。

因此，VTOL 领域形成了三种主流思路。第一是分阶段控制：用传统模型控制负责容易建模的 approach/cruise/hover 段，把 RL 集中部署在 landing 或 transition 等最复杂阶段。第二是层次化控制：高层负责模式切换与目标分配，低层负责连续控制。第三是多智能体/多模块控制：不同执行通道或子任务由不同 agent 学习，再通过协同机制形成整体控制。

从算法上看，PPO 和 SAC 仍是最常见的核心学习器，但它们在 VTOL 中几乎总是与结构化设计并存。相比之下，DQN 等值函数方法多出现在离散阶段决策或模式中，而不适合作全渡控制的主力。模型基、物理束嵌入和家演示初始化在 VTOL 中也比其他平台更常见。

5.4 2024-2026 年最新进展

一是海上/移动平台着陆问题的成熟化。2024 年 offshore docking 工作清楚表明，在含波浪扰动、平台运动和 sim-to-real 需求的场景下，PPO 类策略在 landing phase 上具有很强竞争力，而分阶段结构能显著降低训练难度。

二是多智能体 SAC 在倾转旋翼控制中的兴起。相比单 agent，这类方法更适合处理多执行器耦合和奖励冲突问题，且更容易把每个通道的控制目标和约束显式写入奖励。

三是物理先验融合增强。2026 年关于 hybrid UAV 的 physics-informed sparse RL 工作说明，社区正在探索如何在高保真仿真、硬件在环和嵌入式实时计算框架下，把物理知识与 RL 的表达能力结合，降低黑箱性并改善实时部署。

四是过渡控制方法学逐渐系统化。2025 年的学习型 transition methodology 工作反映出，研究者开始从单篇案例走向对过渡段控制结构本身的重新设计，例如如何处理倾转引起的重心变化、推力方向切换和失稳风险。

5.5 VTOL 方向的阶段性结论

VTOL 是最能体现 RL“结构设计能力”的平台。真正成功的方案通常不是选对了 PPO 还是 SAC，而是把问题分对了层、把奖励写对了物理含义、把容易建模的部分留给传统控制、把最不确定的部分交给学习器。

因此，VTOL 的主流方法可以概括为：分阶段混合控制是基本盘，多智能体/层次化结构是上升趋势，模型辅助与物理约束融合是未来核心。若目标是工程落地，强烈不建议从全阶段单一端到端黑箱控制开始。

6 三类平台的横向比较：发展共识、主流路线与差异化瓶颈

如果从“发展成熟度”排序，多旋翼无疑是最成熟的平台，固定翼次之，VTOL 则最具挑战但潜在收益也最高。多旋翼的研究生态最完整，仿真平台、开源控制栈、真实验证案例、竞速与故障容错等方向都已形成较丰富文献；固定翼的研究深度很强，但总量较少，更强调真实部署与高价值任务；VTOL 则尚处于方法体系快速形成阶段。

如果从“主流算法”看，三者都已基本完成从 DQN/DDPG/TRPO 向 PPO/SAC/TD3 与模型辅助方案的转移，但原因略有不同。多旋翼选择 PPO/SAC 主要是因为连续控制与部署鲁棒性；固定翼则是因为在保证连续控制能力的同时，更容易与系统辨识、时延建模和灰箱模型结合；VTOL 则因为需要分阶段与多模块协同，使 PPO/SAC 更适合作为可插拔核心学习器。

如果从“关键瓶颈”看，多旋翼瓶颈已从控制能力转向零样本迁移、复现性和安全认证；固定翼瓶颈在于高保真气动建模、包线外行为验证和高风险真实试飞；VTOL 的最大瓶颈则是多模态切换与系统级验证。

6.1 三类平台主流路线对比

平台	主要难点	前主流 RL 路线	主流算法	部署关键词
单旋翼/多旋翼	欠驱动、延迟敏感、扰动大、需要高速闭环	端到端连续控制 + sim-to-real + 安全过滤	PPO、SAC、TD3、残差 RL	系统辨识、动作平滑、选择性随机化、零样本迁移

固定翼	气动强非线性、包线约束、真实试飞成本高	灰箱建模 + 连续控制 RL + 时延建模	PPO、SAC、模型辅助 RL、ADP	延迟建模、包线保护、数据效率、真实外场验证
VTOL	多模态切换、过渡耦合、多执行器协同	分阶段/层次化/多智能体混合控制	PPO、SAC、多智能体 SAC、模型辅助 RL	过渡控制、着陆成功率、结构先验、数字孪生

6.2 为什么“主流算法”不能脱离平台物理特性讨论

在很多泛化综述中，PPO、DDPG、SAC 常被简单排成“谁更适合无人机”的排行榜，这其实是误导性的。飞行控制不是标准 MuJoCo 连续控制问题，不同平台对观测、动作、奖励、计算时延和安全约束的敏感性差异极大。一个在多旋翼姿态控制中效果良好的策略结构，未必适合固定翼高迎角机动，更不一定适合 VTOL 过渡段。

因此，更合理的原则是：先识别平台主导物理矛盾，再决定学习范式。对于多旋翼，主导矛盾是高速闭环与 sim-to-real；对于固定翼，是包线约束与真实数据昂贵；对于 VTOL，是模式切换与多子系统耦合。算法只是对这些矛盾的一个求解载体。

7 最新前沿与未来趋势

7.1 从“回报最优”转向“部署就绪”

2024–2026 年最显著的变化，是研究评价标准正在转向部署就绪性。一个策略是否可以在板载处理器上实时运行、是否能在未见参数变化和风扰下保持稳定、是否具备故障恢复能力、是否能提供可解释安全边界，逐渐成为比单一回报更重要的标准。

进一步看，未来突破往往不会来自单篇论文中的“新网络结构”，而更可能来自实验体系与方法学的进步：例如更好的一致性训练接口、更可信的随机化策略、更清晰的安全验证流程以及更可共享的 benchmark。

7.2 模型—数据融合将成为主流

黑箱 RL 在飞行控制中很难成为最终赢家。飞行器拥有丰富的刚体动力学、气动力学与控制分配先验，合理利用这些知识可以显著减少样本需求并提升可解释性。未来更可行的路线是数字孪生 + 残差 RL、物理引导奖励、灰箱世界模型和在线参数辨识结合。

进一步看，未来突破往往不会来自单篇论文中的“新网络结构”，而更可能来自实验体系与方法学的进步：例如更好的一致性训练接口、更可信的随机化策略、更清晰的安全验证流程以及更可共享的 benchmark。

7.3 安全 RL 与形式化验证的重要性快速上升

由于航空控制是典型安全关键系统，未来 RL 飞控必须面对稳定性证明、约束保证、失效保护、形式化验证和认证问题。控制屏障函数、Lyapunov-RL、shielding、运行时监控与可验证神经网络将成为重要方向。

进一步看，未来突破往往不会来自单篇论文中的“新网络结构”，而更可能来自实验体系与方法学的进步：例如更好的一致性训练接口、更可信的随机化策略、更清晰的安全验证流程以及更可共享的 benchmark。

7.4 Offline RL、模仿学习与基础策略

真实飞行数据昂贵，使得 offline RL 和模仿学习在航空中格外有吸引力。未来可能出现“基础飞控策略”——先在大规模仿真与历史飞行数据上预训练，再针对具体机型做少量在线适配。对单旋翼和 VTOL 这类高风险平台尤其如此。

进一步看，未来突破往往不会来自单篇论文中的“新网络结构”，而更可能来自实验体系与方法学的进步：例如更好的一致性训练接口、更可信的随机化策略、更清晰的安全验证流程以及更可共享的 benchmark。

7.5 多任务与通用控制器

四旋翼方向已经出现对 generic controller 和 zero-shot transfer 的追求，固定翼和 VTOL 未来也可能向通用策略发展。但这里的“通用”不太可能是完全统一的黑箱网络，而更可能是共享表征 + 平台特定控制头或共享基础策略 + 机型适配模块。

进一步看，未来突破往往不会来自单篇论文中的“新网络结构”，而更可能来自实验体系与方法学的进步：例如更好的一致性训练接口、更可信的随机化策略、更清晰的安全验证流程以及更可共享的 benchmark。

7.6 数字孪生、HIL 与软硬件协同设计

未来飞行控制 RL 会越来越依赖 hardware-in-the-loop、嵌入式实时测试与软件栈一致性。换言之，训练环境不再只是物理仿真器，而是接近真实 avionics 链路的“系统级数字孪生”。

进一步看，未来突破往往不会来自单篇论文中的“新网络结构”，而更可能来自实验体系与方法学的进步：例如更好的一致性训练接口、更可信的随机化策略、更清晰的安全验证流程以及更可共享的 benchmark。

7.7 研究空白

单旋翼真实深度 RL 仍然明显不足；固定翼在包线外机动、失速恢复和复杂气象中的真实部署案例仍偏少；VTOL 领域缺乏被广泛接受的公开 benchmark、统一评测协议与大规模可复现实验。

进一步看，未来突破往往不会来自单篇论文中的“新网络结构”，而更可能来自实验体系与方法学的进步：例如更好的一致性训练接口、更可信的随机化策略、更清晰的安全验证流程以及更可共享的 benchmark。

8 结论

综合来看，RL 飞行控制已经从探索性概念验证走向平台差异化、方法结构化和部署导向化。单旋翼/多旋翼平台的发展最早、研究最成熟，其主流路线已经清晰收敛到连续动作 actor-critic、sim-to-real、动作平滑和安全保护的组合；固定翼平台则以样本高效真实部署、气动包线扩展和复杂任务自主性为核心价值，主流路线是 PPO/SAC 与系统辨识、时延建模、灰箱模型辅助的结合；VTOL 平台最能体现 RL 与结构设计的协同，分阶段/层次化/多智能体控制将长期是其主流框架。

若从“真正的前沿”定义来看，它不再是单纯追求在仿真器中学出更高回报，而是让策略在真实系统中更安全、更稳健、更可解释、更可验证。面向未来，最有希望形成长期影响的方向包括：物理先验融合的样本高效 RL、安全与形式化验证、offline/pretrain + online adaptation、数字孪生驱动的零样本迁移，以及跨平台可复现 benchmark 的建设。对于任何希望将 RL 引入飞行控制的研究者而言，最重要的结论并不是“哪一个算法绝对最好”，而是必须根据平台物理特性、任务层级、部署约束和安全要求，构造合适的问题分解与训练—部署闭环。

换言之，飞行控制中的 RL 不是对传统控制的简单替代，而是在传统控制、最优控制、系统辨识和数据驱动学习之间，建立一种新的工程协作关系。谁能把这种关系设计得更合理，谁就更可能把 RL 从论文中的“会飞”，真正推进到工程中的“能用、敢用、长期可用”。

9 专题讨论：奖励设计、状态表示与控制接口的工程细节

飞行 RL 文献经常把“算法”当作主角，但在真实项目中，状态、动作与奖励三者构成的控制接口才是真正决定成败的核心。许多失败案例不是因为 PPO 或 SAC 不强，而是因为状态未充分表征真实闭环所需信息，或者动作接口与实际控制架构错位，导致策略只能在仿真器中利用某些不现实的捷径。

首先是状态表示。对多旋翼而言，把姿态欧拉角直接作为唯一姿态表征，往往不如使用旋转矩阵、四元数或误差轴角形式稳定，因为欧拉角在大机动时会出现奇异性与耦合放大。对于固定翼，若只给姿态而不给空速、迎角、历史舵面和气动相关量，策略往往无法区分同一姿态误差对应的不同控制需求。对 VTOL，若不显式加入倾转角、飞行模式变量和阶段指示，策略容易在过渡段出现控制逻辑混乱。

其次是动作接口。一个常见误区是以为越端到端越先进，于是直接让策略输出所有电机 PWM 或所有舵面绝对偏转。事实上，若平台已有成熟混控器、执行器限幅与内环保护逻辑，策略输出参考命令而非最底层信号，往往更利于部署。原因在于：一方面保留了现有工业安全边界；另一方面降低了学习器面对的控制分配复杂度，使其更专注于策略层决策。

再次是奖励函数与终止条件。飞行控制奖励应避免“只在成功时给奖励、平时全为零”的极端稀疏设计，因为这会使高维连续控制中的探索几乎不可行；同时也应避免把过多规则硬塞入奖励，导致策略仅学会针对 shaping 的投机行为。一个更稳妥的原则是：主目标误差项必须与真实控制目标一致，约束相关惩罚要有清晰物理意义，动作变化惩罚应与执行器带宽和结构安全需求对应，而终止惩罚则应用于包线越界、碰撞、失速、倒扣不可恢复等硬失败。

课程学习在飞行任务中非常重要。对多旋翼，可先从悬停和定点姿态跟踪开始，再逐步增加目标变化速度、轨迹复杂度和风扰；对固定翼，可先在窄包线内训练，再逐步扩展空速和姿态范围；对 VTOL，则常需先分别学好各模式，再学习过渡段。课程学习的价值，不只是降低训练难度，更在于避免策略在初期探索中大量落入灾难性失败区域。

对部分可观测系统，引入历史观测与历史动作几乎是必选项。很多真实飞行器中，执行器滞后、未建模弹性和风场扰动无法由单帧状态推断，若不给历史信息，策略会把这些动态误差当作噪声处理，从而导致迟滞和振荡。LSTM/GRU、时间卷积、帧堆叠和简单延迟状态拼接都是实用做法。

最后需要强调，接口设计必须与实际 autopilot 软件栈一致。如果训练时动作含义是机体角速度参考，而部署时又把它错误接入姿态角参考接口，那么即使网络数值上输出正确，闭环行为也会完全不同。许多看似“sim-to-real 失败”的案例，本质上都是接口不一致。

10 专题讨论：sim-to-real 的经验法则与可复现流程

对于飞行控制而言，sim-to-real 不是可有可无的附属问题，而是整个研究是否具有工程价值的分水岭。一个没有迁移路径的 RL 控制器，最多只能证明“在某个仿真器里奖励函数被优化了”，却无法证明其真正具有飞行控制意义。

第一条经验法则是高保真不等于高可迁移。许多研究者倾向于一味追求更复杂的仿真模型，但如果建模误差集中在对闭环影响最大的参数上，例如执行器时延、推力

曲线、传感器噪声、控制频率抖动和风扰分布，那么即便流体细节再精细也无济于事。可迁移仿真环境的关键，是把“闭环敏感因素”建准。

第二条经验法则是随机化要有选择。无差别扩大域随机化区间，虽然可能增加鲁棒性，但也会让训练难度大幅上升，并迫使策略变得过于保守。更有效的方法是围绕可测或半可测的关键参数做 selective domain randomization，例如质量、惯量、推力系数、舵机延迟、风场强度、传感器偏置和控制链路时延。

第三条经验法则是训练参考分布必须覆盖真实任务。若训练时仅让固定翼跟踪低频平缓指令，部署时却要求其完成快速翻滚或大坡度机动，那么策略必然失配。多旋翼竞速成功的一个关键原因，就是训练轨迹与真实赛道动作分布高度匹配。

第四条经验法则是把软件栈也纳入数字孪生。真实飞行中，策略输出并不是直接作用到动力学方程，而是会经过消息传输、滤波器、控制分配、限幅、估计器和任务管理器。若训练完全绕开这些软件环节，现实中的额外时延与逻辑会显著改变闭环。

第五条经验法则是建立逐级验证流程。推荐的顺序通常是：离线仿真 -> 高保真仿真与参数随机化 -> HIL/SIL -> 台架或系留试验 -> 受限外场短时验证 -> 全任务飞行。对于 VTOL 和单旋翼等高风险平台，这种分层验证尤为必要。

第六条经验法则是保留安全基线。无论策略多先进，都应保留传统控制器或安全外层作为回退机制，例如高度保持、姿态包线保护、失速/翻覆保护和人工接管。真正可部署的 RL 很少以“完全替代所有传统控制”的形式出现。

第七条经验法则是记录并公布负结果。飞行 RL 的可复现性长期受困于“只有成功论文被发表”。若没有对失败配置、无效奖励、错误随机化范围和真实部署崩溃模式

的系统记录，领域很难形成稳定知识。未来 benchmark 的价值，很大程度上就在于把这些隐性经验转化为显性协议。

11 专题讨论：开源仿真、基准环境与实验生态

开源仿真环境对 RL 飞行控制的演化有决定性影响。多旋翼研究之所以迅速增长，与 RotorS、Gazebo、AirSim、Flightmare 等环境的可用性直接相关；固定翼和 VTOL 的发展相对缓慢，一个重要原因就是缺乏像 MuJoCo 在机器人领域那样统一且高度易用的基准环境。

JSBSim 和 FlightGear 在固定翼领域具有重要意义。前者提供可配置飞行动力学模型，后者提供可视化和更完整的飞行模拟生态。它们使得研究者可以在较接近真实飞行的环境下设计 RL 控制任务，但同时也带来更复杂的接口和更高的仿真配置成本。

AirSim 对视觉感知和无人机任务研究影响深远，适用于多旋翼视觉控制、避障、导航与落点识别等问题。Flightmare 则强调高速度和面向 RL 的训练效率，尤其适合多旋翼敏捷机动与竞速任务。

2025 年提出的 VVC-GYM 对固定翼 RL 具有里程碑意义，因为它试图把固定翼控制问题标准化、可复现化和 benchmark 化。一个成熟领域通常不缺新算法，而缺统一评价协议。固定翼若要形成类似四旋翼那样的快速迭代生态，公开基准环境和统一任务集是必不可少的。

对 VTOL 来说，当前最大问题不是没有仿真器，而是缺少公认 benchmark。大多数研究依赖自建模型和特定平台，导致论文之间难以直接比较。未来 VTOL 领域最需要的不是更多单平台案例，而是可公开的过渡控制、着陆、风扰和推力分配任务库。

因此，从生态建设角度看，未来几年最值得投入的并不是再做一篇“某算法在某平台上略优”的论文，而是搭建可共享、可扩展、可直接用于 sim-to-real 流程的基准系统。这一点对三类平台都成立，尤其对固定翼和 VTOL 更为迫切。

11.1 常见仿真与实验环境对比

环境/工具	主要适用平台	优势	局限	典型用途
Gazebo/RotorS	多旋翼	开源、与 ROS 生态兼容、控制栈丰富	视觉与高保真气动有限	姿态/轨迹控制、算法基线
AirSim	多旋翼/视觉任务	视觉与物理结合、场景丰富	训练效率和固定翼控制灵活性有限	视觉控制、导航、着陆
Flightmare	多旋翼	面向 RL 的高吞吐训练、适合竞速	平台范围较集中	敏捷飞行、竞速、sim-to-real
JSBSim	固定翼/旋翼/复合构型	动力学可配置、航空社区常用	接口较工程化，上手成本较高	姿态控制、轨迹、包线研究
FlightGear	固定翼/综合飞行仿真	可视化好、生态成熟	与 RL 训练框架集成成本较高	人在回路、综合验证
自建数字孪生 + HIL	三类平台	最接近真实链路、便于部署前验证	开发成本高、难共享	部署级验证、时延和软件栈一致性测试

12 面向后续研究/开题的路线建议

若研究对象是多旋翼，建议从“参考命令级连续控制 + PPO/SAC 双基线 + 统一评价协议”起步。具体可以先做姿态控制，再扩展到轨迹跟踪与风扰鲁棒性，最后加入系统辨识和选择性随机化，形成完整 sim-to-real 链条。对实验资源有限的团队而言，这条路线最具可操作性。

若研究对象是单旋翼，建议避免一上来追求全端到端真实飞行。更实际的路径是先利用学徒学习或历史飞行数据建立初始策略/模型，再在高保真仿真中做安全增强

的 RL 微调，并通过系留试验或台架逐步放开包线。单旋翼更适合研究“结构先验 + RL”的方法论。

若研究对象是固定翼，推荐优先选择高价值场景，而不是与成熟 autopilot 在常规巡航控制上竞争。自动着陆、高迎角控制、强风环境下轨迹跟踪、视觉避障和复杂机动，都是 RL 更可能体现优势的方向。方法上可采用 PPO/SAC 与系统辨识、时延建模、包线保护结合。

若研究对象是 VTOL，建议直接采用分阶段或层次化思路。悬停和巡航段可以沿用已有控制器，把 RL 集中于 transition 或 landing 等最复杂阶段。若平台控制通道多、耦合强，可进一步考虑多智能体 SAC 或模块化 PPO。

从论文产出角度看，当前最容易获得学术价值的不是“某算法精度提升 2%”，而是以下几类问题：其一，零样本 sim-to-real 的决定因素及其消融研究；其二，故障容错与在线适配；其三，安全验证与约束保证；其四，benchmark 与开源生态建设；其五，数字孪生与部署流程标准化。

从工程转化角度看，建议始终保留传统控制基线，并明确 RL 所承担的角色：是替代某个控制环、优化某个阶段，还是作为外层策略器。角色越清晰，系统越容易验证，也更容易获得工程接受。

对于学位论文或综述延展，本文的一个自然扩展方向是加入更系统的公式推导、控制框图与平台动力学模型，或者聚焦某一平台形成专题综述。若用于开题，建议在“发展脉络 + 主流算法 + 研究空白 + 自身切入点”四部分基础上再补充实验平台与评价指标设计。

12.1 可直接改写为论文小节的提纲模板

建议章节	建议内容
研究背景	传统飞行控制局限、RL 的引入动机、平台特性与应用需求
问题定义	动力学模型、状态/动作/奖励设计、约束条件与评估指标
相关工作	按平台或任务分类整理文献，突出算法与部署方式
方法设计	RL 核心算法、先验融合、安全机制、sim-to-real 策略
实验平台	仿真器、飞控软件栈、硬件平台、HIL/外场流程
结果分析	与 PID/MPC/滑模等基线比较，包含鲁棒性和迁移结果
讨论与局限	黑箱性、样本效率、安全认证、计算约束与泛化边界
结论与展望	部署就绪、基准建设、未来研究路线

13 附录：代表性文献矩阵（按平台整理）

以下文献矩阵不是穷尽式目录，而是面向研究入门与开题使用的“代表性抓手”。

每篇文献之所以被列入，主要是因为它在发展历程、方法转折或部署意义上具有代表性。若要进一步扩充为更正式的期刊综述，可在此基础上加入年份、是否真实飞行、开源情况和更细粒度指标。

13.1 单旋翼/多旋翼代表性文献矩阵

年份	文献/主题	平台	方法关键词	代表意义
2003	Autonomous helicopter flight via RL	单旋翼直升机	模型学习 + RL	最早真实飞行 RL 里程碑之一
2006	Aerobatic helicopter flight	单旋翼直升机	学徒学习/模仿 + RL	实现真实特技机动
2008	Autorotation via RL	单旋翼直升机	强化学习机动控制	关注高度非线性自

				转下滑
2018/2019	UAV attitude control	四旋翼	DDPG/TRPO/PPO	建立四旋翼 RL 姿态控制基线
2022	Low-altitude fixed-point quadrotor control	四旋翼	改进 PPO	直接映射到低层控制
2023	Champion-level drone racing	四旋翼	深度 RL	证明高机动真实竞速可行
2024	Model-free RL baseline evaluation	四旋翼	八种算法比较	形成算法比较基准
2024/2025	Zero-shot sim-to-real study	四旋翼	选择性随机化/动作平滑	总结零样本迁移关键因素
2025	Transformer-based adaptation/fault-tolerance	四旋翼	在线适应 + RL	面向故障容错与泛化
2026	Deployment-readiness review	多旋翼/UAV	算法到部署评估	强调部署成熟度

13.2 固定翼代表性文献矩阵

年份	文献/主题	任务	方法关键词	代表意义
2020	Aerobatic maneuvering of agile fixed-wing aircraft	特技机动	NAF / 深度 RL	将 RL 推向敏捷固定翼机动
2021	Attitude control using Q-learning	姿态控制	Q-learning	较早固定翼 RL 控制尝试
2022	Data-efficient DRL for attitude control	姿态控制	SAC/PPO 类 + sim-to-real	强调样本高效与真实部署
2023	High-alpha aerobatic maneuvers	高迎角机动	RL 包线扩展	面向强非线性高攻角
2024	Automatic landing control	自动着陆	DQN + PID/混合控制	着陆场景的工程化路线
2024	Control and motion planning via RL	航迹/拦截	RL 规划控制耦合	拓展到综合 GNC
2024	Dual-control aircraft 6DoF attitude	姿态控制	ADP/LSTM	高维 MIMO 控制

	control			案例
2024/2025	Model-free vs model-based RL	姿态控制	范式比较	比较模型基础与模型自由
2025	VVC-GYM benchmark	基准环境	benchmark	推动固定翼标准化评测
2025	RL for UAV flight controls	综述/比较	PPO/DDPG/SAC 对比	从算法选择角度总结

13.3 VTOL 代表性文献矩阵

年份	文献/主题	任务	方法关键词	代表意义
2022	Transition control for fixed-wing VTOL	过渡飞行	RL 过渡控制	较早系统讨论 transition 的工作
2024	Offshore docking operations	海上平台着陆	分阶段控制 + PPO/DQN	典型 sim-to-real 着陆案例
2025	Tilt-rotor control with MARL	倾转旋翼控制	多智能体 SAC + 模型奖励	体现模块化控制优势
2025	Learning-based methodology for transitioning UAVs	过渡飞行	方法学总结	从案例走向体系
2026	Physics-informed sparse RL for hybrid UAV	混合构型控制	物理信息融合 RL	面向实时部署与数字孪生

13.4 一页式总结

若只保留一句判断：多旋翼最成熟，固定翼最能检验控制价值，VTOL 最能检验结构设计能力。

若只保留一句方法建议：先按平台和任务分解问题，再选 PPO/SAC/模型辅助等工具，而不是反过来。

若只保留一句前沿判断：未来竞争焦点将从算法新奇性，转向部署可靠性、结构先验融合与可验证安全性。

14 专题讨论：安全、可信与认证问题

飞行控制与一般机器人控制最大的不同，在于其失效后果更严重、系统责任链更长。因此，RL 真正走向航空工程，不可回避安全、可信与认证问题。过去相当长时间内，许多研究默认只要仿真和少量真实飞行成功即可证明方法有效，但在工程语境下，这远远不够。

首先，RL 控制器需要给出可理解的失效边界。传统 PID 或 LQR 尽管也未必在所有工况都有严格全局保证，但其结构简单、调参逻辑明确、失效模式相对可预测。相比之下，神经网络策略的隐式非线性映射让其在包线外或未见扰动下的行为更难预判。因此，未来的 RL 飞控必须辅以运行时监控、包线保护和故障隔离机制，使系统在进入危险区域前就触发保守模式或切换到基线控制器。

其次，需要区分“训练时安全”和“运行时安全”。训练时安全强调策略学习过程中不探索灾难动作，常用方法包括安全初始策略、shielding、约束优化、模型预测安全层等；运行时安全则强调部署后每一步动作都必须满足可行域，这通常需要控制屏障函数、可行集投影、控制分配器限幅和独立监督逻辑。两者不能相互替代。

再次，可解释性在飞行 RL 中并不是锦上添花，而是审查和工程接受的前提。固定翼和 VTOL 尤其需要回答：策略为何在某一时刻加大俯仰或改变倾转角？其决策是否与包线、能量管理和阶段任务一致？当前一些研究通过可视化价值函数、敏感度分析、局部线性化和注意力权重等方式部分提升可解释性，但距离工程级透明度仍有差距。

从认证角度看，未来最现实的方向可能不是直接认证一个“完全端到端自主飞控网络”，而是认证一个“包含学习模块的混合控制系统”：其中学习器仅负责在明确定义的子任务或子包线内工作，外层有独立安全壳和接管逻辑。这一思路与当前 VTOL 分阶段控制、固定翼自动着陆混合控制和多旋翼安全过滤器的发展方向高度一致。

此外，可信数据链路同样重要。若 RL 控制器依赖的状态估计本身存在未监测漂移，学习器很可能在错误输入上做出高度自信但不安全的动作。为此，未来系统应把状态估计置信度、传感器健康度与策略不确定度一并纳入控制决策。

总的来说，安全与认证不是 RL 飞控的外部附加要求，而应当内生于方法设计。谁能把安全壳、验证协议和学习器结构从一开始就协同设计，谁就更接近真正可部署的航空智能控制。

15 专题讨论：主流算法的“飞行控制视角”解读

从飞行控制的视角重新看待常见 RL 算法，会得到与通用机器学习文献不太一样的结论。以 DQN 为例，在 Atari 等离散动作问题中其历史地位举足轻重，但飞行低层控制通常要求高频、平滑、精细的连续动作，因此 DQN 的主要用武之地其实退化为阶段决策、离散模式切换和少数着陆问题。

PPO 的价值在飞行控制中主要体现在“稳”和“省心”。它并不总是样本效率最优，但极其适合作为基准，因为对并行仿真友好、更新过程稳定、工程实现成熟。很多论文其实不是因为 PPO 理论上最适合，而是因为在多旋翼、固定翼和 VTOL 三类平台上，它都能较快训练出能工作的初版策略。

SAC 则更像面向部署的强力候选。其最大熵目标鼓励更有韧性的探索，也更容易在连续控制中得到鲁棒策略。对飞行控制而言，SAC 的一个隐含优势是经验回放提高了数据利用率，这对真实数据昂贵的固定翼和 VTOL 尤其重要。但 SAC 对奖励尺度、温度调节和网络结构也更敏感，若缺乏经验，调试成本不一定低于 PPO。

TD3 在飞行控制中的地位常被低估。它不像 PPO 那样“人尽皆知”，也不像 SAC 那样因最大熵而受关注，但在许多连续控制任务中，TD3 以较低复杂度提供了相当可靠的性能，尤其适合用作 DDPG 的稳健替代基线。

模型基础 RL 与世界模型方法对飞行控制的意义，可能比在一般机器人领域更大。飞行器先验强、真实试验贵、包线边界清晰，因此即使学习到的模型并不完美，也往往足以显著提升样本效率、辅助规划或作为安全过滤器的一部分。尤其在固定翼和 VTOL 中，模型辅助并不是保守妥协，而是高价值设计。

层次化 RL 和多智能体 RL 在飞行控制中的适用性也具有平台差异。多旋翼单机低层控制通常不需要过于复杂的层次化，但在竞速、编队或感知-控制耦合任务中价值很高；固定翼在复杂机动或空战决策中更需要层次化；VTOL 则几乎天然适合多阶段和多模块分解。

因此，所谓“主流算法”，其真正含义不是某个方法在所有平台上都最优，而是它在特定平台的工程条件下形成了最好的效率—稳定性—可部署性折中。

16 专题讨论：面向实验设计的实操检查表

为了提高可复现性，飞行 RL 研究应尽可能把实验设计标准化。以下检查表尤其适合作为论文方法部分或实验附录的结构框架。

第一，平台与模型信息是否完整：需要明确机体质量、惯量、推力/舵机模型、估计器、控制频率、动作接口、状态量定义与坐标系约定。很多文献复现困难，根源就在于这些信息写得过于简略。

第二，训练任务分布是否公开：包括参考轨迹生成方式、初始状态采样范围、风扰模型、噪声类型、随机化参数和终止条件。若没有这些信息，其他研究者很难判断策略究竟学会了什么。

第三，评价指标是否覆盖控制学指标而不只是回报：至少应报告跟踪误差、稳定时间、超调、动作平滑度、能耗或控制 effort、失败率和对参数扰动的敏感性。对于部署研究，还应报告推理频率、板载时延和 CPU/GPU 占用。

第四，是否与恰当基线比较：多旋翼至少应与 PID/MPC 或成熟 autopilot 内环对比；固定翼和 VTOL 更应与现有飞控软件栈中的标准控制器比较，而不是只与其他 RL 算法比较。

第五，是否包含消融实验：状态表示、动作定义、随机化范围、延迟建模、动作平滑惩罚、网络结构和安全过滤器都可能深刻影响结果。没有消融，很难判断论文贡献来自何处。

第六，真实部署流程是否透明：是否经过 HIL/台架/系留测试？是否有人工接管与安全回退？失败案例和异常行为如何处理？这些信息虽不如网络结构“新颖”，却是飞行 RL 真正可信的基础。

第七，数据和代码是否开放：若无法完全公开，也至少应开放配置文件、随机化范围、训练日志和关键接口定义。对于一个高度依赖工程细节的方向，开源程度几乎决定了论文的长期影响力。

16.1 适合直接写入论文附录的实验清单表

检查项	建议报告内容	重要性
动力学与平台参数	质量、惯量、推力/舵机模型、估计器、控制频率、坐标系	高
状态定义	是否使用四元数/旋转矩阵、是否含历史信息、是否含模式变量	高
动作定义	参考命令、PWM、舵面绝对/增量、限幅策略	高
奖励函数	各项权重、终止惩罚、动作平滑项、约束惩罚	高
随机化设置	质量、惯量、风扰、噪声、延迟、传感器偏置范围	高
训练分布	初始姿态目标分布、策略、回合数	高
评价指标	RMSE、稳定时间、超调、能耗、失败率、部署时延等	高
基线控制器	PID/MPC/滑模/工业 autopilot 配置	高
真实部署协议	HIL/台架/外场流程、安全回退、接管条件	高
开放性	代码、配置、日志、模型权重与视频	中高

17 写作与研究使用建议

若本文将作为学位论文绪论的基础材料，建议在现有框架上补充三类内容：一是与传统控制方法的系统对比，二是目标平台的动力学公式与控制框图，三是与自身课题直接相关的研究空白定位。这样即可形成一篇较完整的绪论或综述章节。

若本文将作为投稿综述初稿，建议进一步引入系统检索方法，例如明确数据库、检索词、时间范围和纳入排除标准；同时把代表性文献矩阵扩展为更标准的综述表，包括是否真实飞行、使用何种仿真器、是否开源、控制频率、状态/动作维度和主要结论。

若本文将作为开题答辩支撑材料，建议从中抽取三页到五页最关键内容：平台差异图、算法谱系图、研究空白表和拟开展的实验路线。答辩场景通常不需要 50 页长文，但需要一个能显示研究判断力的结构化提炼。

从研究策略上，建议优先攻克“容易形成可复现结果”的问题，而不是直接投入最高风险的全端到端真实部署。对于多旋翼，这意味着先做标准化 benchmark；对于固定翼，这意味着优先选择自动着陆、姿态控制或风扰鲁棒性；对于 VTOL，这意味着从过渡段或着陆段的分阶段控制切入。

最后需要强调，飞行 RL 是一个很容易被“演示效果”诱惑的领域。真正高质量的工作，应当把视频中看起来很炫的机动动作，转化为可量化、可复现、可解释、可部署的研究成果。本文的整体结构正是围绕这一目标构建的。

18 附录：逐年发展年表（压缩版）

为便于后续写作引用，本附录将三类平台的 RL 飞行控制发展主线压缩为逐年年表。与前文的代表性文献矩阵不同，年表更强调“发展节奏”和“研究重心迁移”。

18.1 单旋翼/多旋翼年表

年份	阶段主题	代表性变化
2003	真实直升机先驱	模型学习 + RL 证明真实飞行可行

2004-2006	学徒学习与特技机动	从悬停/前飞扩展到翻滚、漏斗等机动
2007-2010	单旋翼探索延续	自转下滑、倒飞等高难度问题被纳入学习控制
2011-2014	过渡期	研究量相对有限，等待深度 RL 成熟
2015	深度 RL 引入背景形成	DQN 引爆 RL，航空控制开始受关注
2016	连续控制算法成熟	DDPG 等方法使连续飞控更可行
2017	PPO 成为稳定基线	更适合四旋翼批量仿真训练
2018	四旋翼姿态控制系统化	公开环境、标准任务、算法比较出现
2019	多算法对比与复现实验	DDPG/TRPO/PPO 被系统评估
2020	轨迹与视觉任务增多	RL 从内环扩展到轨迹跟踪和复杂任务
2021	鲁棒性与协同任务	编队、围捕、强扰动控制等方向发展
2022	低层端到端控制深化	PPO/SAC/TD3 深入到推力与姿态命令层
2023	高敏捷竞速突破	冠军级无人机竞速表明 RL 可达超人水平
2024	零样本迁移机制化	开始总结 sim-to-real 关键因素
2025	在线适应与故障容错	Transformer/适配器与 RL 结合
2026	部署成熟度评估	从算法竞赛走向部署 readiness 评价

18.2 固定翼年表

年份	阶段主题	代表性变化
2018 以前	零散探索	多为局部姿态/决策问题，系统性不足
2019	深度 RL 开始进入固定翼视野	关注路径跟踪与姿态控制

2020	特技机动成为亮点	敏捷固定翼机动显示 RL 的包线扩展潜力
2021	离散到连续方法过渡	Q-learning 等与连续控制方法并存
2022	样本高效与真实部署突破	固定翼姿态控制实现外场飞行验证
2023	高迎角与非线性包线控制	RL 向高 alpha 特技动作扩展
2024	自动着陆与复杂任务拓展	着陆、视觉避障、规划控制耦合增多
2024/2025	模型自由与模型基础比较	开始系统讨论范式优劣
2025	benchmark 意识增强	VVC-GYM 等环境推动标准化
2026	部署导向综述增加	更多从工程视角总结算法选择

18.3 VTOL 年表

年份	阶段主题	代表性变化
2021 以前	案例零散	多以特定平台控制为主，缺少统一方法学
2022	过渡飞行 RL 明确化	transition control 成为重点
2023	数字孪生与平台实现结合	更关注完整系统构型
2024	海上平台着陆与 sim-to-real	分阶段控制显现优势
2025	多智能体倾转旋翼控制	SAC 与模型奖励结合
2025/2026	物理先验融合与方法学总结	开始形成可迁移的设计原则

19 附录：术语、缩写与阅读建议

由于飞行控制和强化学习同时拥有各自的术语体系，读者在跨领域阅读时往往会遇到概念错位。下面给出常见缩写及其在本文中的使用语境。

RL 指强化学习；DRL 指深度强化学习；MDP 指马尔可夫决策过程；PPO、SAC、TD3、DDPG、TRPO 分别代表常用策略优化或 actor-critic 算法；ADP 指自适应

应动态规划；MPC 指模型预测控制；HIL 指硬件在环；SIL 指软件在环；sim-to-real 指从仿真到真实系统迁移；CTDE 指 centralized training with decentralized execution。

在飞行器术语中，inner-loop 常指姿态或角速度内环，outer-loop 常指位置、速度或航迹外环；reference command 指参考命令而非底层执行器指令；control allocation 指将抽象控制量分配到电机、舵面或倾转机构；flight envelope 指飞行包线；transition 在 VTOL 中特指悬停与巡航之间的过渡段。

建议阅读顺序如下：对初学者，可先阅读第 1、2、6、8 章建立整体框架，再分别选读与自己平台相关的第 3、4 或 5 章；对准备开题或投稿的研究者，可重点阅读第 7、9、10、12、14、16 章，这些部分更接近问题定义、方法设计和实验组织；对需要扩写为正式综述论文的读者，可从第 13、18 章中的文献矩阵和年表继续向外扩展。

如果将本文继续扩展，可考虑新增一个“公式与模型附录”，分别给出四旋翼刚体动力学、固定翼纵侧向耦合模型、VTOL 倾转动力学和常见奖励函数模板，以增强其作为论文底稿的可用性。

参考文献

- [1] Ng A Y, Kim H J, Jordan M I, Sastry S. Autonomous helicopter flight via reinforcement learning. Advances in Neural Information Processing Systems, 2003.
- [2] Abbeel P, Coates A, Quigley M, Ng A Y. An application of reinforcement learning to aerobatic helicopter flight. Advances in Neural Information Processing Systems, 2006.
- [3] Lee D J, et al. Autorotation of an unmanned helicopter by a reinforcement learning algorithm. AIAA Guidance, Navigation, and Control Conference, 2008.
- [4] Mnih V, et al. Human-level control through deep reinforcement learning. Nature, 2015.
- [5] Lillicrap T P, et al. Continuous control with deep reinforcement learning. ICLR, 2016.
- [6] Schulman J, et al. Trust region policy optimization. ICML, 2015.
- [7] Schulman J, et al. Proximal policy optimization algorithms. arXiv:1707.06347, 2017.

- [8] Fujimoto S, van Hoof H, Meger D. Addressing function approximation error in actor-critic methods. ICML, 2018.
- [9] Haarnoja T, et al. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. ICML, 2018.
- [10] Koch W, et al. Reinforcement learning for UAV attitude control. ACM Transactions on Cyber-Physical Systems, 2019.
- [11] Kaufmann E, et al. Champion-level drone racing using deep reinforcement learning. Nature, 2023.
- [12] Azar A T, et al. Drone deep reinforcement learning: A review. Electronics, 2021.
- [13] Razzaghi P, Tabrizian A, Guo W. A survey on reinforcement learning in aviation applications. Engineering Applications of Artificial Intelligence, 2024.
- [14] Dang N T, Dao P N. Data-driven reinforcement learning control for quadrotor systems. International Journal of Mechanical Engineering and Robotics Research, 2024.
- [15] Yuste P C, Iglesias Martínez J A, Sanchis de Miguel M A. Simulation-based evaluation of model-free reinforcement learning algorithms for quadcopter attitude control and trajectory tracking. Neurocomputing, 2024.
- [16] Shen S E, et al. Application of reinforcement learning in controlling quadrotor UAV flight actions. Drones, 2024.
- [17] Xue W, et al. An improved proximal policy optimization method for low-altitude fixed-point flight control of a quadrotor. Actuators, 2022.
- [18] Zhang M, et al. Zero-shot sim-to-real transfer of robust and generic quadrotor control policies. 2024.
- [19] What matters in learning a zero-shot sim-to-real RL policy for quadrotor control? A comprehensive study. arXiv, 2024/2025.
- [20] Jang Y, et al. Transformer-based dynamics model for sim-to-real quadrotor control. Applied Soft Computing, 2025.
- [21] Robust reinforcement learning control framework for a quadrotor UAV under disturbances. Advanced Intelligent Systems, 2025.
- [22] Reinforcement learning-based fault-tolerant control for aerial vehicles with transformer-based online adaptation. arXiv, 2025.
- [23] Quadrotor motion control using deep reinforcement learning. Journal of Unmanned Vehicle Systems, 2022.
- [24] Bohn E, et al. Data-efficient deep reinforcement learning for attitude control of fixed-wing UAVs. 2022.
- [25] Bohn E, et al. Deep reinforcement learning for fixed-wing UAV attitude control with real flight experiments. 2022.
- [26] Richter D J, et al. Attitude control for fixed-wing aircraft using Q-learning. ICINCO / related proceedings, 2021.
- [27] Clarke S G, Hwang I. Deep reinforcement learning control for aerobatic maneuvering of agile fixed-wing aircraft. AIAA SciTech, 2020.
- [28] Clarke R, et al. Reinforcement learning derived high-alpha aerobatic maneuvers for fixed-wing aircraft. Algorithms, 2023.
- [29] Li J, et al. Automatic landing control for fixed-wing UAV in complex environments based on deep reinforcement learning. Drones, 2024.
- [30] Olivares D, et al. Model-free versus model-based reinforcement learning for attitude control of fixed-wing unmanned aerial vehicles. ICAART / related proceedings, 2024.
- [31] Khanzada H R, et al. Reinforcement learning for UAV flight controls. PLOS ONE, 2025.
- [32] Giral F, et al. Control and motion planning of fixed-wing UAV through reinforcement learning. Results in Engineering, 2024.

- [33] Yuan Y, et al. Reinforcement learning for dual-control aircraft six-degree-of-freedom attitude control. Aerospace, 2024.
- [34] Xu D, et al. PPO-Exp: Keeping fixed-wing UAV formation with deep reinforcement learning. Drones, 2022.
- [35] Wang X, et al. Deep reinforcement learning-based air combat maneuver decision-making: A review or framework-oriented paper. Artificial Intelligence Review, 2024.
- [36] VVC-GYM: A fixed-wing UAV reinforcement learning benchmark. ICLR, 2025.
- [37] Transition flight control system design for fixed-wing VTOL UAV: A reinforcement learning approach. AIAA SciTech, 2022.
- [38] Ali A M, Gupta A, Hashim H A. Deep reinforcement learning for sim-to-real policy transfer of VTOL-UAVs offshore docking operations. Applied Soft Computing, 2024.
- [39] Ugur M, Yesildirek A. Improving control performance of tilt-rotor VTOL UAV with model-based reward and multi-agent reinforcement learning. Aerospace, 2025.
- [40] A learning-based control methodology for transitioning UAVs. arXiv, 2025.
- [41] Physics-informed sparse reinforcement learning for hybrid UAV control. Aerospace Science and Technology, 2026.
- [42] Memlikai G, et al. Reinforcement learning for UAV control: From algorithms to deployment readiness. Machines, 2026.
- [43] Coates A, Abbeel P, Ng A Y. Apprenticeship learning for helicopter control. Communications of the ACM / related earlier conference version, 2009.
- [44] Sutton R S, Barto A G. Reinforcement Learning: An Introduction. 2nd ed., MIT Press, 2018.
- [45] Ross S, Gordon G, Bagnell D. A reduction of imitation learning and structured prediction to no-regret online learning. AISTATS, 2011.
- [46] Levine S, Kumar A, Tucker G, Fu J. Offline reinforcement learning: Tutorial, review, and perspectives on open problems. arXiv, 2020.
- [47] Garcia J, Fernandez F. A comprehensive survey on safe reinforcement learning. JMLR, 2015.
- [48] Berkenkamp F, et al. Safe model-based reinforcement learning with stability guarantees. NeurIPS, 2017.
- [49] Achiam J, et al. Constrained policy optimization. ICML, 2017.
- [50] Todorov E, Erez T, Tassa Y. MuJoCo: A physics engine for model-based control. IROS, 2012.
- [51] Meier F, et al. RotorS - A modular Gazebo MAV simulator framework. 2015.
- [52] Shah S, et al. AirSim: High-fidelity visual and physical simulation for autonomous vehicles. Field and Service Robotics, 2017.
- [53] Song Y, et al. Flightmare: A flexible quadrotor simulator. CoRL, 2020.
- [54] JSBSim development team. JSBSim Flight Dynamics Model documentation and project materials.
- [55] FlightGear project. FlightGear Flight Simulator documentation and project materials.
- [56] BlueSky ATC Simulator project documentation.
- [57] Huang D, Hu J, Peng Z, et al. Model-free based reinforcement learning control strategy of aircraft attitude systems. Chinese Automation Congress, 2020.
- [58] Weak-model based reinforcement learning control strategy of aircraft attitude system. Lecture Notes in Electrical Engineering, 2022.
- [59] Path following control for UAV using deep reinforcement learning approach. International Journal of Unmanned Systems Engineering, 2021.
- [60] Reinforcement learning based robust tracking control for helicopters with input saturation and state constraints. Aerospace Science and Technology, 2024.

- [61] Application of reinforcement learning to aerobatic helicopter flight and related follow-up publications on inverted helicopter flight. 2006–2008.
- [62] Deep reinforcement learning automatic landing control of fixed-wing aircraft using deep deterministic policy gradient. conference/technical report, 2020s.
- [63] Monocular obstacle avoidance based on inverse PPO for fixed-wing UAVs. arXiv, 2024.
- [64] Deep reinforcement learning based quadrotor control challenges and engineering considerations. ACM, 2024.
- [65] Survey of inverse reinforcement learning in aviation and aerospace. AIAA Journal of Aerospace Information Systems, 2026.