

强化学习在飞行控制中的应用：综述

A Comprehensive Survey on Reinforcement Learning for Flight Control

2026 年 3 月

摘要

强化学习 (Reinforcement Learning, RL) 作为一种数据驱动的智能控制方法,近年来在飞行控制领域取得了显著进展。本文系统综述了强化学习在多旋翼、固定翼和垂直起降 (VTOL) 三种主要飞行平台控制中的研究进展,涵盖 100 余篇近期文献,包括 2025-2026 年的最新研究成果。

首先,本文介绍了强化学习与飞行控制的基础理论,包括马尔可夫决策过程、主流深度强化学习算法 (PPO、SAC、TD3 等) 以及飞行器动力学建模。然后,分别深入分析了三种平台的 RL 控制方法、主流算法及其应用案例,重点讨论了各算法的适用性与局限性。

此外,本文详细探讨了 Sim-to-Real 迁移、样本效率、安全保证等关键挑战及解决方案,包括域随机化、系统辨识、残差学习等技术。还讨论了奖励函数设计、神经网络架构、训练技巧等工程实践问题。

最后,本文展望了该领域的未来研究方向,包括安全强化学习、端到端自主飞行、集群协同控制等前沿趋势。本文旨在为研究人员和工程师提供全面的技术参考和研究指引。

目录

1 引言	6
1.1 研究背景与意义	6
1.2 问题定义与挑战	7
1.3 研究现状概述	8
1.4 本文组织结构	9
2 强化学习与飞行控制基础	9
2.1 强化学习基础	9
2.1.1 马尔可夫决策过程	9

2.1.2	策略与价值函数	9
2.1.3	优势函数	10
2.2	主流深度强化学习算法	10
2.2.1	策略梯度方法	10
2.2.2	Actor-Critic 架构	10
2.2.3	PPO (Proximal Policy Optimization)	11
2.2.4	SAC (Soft Actor-Critic)	11
2.2.5	TD3 (Twin Delayed DDPG)	11
2.2.6	算法对比总结	12
2.3	飞行器动力学建模	12
2.3.1	多旋翼动力学	12
2.3.2	固定翼动力学	12
2.3.3	VTOL 动力学	13
2.4	仿真环境与基准测试	13
2.4.1	常用仿真平台	13
2.4.2	基准测试任务	13
3	多旋翼无人机强化学习控制	13
3.1	姿态控制	14
3.1.1	问题描述	14
3.1.2	基于 PPO 的姿态控制	14
3.1.3	基于 SAC 的姿态控制	14
3.1.4	姿态控制方法对比	15
3.2	位置与轨迹跟踪控制	15
3.2.1	级联控制架构	15
3.2.2	轨迹跟踪的 RL 方法	15
3.3	避障与路径规划	16
3.3.1	基于视觉的避障	16
3.3.2	多智能体协同避障	16
3.4	故障容错控制	16
3.4.1	执行器故障的 RL 处理	16
3.5	多旋翼 RL 控制的局限性与挑战	16
4	固定翼飞行器强化学习控制	17
4.1	巡航与机动控制	17
4.1.1	巡航控制	17
4.1.2	机动控制	17
4.2	失速恢复与边界保护	17

4.2.1	失速恢复控制	17
4.2.2	包线保护	18
4.3	路径跟踪与制导	18
4.3.1	路径跟踪 RL 方法	18
4.4	固定翼 RL 控制的挑战	18
5	垂直起降飞行器强化学习控制	18
5.1	过渡飞行控制	18
5.1.1	过渡飞行的挑战	18
5.1.2	基于 RL 的耦合过渡控制	19
5.2	倾转旋翼控制	19
5.2.1	多智能体 RL 控制	19
5.2.2	离线 RL 方法	19
5.3	尾座式无人机控制	20
5.4	多模态切换策略	20
5.4.1	混合控制架构	20
6	实验验证与应用	20
6.1	仿真平台与工具	20
6.1.1	Gazebo	20
6.1.2	AirSim	20
6.1.3	Isaac Gym	21
6.2	Sim-to-Real 迁移技术	21
6.2.1	域随机化 (Domain Randomization)	21
6.2.2	系统辨识 (System Identification)	21
6.2.3	残差学习 (Residual Learning)	21
6.3	性能对比分析	22
7	未来研究方向	22
7.1	技术挑战	22
7.1.1	安全强化学习	22
7.1.2	样本效率提升	22
7.1.3	可解释性	22
7.2	研究趋势	23
7.2.1	端到端自主飞行	23
7.2.2	集群协同控制	23
7.2.3	人机协同	23
7.3	展望	24

8 算法详细对比与分析	24
8.1 PPO 算法深度分析	24
8.1.1 算法原理与数学推导	24
8.1.2 优势函数估计	24
8.1.3 在飞行控制中的优势	25
8.1.4 局限性与改进方向	25
8.2 SAC 算法深度分析	25
8.2.1 最大熵强化学习框架	25
8.2.2 自动温度调整	25
8.2.3 在飞行控制中的优势	25
8.2.4 局限性与改进方向	26
8.3 TD3 与 DDPG 对比分析	26
8.3.1 DDPG 的过估计问题	26
8.3.2 TD3 的三项改进	26
8.3.3 适用场景分析	26
8.4 算法选择决策树	26
9 奖励函数设计方法论	26
9.1 奖励函数的重要性与挑战	26
9.2 常见奖励函数组件	27
9.2.1 跟踪误差奖励	27
9.2.2 控制量惩罚	27
9.2.3 能耗惩罚	27
9.2.4 存活与任务奖励	28
9.3 奖励塑形技术	28
9.3.1 势函数塑形	28
9.3.2 课程学习	28
9.3.3 多尺度奖励	28
10 神经网络架构与训练技巧	28
10.1 策略网络设计	28
10.1.1 MLP 架构	28
10.1.2 考虑时序的架构	29
10.1.3 注意力机制	29
10.2 超参数调优指南	29
10.2.1 学习率	29
10.2.2 折扣因子	29
10.2.3 GAE 参数	29

目录	5
10.3 归一化与预处理	30
10.4 并行训练	30
11 安全强化学习	30
11.1 安全挑战	30
11.2 安全 RL 方法	30
11.2.1 约束 MDP (CMDP)	30
11.2.2 安全层 (Safety Layer)	30
11.2.3 控制屏障函数 (CBF)	31
12 实飞部署技术	31
12.1 嵌入式平台	31
12.1.1 常用平台对比	31
12.2 推理优化	31
12.2.1 模型量化	31
12.2.2 TensorRT 优化	31
12.3 软件架构	32
13 典型应用案例分析	32
13.1 案例 1: 无人机竞速	32
13.2 案例 2: 高速野外飞行	32
13.3 案例 3: 精准着陆	33
14 结论	33
A 常用仿真环境配置	48
A.1 Gazebo 仿真环境	48
A.2 AirSim 仿真环境	49
A.3 Isaac Gym 配置	49
B RL 算法实现代码示例	50
B.1 PPO 实现核心代码	50
B.2 SAC 实现核心代码	51
C 超参数推荐表	53
D 常用数据集与基准	53
D.1 飞行数据集	53
D.2 仿真基准任务	54

E 学术会议与期刊	54
E.1 顶级会议	54
E.2 权威期刊	54

1 引言

1.1 研究背景与意义

无人机 (Unmanned Aerial Vehicles, UAVs) 在现代航空领域扮演着越来越重要的角色, 广泛应用于军事侦察、物流配送、农业监测、灾害救援、基础设施巡检等领域。根据飞行原理和结构特点, 无人机主要分为三大类:

1. **多旋翼 (Multicopter)**: 以四旋翼、六旋翼、八旋翼为代表, 具有垂直起降、悬停、机动灵活等特点, 是目前应用最广泛的无人机类型。
2. **固定翼 (Fixed-wing)**: 类似传统飞机, 具有航程远、速度快、能效高等优势, 适合长距离任务。
3. **垂直起降 (VTOL)**: 结合多旋翼和固定翼的优点, 既能垂直起降又能高效巡航, 包括倾转旋翼、尾座式等构型。

传统飞行控制方法主要基于经典控制理论, 如 PID 控制、线性二次调节器 (LQR)、模型预测控制 (MPC)、反馈线性化等。这些方法在特定工况下表现良好, 但存在以下局限性:

- **模型依赖**: 需要精确的动力学模型, 而实际飞行器往往存在模型不确定性, 包括质量变化、气动参数漂移、执行器特性变化等。
- **参数整定困难**: 控制器参数依赖专家经验, 需要大量试错, 难以适应复杂多变的环境。
- **非线性处理能力有限**: 对于强非线性、强耦合的系统, 线性化方法性能受限。
- **适应性差**: 难以自动适应故障、损伤、环境变化等情况。

强化学习作为一种通过与环境交互学习最优策略的机器学习方法, 为飞行控制提供了新的解决思路。RL 方法具有以下优势:

1. **模型无关**: 无需精确数学模型, 可直接从数据中学习控制策略。
2. **高维处理能力**: 能够处理高维状态空间和连续动作空间, 适合复杂的飞行控制任务。
3. **适应性强**: 具备适应不确定性、扰动和变化的能力。
4. **端到端学习**: 可实现从感知到控制的端到端学习, 简化系统架构。
5. **持续优化**: 可在线学习和适应, 不断提升性能。

近年来,深度强化学习 (Deep Reinforcement Learning, DRL) 的快速发展推动了 RL 在飞行控制领域的广泛应用。从 2015 年 Deep Q-Network(DQN) 的提出,到 Proximal Policy Optimization(PPO)、Soft Actor-Critic(SAC)、Twin Delayed Deep Deterministic Policy Gradient(TD3) 等算法的成熟,RL 在无人机姿态控制、轨迹跟踪、避障导航、故障容错等任务中取得了突破性进展。

1.2 问题定义与挑战

将强化学习应用于飞行控制面临以下核心挑战:

挑战 1: Sim-to-Real 迁移 Gap

仿真环境与真实环境之间存在显著差异,包括:

- 动力学差异: 仿真模型难以完全捕捉真实飞行器的动力学特性
- 传感器噪声: 真实传感器存在噪声、偏差和延迟
- 执行器延迟: 电机响应存在时间延迟和非线性
- 风扰动: 真实环境中的风场复杂多变
- 地面效应: 近地面飞行时的气动干扰

这些因素导致仿真训练的策略难以直接部署到真实飞行器,性能可能显著下降甚至失控。

挑战 2: 样本效率

飞行控制任务需要大量交互样本进行训练:

- 真实飞行试验成本高昂 (设备、场地、人员)
- 存在安全风险,不能随意探索危险状态
- 飞行时间有限,数据收集效率低
- 某些极端状态 (如失速、故障) 难以在实飞中复现

如何在有限样本下高效学习是亟待解决的问题。

挑战 3: 安全保证

飞行器的安全性至关重要:

- RL 策略的决策过程缺乏可解释性
- 难以提供严格的安全保证
- 分布外泛化能力不确定

- 认证和监管困难

挑战 4：实时性约束

飞行控制需要高频率的实时决策：

- 姿态控制通常需要 250-1000Hz
- 位置控制通常需要 50-100Hz
- 深度神经网络的推理延迟可能成为瓶颈
- 嵌入式平台的计算资源有限

挑战 5：泛化能力

训练好的策略在面对未见过的环境条件时，性能可能显著下降：

- 不同飞行器参数（质量、惯性、推力）
- 环境变化（风、温度、气压）
- 任务变化（负载、速度要求）
- 传感器配置差异

1.3 研究现状概述

近年来，RL 在飞行控制领域的研究呈现以下特点：

(1) **多旋翼平台研究最为成熟**。由于多旋翼动力学相对简单、仿真环境完善、实验成本低，RL 在四旋翼姿态控制、位置控制、轨迹跟踪等任务中已取得大量成功案例，部分方法已实现实飞验证和商业应用。

(2) **固定翼平台研究稳步推进**。针对固定翼飞行器的巡航控制、机动飞行、失速恢复等任务，研究者提出了多种 RL 方法，但受限于动力学复杂性和实验安全性，实飞验证相对较少。

(3) **VTOL 平台研究处于起步阶段**。VTOL 飞行器的过渡飞行控制涉及多模态切换，动力学高度非线性，目前 RL 应用研究较少，但随着城市空中交通 (UAM) 的发展，这一领域潜力巨大。

(4) **算法以 PPO 和 SAC 为主流**。PPO 因其稳定性和易用性成为最广泛使用的算法，SAC 在样本效率方面表现优异，TD3、DDPG 等算法也有特定应用场景。

(5) **Sim-to-Real 技术快速发展**。域随机化 (Domain Randomization)、系统辨识 (System Identification)、残差学习 (Residual Learning)、元学习 (Meta-Learning) 等技术显著提升了策略的迁移能力。

1.4 本文组织结构

本文的组织结构如下：

第2章介绍强化学习与飞行控制的基础理论，包括 RL 基本框架、飞行器动力学建模和仿真环境。

第3章系统综述多旋翼无人机的 RL 控制方法，涵盖姿态控制、位置控制、避障和故障容错等任务。

第4章深入分析固定翼飞行器的 RL 控制技术，包括巡航控制、机动飞行、失速恢复和路径跟踪。

第5章探讨 VTOL 飞行器的 RL 控制挑战与进展，重点关注过渡飞行和模态切换。

第6章总结实验验证与应用案例，讨论 Sim-to-Real 迁移和性能评估。

第7章展望未来的研究方向和技术趋势。

最后，第14章对全文进行总结。

2 强化学习与飞行控制基础

2.1 强化学习基础

2.1.1 马尔可夫决策过程

强化学习问题通常建模为马尔可夫决策过程 (Markov Decision Process, MDP)，由五元组 $(\mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R}, \gamma)$ 定义：

- $\mathcal{S}$ ：状态空间，表示环境的所有可能状态
- $\mathcal{A}$ ：动作空间，表示智能体可执行的所有动作
- $\mathcal{P}(s'|s, a)$ ：状态转移概率，表示在状态 s 执行动作 a 后转移到状态 s' 的概率
- $\mathcal{R}(s, a)$ ：奖励函数，表示在状态 s 执行动作 a 获得的即时奖励
- $\gamma \in [0, 1]$ ：折扣因子，用于平衡即时奖励与未来奖励

在飞行控制中，状态 s 通常包括飞行器的位置 $\mathbf{p}$ 、速度 $\mathbf{v}$ 、姿态 (旋转矩阵 $\mathbf{R}$ 或四元数 $\mathbf{q}$)、角速度 $\boldsymbol{\omega}$ 等；动作 a 通常包括推力 T 和力矩 $\mathbf{M} = [M_x, M_y, M_z]^T$ 或控制面偏转。

2.1.2 策略与价值函数

策略 $\pi(a|s)$ 定义了状态 s 下选择动作 a 的概率分布。目标是找到最优策略 π^* ，使得累积折扣奖励最大化：

$$\pi^* = \arg \max_{\pi} \mathbb{E}_{\tau \sim \pi} \left[\sum_{t=0}^T \gamma^t r_t \right] \quad (1)$$

状态价值函数 $V^\pi(s)$ 表示从状态 s 开始，遵循策略 π 的期望累积奖励：

$$V^\pi(s) = \mathbb{E}_\pi \left[\sum_{t=0}^T \gamma^t r_t \mid s_0 = s \right] \quad (2)$$

动作价值函数 $Q^\pi(s, a)$ 表示在状态 s 执行动作 a 后，遵循策略 π 的期望累积奖励：

$$Q^\pi(s, a) = \mathbb{E}_\pi \left[\sum_{t=0}^T \gamma^t r_t \mid s_0 = s, a_0 = a \right] \quad (3)$$

2.1.3 优势函数

优势函数 $A^\pi(s, a)$ 表示在状态 s 采取动作 a 相对于平均水平的优势：

$$A^\pi(s, a) = Q^\pi(s, a) - V^\pi(s) \quad (4)$$

优势函数在策略梯度方法中起着关键作用，用于降低方差。

2.2 主流深度强化学习算法

2.2.1 策略梯度方法

策略梯度方法直接参数化策略 $\pi_\theta(a|s)$ ，通过梯度上升优化策略参数 θ 。基础策略梯度定理为：

$$\nabla_\theta J(\theta) = \mathbb{E}_{\pi_\theta} [\nabla_\theta \log \pi_\theta(a|s) \cdot Q^{\pi_\theta}(s, a)] \quad (5)$$

REINFORCE 算法使用蒙特卡洛估计：

$$\nabla_\theta J(\theta) \approx \frac{1}{N} \sum_{i=1}^N \nabla_\theta \log \pi_\theta(\tau^{(i)}) R(\tau^{(i)}) \quad (6)$$

2.2.2 Actor-Critic 架构

Actor-Critic 方法结合了策略梯度和价值函数估计，包含两个网络：

- Actor 网络：参数化策略 $\pi_\theta(a|s)$ ，负责决策
- Critic 网络：估计价值函数 $V_\phi(s)$ 或 $Q_\phi(s, a)$ ，负责评估

这种架构的优势在于 Critic 提供的基线可以降低方差，加速训练。

2.2.3 PPO (Proximal Policy Optimization)

PPO 是飞行控制中最广泛使用的算法，由 OpenAI 于 2017 年提出。PPO 通过裁剪目标函数限制策略更新幅度，避免策略发生剧烈变化：

$$L^{CLIP}(\theta) = \mathbb{E}_t \left[\min \left(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right] \quad (7)$$

其中 $r_t(\theta) = \frac{\pi_\theta(a_t|s_t)}{\pi_{\theta_{old}}(a_t|s_t)}$ 是策略比率， $\hat{A}_t$ 是优势函数估计， ϵ 通常取 0.1 或 0.2。

PPO 的优势在于：

1. 实现简单，代码量小
2. 超参数敏感度低，易于调参
3. 样本效率较高
4. 训练稳定性好，不易发散
5. 支持并行训练

2.2.4 SAC (Soft Actor-Critic)

SAC 是一种最大熵强化学习算法，在最大化奖励的同时最大化策略熵：

$$J(\pi) = \sum_{t=0}^T \mathbb{E}_\pi [r(s_t, a_t) + \alpha \mathcal{H}(\pi(\cdot|s_t)))] \quad (8)$$

其中 α 是温度参数，自动调整以平衡奖励和熵。

SAC 的关键特点：

- Off-policy 学习，可重复利用历史数据
- 样本效率最高，适合数据收集成本高的场景
- 熵正则化鼓励探索，避免过早收敛
- 双 Q 网络减少过估计

2.2.5 TD3 (Twin Delayed DDPG)

TD3 通过三项改进解决 DDPG 的过估计问题：

(1) **双 Q 网络**：使用两个 Q 网络，取较小值作为目标：

$$y = r + \gamma \min_{i=1,2} Q_{\phi'_i}(s', \pi_{\theta'}(s')) + \epsilon \quad (9)$$

(2) **延迟策略更新**：每更新两次 Q 网络才更新一次策略，减少策略更新频率。

(3) **目标策略平滑**：在目标动作上添加噪声，平滑 Q 函数：

$$\epsilon \sim \text{clip}(\mathcal{N}(0, \sigma), -c, c) \quad (10)$$

2.2.6 算法对比总结

表 1: 主流深度强化学习算法对比

算法	类型	样本效率	稳定性	实现难度	适用场景
PPO	On-policy	中	高	低	通用首选
SAC	Off-policy	高	中	中	数据有限
TD3	Off-policy	高	高	中	高精度控制
DDPG	Off-policy	中	低	低	简单任务
TRPO	On-policy	中	高	高	理论研究

2.3 飞行器动力学建模

2.3.1 多旋翼动力学

四旋翼飞行器的动力学模型可表示为：

$$\dot{\mathbf{p}} = \mathbf{v} \quad (11)$$

$$m\dot{\mathbf{v}} = -mg\mathbf{e}_3 + \mathbf{R}\mathbf{e}_3T + \mathbf{F}_{dist} \quad (12)$$

$$\dot{\mathbf{R}} = \mathbf{R}[\boldsymbol{\omega} \times] \quad (13)$$

$$\mathbf{J}\dot{\boldsymbol{\omega}} = -\boldsymbol{\omega} \times \mathbf{J}\boldsymbol{\omega} + \mathbf{M} + \mathbf{M}_{dist} \quad (14)$$

其中 m 为质量， $\mathbf{J}$ 为惯性矩阵， T 为总推力， $\mathbf{M}$ 为控制力矩， $\mathbf{F}_{dist}$ 和 $\mathbf{M}_{dist}$ 为扰动力和力矩。

电机模型：

$$T_i = k_T \omega_i^2, \quad M_i = k_M \omega_i^2 \quad (15)$$

其中 k_T 和 k_M 分别是推力系数和力矩系数。

2.3.2 固定翼动力学

固定翼飞行器的六自由度动力学：

$$\dot{\mathbf{p}} = \mathbf{R}\mathbf{v}_b \quad (16)$$

$$m\dot{\mathbf{v}}_b = -m\boldsymbol{\omega} \times \mathbf{v}_b + \mathbf{F}_{aero} + \mathbf{F}_{grav} + \mathbf{F}_{thrust} \quad (17)$$

$$\dot{\mathbf{R}} = \mathbf{R}[\boldsymbol{\omega} \times] \quad (18)$$

$$\mathbf{J}\dot{\boldsymbol{\omega}} = -\boldsymbol{\omega} \times \mathbf{J}\boldsymbol{\omega} + \mathbf{M}_{aero} + \mathbf{M}_{control} \quad (19)$$

气动力和力矩取决于攻角 α 、侧滑角 β 、空速 V 和控制面偏转 δ ：

$$\mathbf{F}_{aero} = \frac{1}{2}\rho V^2 S \mathbf{C}_F(\alpha, \beta, \delta) \quad (20)$$

2.3.3 VTOL 动力学

VTOL 飞行器在过渡飞行阶段涉及多旋翼和固定翼模式的切换，动力学模型更为复杂。对于倾转旋翼 VTOL：

$$m\dot{\mathbf{v}} = \mathbf{F}_{rotor}(\theta_{tilt}) + \mathbf{F}_{wing}(\alpha, V) + \mathbf{F}_{grav} \quad (21)$$

其中 θ_{tilt} 为倾转角度，过渡过程中气动特性发生显著变化。

2.4 仿真环境与基准测试

2.4.1 常用仿真平台

表 2: 主流飞行控制仿真平台对比

平台	物理引擎	传感器	RL 接口	适用平台
Gazebo	ODE/Bullet	完整	Gym 接口	全平台
AirSim	UE4	视觉 +IMU	Gym 接口	全平台
Isaac Gym	PhysX	完整	GPU 并行	多旋翼
PyBullet	Bullet	基础	Gym 接口	多旋翼
JSBSim	自定义	完整	自定义	固定翼
FlightGear	自定义	完整	自定义	固定翼

2.4.2 基准测试任务

- (1) **姿态控制**：跟踪期望的滚转、俯仰、偏航角，典型要求误差 $< 5^\circ$ 。
- (2) **位置控制**：跟踪期望的位置和速度，典型要求位置误差 $< 0.1\text{m}$ 。
- (3) **轨迹跟踪**：跟踪时变参考轨迹，如圆形、八字形轨迹。
- (4) **避障导航**：在障碍物环境中规划路径，到达目标点。
- (5) **过渡飞行**：VTOL 飞行器的模式切换，从悬停到前飞或反向。

3 多旋翼无人机强化学习控制

多旋翼无人机 (以四旋翼为代表) 因其结构简单、机动性强、可垂直起降等特点，成为强化学习飞行控制研究最广泛的平台。本章系统综述多旋翼 RL 控制在姿态控制、位置控制、避障导航和故障容错等方面的研究进展。

3.1 姿态控制

3.1.1 问题描述

姿态控制是多旋翼飞行控制的基础，目标是使飞行器的实际姿态 $\mathbf{R}$ 跟踪期望姿态 $\mathbf{R}_{des}$ 。状态空间通常包括：

$$s = [\phi, \theta, \psi, p, q, r, \phi_{des}, \theta_{des}, \psi_{des}] \in \mathbb{R}^9 \quad (22)$$

动作空间为归一化的力矩指令：

$$a = [\tau_x, \tau_y, \tau_z] \in [-1, 1]^3 \quad (23)$$

奖励函数通常设计为：

$$r = -w_1 \|\mathbf{e}_{att}\|^2 - w_2 \|\boldsymbol{\omega}\|^2 - w_3 \|\mathbf{a}\|^2 \quad (24)$$

3.1.2 基于 PPO 的姿态控制

Koch 等人 (2019) 首次将 PPO 应用于四旋翼姿态控制，在 Gazebo 仿真环境中实现了对 Simulink 仿真器训练策略的迁移。其核心贡献在于：

- (1) 设计了包含姿态误差、角速度、控制量的奖励函数。
- (2) 通过域随机化提升策略鲁棒性，随机化参数包括质量、惯性、电机响应时间等。
- (3) 实现了从仿真到 Crazyflie 微型无人机的成功迁移。

局限性分析：该方法假设推力恒定，仅控制力矩，实际应用中需要与高度控制器配合。此外，奖励函数权重需要针对具体平台仔细调参。

3.1.3 基于 SAC 的姿态控制

SAC 在样本效率方面的优势使其适合数据收集成本高的场景。研究表明，SAC 在姿态控制任务上通常比 PPO 收敛更快，但策略的稳定性略逊。

Zhang 等人 (2023) 提出了 "Learning a single near-hover position controller for vastly different quadcopters"，使用 SAC 训练单一策略控制多种不同规格的四旋翼，展示了强大的泛化能力。

关键创新：

- 使用飞行器物理参数 (质量、臂长、推力系数) 作为策略输入
- 设计自适应奖励函数，根据飞行器特性动态调整
- 在 8 种不同四旋翼平台上验证，均实现稳定悬停

局限性：该方法主要针对悬停和近悬停状态，对于大机动飞行的适用性有限。

表 3: 多旋翼姿态控制 RL 方法对比

方法	算法	训练样本	跟踪误差	实飞验证	年份
Koch et al.	PPO	10^6	$< 5^\circ$	Crazyflie	2019
Song et al.	DDPG	5×10^5	$< 3^\circ$	无	2021
Zhang et al.	SAC	2×10^6	$< 2^\circ$	多平台	2023
MDPI 2025	PPO+PD	10^5	$< 4^\circ$	有	2025

3.1.4 姿态控制方法对比

3.2 位置与轨迹跟踪控制

3.2.1 级联控制架构

实际应用中，位置控制通常采用级联架构：外环位置控制器生成期望姿态，内环姿态控制器跟踪期望姿态。RL 可应用于外环、内环或端到端。

方案 1: RL 位置控制器 + 传统姿态控制器

RL 策略输出期望姿态和总推力，由 PID 或 LQR 内环控制器跟踪。这种方案的优势在于：

- 利用传统控制器保证姿态稳定性
- RL 专注于处理位置动力学的不确定性
- 更容易实现 Sim-to-Real 迁移

方案 2: 端到端 RL 控制

RL 策略直接输出四个电机的转速指令。这种方案可以实现更优的性能，但训练难度大，安全性保障困难。

3.2.2 轨迹跟踪的 RL 方法

轨迹跟踪任务要求飞行器跟踪时变参考轨迹 $\mathbf{p}_{ref}(t)$ 。奖励函数设计是关键：

$$r_t = -\|\mathbf{p}_t - \mathbf{p}_{ref,t}\|^2 - w_v \|\mathbf{v}_t - \mathbf{v}_{ref,t}\|^2 - w_a \|a_t\|^2 + r_{bonus} \quad (25)$$

其中 r_{bonus} 为任务完成奖励，用于引导策略学习长期行为。

Nature Scientific Reports 2025 年的工作”RL for end-to-end UAV slung-load navigation”研究了带悬挂负载的轨迹跟踪问题，这是一个极具挑战性的欠驱动系统。

3.3 避障与路径规划

3.3.1 基于视觉的避障

将深度相机或激光雷达数据纳入状态空间，RL 策略学习避障行为。状态空间维度高 (图像通常为 $64 \times 64 \times 3$ 或更高)，需要采用以下技术：

- (1) **卷积编码器**：使用 CNN 提取图像特征，降低状态维度
- (2) **注意力机制**：关注障碍物区域，提高决策效率
- (3) **课程学习**：从简单场景逐步过渡到复杂环境

3.3.2 多智能体协同避障

MDPI Drones 2025 年的综述“A Survey on UAV Control with Multi-Agent RL”系统总结了多智能体强化学习 (MARL) 在无人机集群控制中的应用。MADDPG、MAPPO 等算法被用于多机协同避障和编队控制。

3.4 故障容错控制

3.4.1 执行器故障的 RL 处理

执行器故障 (如电机失效) 会显著改变飞行器动力学。传统方法需要重新设计控制器，而 RL 可以通过在线学习适应故障。

Springer JIRS 2025 年的工作“Learning uncertainties online for quadrotor flight control”提出了在线学习框架，结合数据驱动的扰动估计和名义控制器，实现了对模型不确定性和故障的适应。

arXiv 2025 年的工作“RL-based Fault-Tolerant Control with Online Transformer Adaptation”创新性地将 Transformer 引入故障检测和策略适应。

3.5 多旋翼 RL 控制的局限性与挑战

尽管取得了显著进展，多旋翼 RL 控制仍面临以下局限：

- (1) **奖励函数设计依赖专家知识**：不同任务需要精心设计的奖励函数，缺乏通用设计方法。
- (2) **Sim-to-Real Gap 仍然存在**：虽然域随机化等技术有所改进，但在强风、GPS 拒止等极端条件下的迁移仍是挑战。
- (3) **可解释性不足**：神经网络策略的决策过程难以解释，不利于安全认证。
- (4) **计算资源需求**：实飞部署需要嵌入式 GPU，功耗和重量是微型无人机的约束。

4 固定翼飞行器强化学习控制

固定翼飞行器具有航程远、速度快、能效高等优势，在长距离侦察、测绘、物流等场景中广泛应用。与多旋翼相比，固定翼动力学更为复杂，涉及失速、螺旋等非线性气动现象，对 RL 控制提出了更高要求。

4.1 巡航与机动控制

4.1.1 巡航控制

巡航控制的目标是维持恒定的空速、高度和航向。PLOS One 2025 年的工作”Evaluating continuous space RL algorithms for fixed-wing UAVs”系统比较了 DDPG、TD3、PPO、TRPO 和 SAC 五种算法在固定翼巡航控制中的性能。

实验设置：

- 飞行器模型：高保真 6-DOF 固定翼 UAV
- 状态空间： $[V, h, \chi, \alpha, \beta, p, q, r]$
- 动作空间： $[\delta_e, \delta_a, \delta_r, \delta_t]$

核心发现：

- PPO 在位置精度方面表现最佳，53.3% 的飞行时间保持在目标位置 0.1 米范围内
- SAC 样本效率最高，仅需 32 个训练回合即可收敛
- TD3 在稳定性方面表现优异，但收敛速度较慢

4.1.2 机动控制

机动飞行涉及大攻角、高过载等极端工况，传统增益调度控制器的性能受限。ScienceDirect 2025 年的工作提出了集成注意力机制、残差网络、模仿学习和课程学习的 PPO 框架。

4.2 失速恢复与边界保护

4.2.1 失速恢复控制

失速 (Stall) 是固定翼飞行器的危险状态，传统控制方法在深度失速 (Deep Stall) 和尾旋 (Spin) 状态下往往失效。arXiv 2026 年的工作”DRL for Aircraft Recovery from Loss-of-Control”将失速恢复建模为连续状态-连续动作的 MDP，使用 PPO 训练恢复策略。

关键贡献：

- 基于 F-18/HARV 高保真模型的训练环境
- 考虑非线性气动、执行器饱和和速率耦合
- 成功实现了从尾旋状态的自动恢复

4.2.2 包线保护

飞行包线保护旨在防止飞行器进入危险状态。MDPI Aerospace 2025 年的工作”Precise Cruise Control with Nonlinear Attitude Constraints” 提出了基于 PPO 的非线性姿态约束控制方法。

4.3 路径跟踪与制导

4.3.1 路径跟踪 RL 方法

路径跟踪要求飞行器跟踪预设的航路点序列。arXiv 2025 年的工作”Adversarial RL for Robust Path Following” 提出了对抗强化学习框架，训练对气动模型不确定性鲁棒的路径跟踪控制器。

4.4 固定翼 RL 控制的挑战

- (1) **动力学复杂性**：固定翼涉及复杂的气动效应，精确建模困难。
- (2) **训练安全性**：危险状态（如失速）的样本难以在实飞中获取。
- (3) **验证困难**：实飞试验成本高，风险大，大多数研究停留在仿真阶段。
- (4) **法规限制**：固定翼通常需要空域申请，限制了大规模实验。

5 垂直起降飞行器强化学习控制

VTOL 飞行器结合了多旋翼的垂直起降能力和固定翼的高效巡航能力，在城市空中交通 (UAM)、物流配送等场景中具有巨大潜力。然而，VTOL 的过渡飞行控制涉及多模态切换，动力学高度非线性，是 RL 应用最具挑战性的领域之一。

5.1 过渡飞行控制

5.1.1 过渡飞行的挑战

过渡飞行是指 VTOL 飞行器从悬停模式切换到前飞模式（或反向）的过程。这一过程中：

- 气动特性发生剧烈变化

- 操纵冗余度降低
- 存在不稳定平衡点
- 对抗动敏感

传统方法通常将过渡飞行简化为纵向平面问题，使用增益调度或轨迹优化。但这种方法难以处理三维空间中的复杂机动。

5.1.2 基于 RL 的耦合过渡控制

arXiv 2025 年的工作“A Learning-based Control Methodology for Transitioning VTOL UAVs”提出了耦合过渡控制方法，解决了传统方法高度和位置解耦控制导致的振动问题。

核心思想：

- 将过渡飞行建模为统一的 RL 问题
- 状态空间包含完整的位置、速度、姿态信息
- 动作空间输出倾转角度和旋翼转速
- 奖励函数综合考虑跟踪精度、平滑性和能耗

5.2 倾转旋翼控制

5.2.1 多智能体 RL 控制

MDPI Aerospace 2025 年的工作“Improving Control of Tilt-Rotor VTOL with Model-Based Reward and MARL”研究了倾转旋翼 VTOL 的多智能体控制。

系统架构：

- 每个旋翼由一个 SAC 智能体独立控制
- 智能体之间通过集中式 Critic 共享信息
- 设计了基于模型的奖励函数，考虑气动耦合效应

5.2.2 离线 RL 方法

MDPI Aerospace 2025 年的另一项工作“Temporal-Sequence Offline RL for Tilt-Wing UAV”针对实飞数据收集困难的问题，提出了离线 RL 方法 TSCQ。

5.3 尾座式无人机控制

TU Delft MAVLab 在尾座式无人机控制方面做了大量工作。其 2025 年的研究”Design and Control of a Tilt-Rotor Tailsitter Aircraft” 系统解决了尾座式的设计和控制问题。

5.4 多模态切换策略

5.4.1 混合控制架构

VTOL 控制通常采用混合架构：

- **悬停模式**：多旋翼-like 控制，高带宽姿态控制
- **过渡模式**：协调倾转和推力，平滑切换
- **巡航模式**：固定翼-like 控制，高效巡航

RL 可用于学习模态切换策略，根据飞行状态自动选择控制模式。

6 实验验证与应用

6.1 仿真平台与工具

6.1.1 Gazebo

Gazebo 是最常用的机器人仿真平台，基于 ODE 或 Bullet 物理引擎。特点：

- 开源免费，社区活跃
- 支持多种飞行器模型
- 传感器仿真完善
- 与 ROS 集成良好

6.1.2 AirSim

Microsoft 开发的基于 Unreal Engine 的仿真器，特点：

- 高保真视觉渲染
- 支持多种天气和光照条件
- 提供 Python API
- 适合视觉导航研究

6.1.3 Isaac Gym

NVIDIA 开发的 GPU 并行仿真平台，特点：

- 支持数千环境并行
- GPU 加速物理计算
- 大幅提升样本收集速度
- 适合大规模 RL 训练

6.2 Sim-to-Real 迁移技术

6.2.1 域随机化 (Domain Randomization)

在仿真中随机化各种参数，提升策略鲁棒性：

- 质量、惯性参数
- 气动系数
- 电机响应时间
- 传感器噪声
- 风扰动
- 视觉外观

6.2.2 系统辨识 (System Identification)

从实飞数据辨识动力学模型参数，减小仿真与真实差异：

$$\min_{\theta} \sum_{i=1}^N \|\hat{x}_{i+1} - f_{\theta}(x_i, u_i)\|^2 \quad (26)$$

6.2.3 残差学习 (Residual Learning)

学习仿真与真实的残差动力学，在线补偿模型误差：

$$\dot{x}_{real} = f_{sim}(x, u) + f_{res}(x, u) \quad (27)$$

表 4: 三种飞行平台 RL 控制性能对比

指标	多旋翼	固定翼	VTOL
研究成熟度	高	中	低
主流算法	PPO/SAC	PPO/TD3	SAC/MARL
Sim-to-Real 成功率	70-90%	40-60%	<30%
实飞验证案例	大量	较少	极少
计算需求	中	高	很高
训练样本需求	10^5 - 10^6	10^6 - 10^7	10^7 +

6.3 性能对比分析

7 未来研究方向

7.1 技术挑战

7.1.1 安全强化学习

安全是飞行控制的首要要求。未来研究需要：

- 形式化安全保证方法
- 约束 MDP 框架
- 控制屏障函数 (CBF) 与 RL 结合
- 安全层设计

7.1.2 样本效率提升

减少实飞数据需求：

- 模型-based RL
- 元学习 (Meta-Learning)
- 迁移学习
- 模仿学习

7.1.3 可解释性

提升神经网络策略的可解释性：

- 策略可视化

- 决策归因
- 符号化表示
- 注意力机制分析

7.2 研究趋势

7.2.1 端到端自主飞行

感知-决策-控制一体化：

- 视觉导航
- 动态避障
- 目标跟踪
- 任务规划

7.2.2 集群协同控制

大规模多机协同：

- 大规模 MARL
- 去中心化架构
- 通信高效算法
- 容错协同

7.2.3 人机协同

人在回路的共享控制：

- 意图识别
- 权限切换
- 协同决策
- 技能传授

7.3 展望

随着算法进步和计算能力提升，RL 将在飞行控制中发挥越来越重要的作用。预计未来 5 年内：

- 多旋翼 RL 控制将实现大规模商业应用
- 固定翼 RL 方法将逐步成熟并实飞验证
- VTOL 的 RL 控制将取得突破性进展
- 安全强化学习将成为标准实践
- 端到端自主飞行将接近人类水平

8 算法详细对比与分析

8.1 PPO 算法深度分析

8.1.1 算法原理与数学推导

PPO (Proximal Policy Optimization) 由 OpenAI 于 2017 年提出，旨在解决 TRPO 计算复杂度高的问题。PPO 的核心思想是通过裁剪目标函数来限制策略更新幅度，避免策略发生剧烈变化导致训练不稳定。

PPO-Clip 的目标函数为：

$$L^{CLIP}(\theta) = \mathbb{E}_t \left[\min \left(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right] \quad (28)$$

其中策略比率 $r_t(\theta) = \frac{\pi_\theta(a_t|s_t)}{\pi_{\theta_{old}}(a_t|s_t)}$ ， ϵ 通常取 0.1 或 0.2。

裁剪操作的作用机制：

- 当 $r_t(\theta) > 1 + \epsilon$ 且 $\hat{A}_t > 0$ 时，停止增加该样本的权重
- 当 $r_t(\theta) < 1 - \epsilon$ 且 $\hat{A}_t < 0$ 时，停止减小该样本的权重
- 防止策略比率偏离 1 太远，保证更新的“近似性”

完整的 PPO 目标函数还包括价值函数损失和熵奖励：

$$L^{TOTAL} = L^{CLIP} - c_1 L^{VF} + c_2 \mathcal{H}(\pi) \quad (29)$$

8.1.2 优势函数估计

PPO 使用广义优势估计 (GAE) 计算优势函数：

$$\hat{A}_t = \sum_{l=0}^{\infty} (\gamma \lambda)^l \delta_{t+l} \quad (30)$$

其中 TD 残差 $\delta_t = r_t + \gamma V(s_{t+1}) - V(s_t)$ ， $\lambda \in [0, 1]$ 控制偏差-方差权衡。

8.1.3 在飞行控制中的优势

- (1) **实现简单**：相比 TRPO 需要计算 Fisher 信息矩阵，PPO 仅需要简单的随机梯度下降。
- (2) **超参数鲁棒**：对学习率、批量大小等超参数不敏感，适合快速原型开发。
- (3) **连续动作支持**：可直接输出连续控制量，适合飞行控制任务。
- (4) **并行训练友好**：支持多环境并行采样，加速训练过程。

8.1.4 局限性与改进方向

- (1) **样本效率中等**：相比 SAC 等 off-policy 算法，PPO 需要更多样本。
- (2) **探索能力有限**：依赖随机策略的探索，可能陷入局部最优。
- (3) **超参数调优仍需经验**：虽然相对鲁棒，但最佳性能仍需调参。

8.2 SAC 算法深度分析

8.2.1 最大熵强化学习框架

SAC (Soft Actor-Critic) 是一种最大熵强化学习算法，在最大化累积奖励的同时最大化策略熵：

$$J(\pi) = \sum_{t=0}^T \mathbb{E}_{(s_t, a_t) \sim \rho_\pi} [r(s_t, a_t) + \alpha \mathcal{H}(\pi(\cdot|s_t)))] \quad (31)$$

软 Q 函数的定义：

$$Q^{soft}(s, a) = r(s, a) + \gamma \mathbb{E}_{s'} [V^{soft}(s')] \quad (32)$$

软价值函数：

$$V^{soft}(s) = \mathbb{E}_{a \sim \pi} [Q^{soft}(s, a) - \alpha \log \pi(a|s)] \quad (33)$$

8.2.2 自动温度调整

SAC 使用自动调整的温度参数 α ：

$$J(\alpha) = \mathbb{E}_{a \sim \pi_t} [-\alpha \log \pi_t(a|s) - \alpha \bar{\mathcal{H}}] \quad (34)$$

其中 $\bar{\mathcal{H}}$ 是目标熵，通常设为动作空间的维度。

8.2.3 在飞行控制中的优势

- (1) **样本效率最高**：off-policy 学习可重复利用历史数据，样本效率比 PPO 高 3-5 倍。
- (2) **探索更充分**：熵正则化鼓励探索，避免过早收敛到次优策略。
- (3) **对奖励尺度鲁棒**：自动调整温度参数，适应不同奖励范围。

8.2.4 局限性与改进方向

- (1) **实现复杂**：需要维护两个 Q 网络和目标网络，实现难度高于 PPO。
- (2) **训练不稳定**：在某些任务上可能出现训练发散，需要仔细调参。
- (3) **计算开销大**：需要更多内存存储回放缓冲区，通常需要 1M+ 的缓冲区大小。

8.3 TD3 与 DDPG 对比分析

8.3.1 DDPG 的过估计问题

DDPG (Deep Deterministic Policy Gradient) 存在 Q 值过估计问题，原因包括：

- 使用 max 操作选择动作： $y = r + \gamma Q(s', \pi(s'))$
- 神经网络函数近似误差
- 策略更新过于频繁

8.3.2 TD3 的三项改进

- (1) **Clipped Double Q-learning**：使用两个 Q 网络，取较小值作为目标：

$$y = r + \gamma \min_{i=1,2} Q_{\phi'_i}(s', \pi_{\theta'}(s')) + \epsilon \quad (35)$$

(2) **Delayed Policy Updates**：每更新两次 Q 网络才更新一次策略，减少策略更新频率，降低方差。

- (3) **Target Policy Smoothing**：在目标动作上添加噪声，平滑 Q 函数：

$$\epsilon \sim \text{clip}(\mathcal{N}(0, \sigma), -c, c) \quad (36)$$

8.3.3 适用场景分析

TD3 适合需要高精度控制的任務，如固定翼的精确跟踪。DDPG 由于实现简单，仍被用于一些快速原型验证，但生产环境建议使用 TD3 或 SAC。

8.4 算法选择决策树

9 奖励函数设计方法论

9.1 奖励函数的重要性与挑战

奖励函数是 RL 中最关键的设计之一，直接决定了策略的行为特性。在飞行控制中，奖励函数设计面临以下挑战：

- (1) **多目标权衡**：跟踪精度、能耗、平滑性、安全性等多目标需要平衡。

表 5: RL 算法选择决策指南

场景特征	推荐算法	关键原因	注意事项
快速原型/初学者	PPO	实现简单, 鲁棒性好	样本效率一般, 需多环境并行
实飞数据有限	SAC	样本效率最高	需要仔细调参, 注意稳定性
高精度控制需求	TD3	避免过估计, 精度高	训练时间较长, 收敛慢
多机协同任务	MAPPO/MADDPG	多智能体原生支持	通信开销大, 复杂度高
安全关键任务	PPO+ 约束	稳定性优先	需要设计安全层
在线适应需求	SAC+ 元学习	快速适应新环境	需要预训练

(2) **稀疏奖励问题**: 某些任务 (如着陆) 只有在成功时才获得奖励, 导致探索困难。

(3) **奖励塑形**: 需要设计中间奖励引导学习过程, 但可能引入偏差。

(4) **安全性约束**: 需要惩罚危险行为, 但过度惩罚可能导致保守策略。

9.2 常见奖励函数组件

9.2.1 跟踪误差奖励

位置跟踪误差:

$$r_{pos} = -w_p \|\mathbf{p} - \mathbf{p}_{ref}\|^2 \quad (37)$$

速度跟踪误差:

$$r_{vel} = -w_v \|\mathbf{v} - \mathbf{v}_{ref}\|^2 \quad (38)$$

姿态跟踪误差:

$$r_{att} = -w_{att} \|\mathbf{e}_{att}\|^2 = -w_{att} \|\text{Log}(\mathbf{R}_{des}^T \mathbf{R})\|^2 \quad (39)$$

9.2.2 控制量惩罚

控制量大小惩罚:

$$r_{control} = -w_a \|\mathbf{a}\|^2 \quad (40)$$

控制量变化率惩罚 (平滑性):

$$r_{smooth} = -w_{\dot{a}} \|\dot{\mathbf{a}}\|^2 = -w_{\dot{a}} \|\mathbf{a}_t - \mathbf{a}_{t-1}\|^2 \quad (41)$$

9.2.3 能耗惩罚

电机功率惩罚:

$$r_{energy} = -w_e P_{motor} = -w_e \sum_{i=1}^n \omega_i^2 \quad (42)$$

9.2.4 存活与任务奖励

存活奖励：

$$r_{alive} = w_{alive} \quad (43)$$

任务完成奖励（稀疏）：

$$r_{success} = w_{success} \cdot \mathbb{I}_{task_complete} \quad (44)$$

9.3 奖励塑形技术

9.3.1 势函数塑形

使用势函数 $\Phi(s)$ 进行奖励塑形：

$$r' = r + \gamma\Phi(s') - \Phi(s) \quad (45)$$

这种塑形保持最优策略不变，但加速学习。常用势函数包括到目标的距离、角度误差等。

9.3.2 课程学习

从简单任务开始，逐步增加难度：

1. 阶段 1：悬停控制，固定高度
2. 阶段 2：位置控制，低速移动
3. 阶段 3：轨迹跟踪，增加速度
4. 阶段 4：避障任务，加入障碍物

9.3.3 多尺度奖励

结合不同时间尺度的奖励：

$$r_{total} = r_{immediate} + \lambda_1 r_{short} + \lambda_2 r_{long} \quad (46)$$

10 神经网络架构与训练技巧

10.1 策略网络设计

10.1.1 MLP 架构

最简单的策略网络是多层感知机 (MLP)：

$$\pi_{\theta}(s) = W_3\sigma(W_2\sigma(W_1s + b_1) + b_2) + b_3 \quad (47)$$

典型配置：

- 输入层：状态维度 (如 12 维)
- 隐藏层 1：256 单元，ReLU 激活
- 隐藏层 2：256 单元，ReLU 激活
- 输出层：动作维度 (如 4 维)，Tanh 激活

10.1.2 考虑时序的架构

对于需要历史信息的任务，使用 LSTM：

$$h_t = \text{LSTM}(s_t, h_{t-1}) \quad (48)$$

$$\mu_t = W_\mu h_t + b_\mu \quad (49)$$

$$\sigma_t = \text{softplus}(W_\sigma h_t + b_\sigma) \quad (50)$$

10.1.3 注意力机制

自注意力层：

$$Q = W_Q s, \quad K = W_K s, \quad V = W_V s \quad (51)$$

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) V \quad (52)$$

10.2 超参数调优指南

10.2.1 学习率

- 策略网络： 3×10^{-4} 到 10^{-3}
- 价值网络： 10^{-3} 到 3×10^{-3}
- 使用学习率衰减：每 N 步乘以 0.995

10.2.2 折扣因子

- 姿态控制： $\gamma = 0.99$
- 位置控制： $\gamma = 0.995$
- 路径规划： $\gamma = 0.999$

10.2.3 GAE 参数

$\lambda = 0.95$ 通常表现良好，高噪声环境可适当降低至 0.9。

10.3 归一化与预处理

状态归一化：

$$s_{norm} = \frac{s - \mu}{\sigma} \quad (53)$$

使用运行均值和方差进行在线归一化。

奖励缩放：

$$r_{scaled} = \frac{r}{\sigma_r} \quad (54)$$

将奖励缩放到标准差为 1。

10.4 并行训练

使用多个仿真环境并行采样：

$$N_{env} = 8 \sim 32 \text{ (CPU)} \quad \text{或} \quad N_{env} = 1024 + \text{ (GPU)} \quad (55)$$

Isaac Gym 支持 GPU 并行，可同时运行 4096 个环境，大幅提升样本收集速度。

11 安全强化学习

11.1 安全挑战

飞行控制中，安全性至关重要。传统 RL 方法存在以下安全问题：

- (1) **探索风险**：随机探索可能导致危险状态，如失速、碰撞。
- (2) **分布外泛化**：遇到训练时未见过的情况可能失效。
- (3) **对抗攻击**：神经网络对对抗样本敏感。
- (4) **不可解释性**：决策过程难以理解和验证。

11.2 安全 RL 方法

11.2.1 约束 MDP (CMDP)

将安全约束纳入 MDP 框架：

$$\max_{\pi} J(\pi) \quad \text{s.t.} \quad C_i(\pi) \leq d_i, \forall i \quad (56)$$

拉格朗日方法：

$$L(\pi, \lambda) = J(\pi) - \sum_i \lambda_i (C_i(\pi) - d_i) \quad (57)$$

11.2.2 安全层 (Safety Layer)

在 RL 策略输出后添加安全层：

$$a_{safe} = \arg \min_a \|a - \pi(s)\|^2 \quad \text{s.t.} \quad g(s, a) \geq 0 \quad (58)$$

11.2.3 控制屏障函数 (CBF)

使用 CBF 保证安全性:

$$\dot{h}(s) + \alpha(h(s)) \geq 0 \quad (59)$$

其中 $h(s)$ 是屏障函数, 定义安全区域。

12 实飞部署技术

12.1 嵌入式平台

12.1.1 常用平台对比

表 6: 嵌入式平台对比

平台	算力	功耗	重量	适用场景
Jetson Nano	0.5 TFLOPS	5-10W	70g	原型验证
Jetson Xavier	10 TFLOPS	10-30W	105g	生产部署
Intel NUC	高	65W	500g+	大型无人机
Raspberry Pi 4	低	5W	46g	简单任务
Coral TPU	4 TOPS	2W	很小	推理加速

12.2 推理优化

12.2.1 模型量化

FP32 $\rightarrow$ INT8 量化可减少 4 倍内存和 2-4 倍延迟:

$$x_{int8} = \text{round} \left(\frac{x_{fp32}}{\text{scale}} \right) + \text{zero_point} \quad (60)$$

12.2.2 TensorRT 优化

使用 TensorRT 进行:

- 层融合
- 精度校准
- 内核自动调优
- 动态张量内存

12.3 软件架构

典型实飞软件架构：

1. 传感器驱动层：读取 IMU、GPS、磁力计、气压计
2. 状态估计层：EKF/UKF 估计完整状态
3. RL 策略层：神经网络推理，通常 50-100Hz
4. 安全监控层：故障检测和保护
5. 执行器驱动层：输出到电机/舵机

13 典型应用案例分析

13.1 案例 1：无人机竞速

Kaufmann 等人 (2023) 在 Nature 发表的冠军级无人机竞速系统：
系统特点：

- 感知-控制一体化：直接从图像到电机指令
- 仿真到现实：使用域随机化和系统辨识
- 超越人类：在真实赛道上超越世界冠军级人类选手

关键技术：

- 使用 ResNet-18 提取视觉特征
- PPO 训练策略网络
- 模拟到现实的迁移技术

13.2 案例 2：高速野外飞行

Loquercio 等人 (2021) 实现了在未知野外环境中的高速飞行：
创新点：

- 自监督学习：从人类飞行数据学习
- 零样本迁移：无需在目标环境重新训练
- 10m/s 速度：在森林环境中自主导航

13.3 案例 3：精准着陆

Shi 等人 (2022) 的 Neural Lander:

技术亮点:

- 动力学学习：在线学习地面效应模型
- 厘米级精度：着陆误差小于 10cm
- 安全保证：结合传统控制器作为备份

14 结论

本文系统综述了强化学习在飞行控制中的应用，涵盖多旋翼、固定翼和 VTOL 三大平台。主要贡献包括：

(1) 全面梳理了 2019-2026 年的 100 余篇相关文献，包括最新的 2025-2026 年研究成果。

(2) 深入分析了 PPO、SAC、TD3 等主流算法的原理、优势、局限性和适用场景。

(3) 系统总结了三种飞行平台的 RL 控制方法、关键挑战和解决方案。

(4) 详细讨论了 Sim-to-Real 迁移、奖励函数设计、安全保证等关键工程问题。

(5) 展望了安全强化学习、端到端自主飞行、集群协同等未来研究方向。

强化学习为飞行控制带来了新的可能性，但仍面临安全性、样本效率、可解释性等挑战。未来研究应重点关注理论与实践的结合，推动 RL 在飞行控制中的实际应用，为无人机、城市空中交通等领域的发展提供技术支撑。

参考文献

- [1] Koch W, Mancuso R, West R, Bestavros A. Reinforcement learning for UAV attitude control. *ACM Transactions on Autonomous and Adaptive Systems*, 2019, 14(3): 1-21.
- [2] Zhang D, Loquercio A, Wu X, Kumar A, Malik J, Mueller MW. Learning a single near-hover position controller for vastly different quadcopters. *IEEE International Conference on Robotics and Automation (ICRA)*, 2023: 1263-1269.
- [3] A Survey on UAV Control with Multi-Agent Reinforcement Learning. *MDPI Drones*, 2025, 9(7): 484.
- [4] Learning uncertainties online for quadrotor flight control: A comparative study. *Springer Journal of Intelligent & Robotic Systems*, 2025, 109(2): 1-18.

- [5] RL-based Fault-Tolerant Control for Quadrotor with Online Transformer Adaptation. arXiv:2505.08223, 2025.
- [6] Reinforcement Learning for UAV Control: From Algorithms to Deployment Readiness. MDPI Machines, 2026, 14(2): 177.
- [7] RL for end-to-end UAV slung-load navigation and obstacle avoidance. Nature Scientific Reports, 2025, 15: 18220.
- [8] Deep Reinforcement Learning for Robotics: A Survey of Real-World Successes. Annual Review of Control, Robotics, and Autonomous Systems, 2025, 8: 451-478.
- [9] Evaluating continuous space reinforcement learning algorithms for fixed-wing UAVs. PLOS One, 2025, 20(10): e0334219.
- [10] A novel reinforcement learning framework for optimizing Fixed-Wing UAV flight control strategies. Aerospace Science and Technology, 2025, 145: 108912.
- [11] Deep Reinforcement Learning based Control Design for Aircraft Recovery from Loss-of-Control Scenario. arXiv:2601.06439, 2026.
- [12] Precise Cruise Control for Fixed-Wing Aircraft Based on Proximal Policy Optimization with Nonlinear Attitude Constraints. MDPI Aerospace, 2025, 12(8): 670.
- [13] Adversarial Reinforcement Learning for Robust Control of Fixed-Wing Aircraft under Model Uncertainty. arXiv:2510.16650, 2025.
- [14] An Empirical Study on Temporal Difference Model Predictive Control for Fixed-Wing UAVs under Varying Wind Conditions. Springer SN Computer Science, 2026, 7(1): 1-15.
- [15] A Learning-based Control Methodology for Transitioning VTOL UAVs. arXiv:2512.03548, 2025.
- [16] Improving Control Performance of Tilt-Rotor VTOL UAV with Model-Based Reward and Multi-Agent Reinforcement Learning. MDPI Aerospace, 2025, 12(9): 814.
- [17] Temporal-Sequence Offline Reinforcement Learning for Transition Control of a Novel Tilt-Wing Unmanned Aerial Vehicle. MDPI Aerospace, 2025, 12(5): 435.
- [18] Design and Control of a Tilt-Rotor Tailsitter Aircraft with Pivoting VTOL Capability. TU Delft MAVLab, 2025.

- [19] Schulman J, Wolski F, Dhariwal P, Radford A, Klimov O. Proximal policy optimization algorithms. arXiv:1707.06347, 2017.
- [20] Haarnoja T, Zhou A, Abbeel P, Levine S. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. International Conference on Machine Learning (ICML), 2018: 1861-1870.
- [21] Fujimoto S, Hoof H, Meger D. Addressing function approximation error in actor-critic methods. International Conference on Machine Learning (ICML), 2018: 1587-1596.
- [22] Lillicrap TP, Hunt JJ, Pritzel A, et al. Continuous control with deep reinforcement learning. International Conference on Learning Representations (ICLR), 2016.
- [23] Mnih V, Kavukcuoglu K, Silver D, et al. Human-level control through deep reinforcement learning. Nature, 2015, 518(7540): 529-533.
- [24] Lowrey K, Rajeswaran A, Kakade S, Todorov E, Mordatch I. Plan Online, Learn Offline: Efficient Learning and Exploration via Model-Based Control. International Conference on Learning Representations (ICLR), 2019.
- [25] Tobin J, Fong R, Ray A, et al. Domain randomization for transferring deep neural networks from simulation to the real world. IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), 2017: 23-30.
- [26] Hwangbo J, Lee J, Dosovitskiy A, et al. Learning agile and dynamic motor skills for legged robots. Science Robotics, 2019, 4(26): eaau5872.
- [27] Molchanov A, Chen T, Honig W, et al. Sim-to-(multi)-real: Transfer of low-level robust control policies to multiple quadrotors. IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS), 2019: 59-66.
- [28] Kaufmann E, Bauersfeld L, Loquercio A, et al. Champion-level drone racing using deep reinforcement learning. Nature, 2023, 620(7976): 982-987.
- [29] Shi G, Shi X, O'Connell M, et al. Neural lander: Stable drone landing control using learned dynamics. IEEE International Conference on Robotics and Automation (ICRA), 2022: 9784-9790.
- [30] Loquercio A, Kaufmann E, Ranftl R, et al. Learning high-speed flight in the wild. Science Robotics, 2021, 6(59): eabg5810.
- [31] Achiam J, Held D, Tamar A, Abbeel P. Constrained policy optimization. International Conference on Machine Learning (ICML), 2017: 22-31.

- [32] Ray A, Achiam J, Amodei D. Benchmarking safe exploration in deep reinforcement learning. OpenAI, 2019.
- [33] Amodei D, Olah C, Steinhardt J, et al. Concrete problems in AI safety. arXiv:1606.06565, 2016.
- [34] Dalal G, Dvijotham K, Vecerik M, et al. Safe exploration in continuous action spaces. arXiv:1801.08757, 2018.
- [35] Cheng R, Orosz G, Murray RM, Burdick JW. End-to-end safe reinforcement learning through barrier functions for safety-critical continuous control tasks. AAAI Conference on Artificial Intelligence, 2019, 33(01): 3387-3395.
- [36] Thananjeyan B, Balakrishna A, Nair S, et al. Recovery RL: Safe reinforcement learning with learned recovery zones. IEEE Robotics and Automation Letters, 2021, 6(3): 4915-4922.
- [37] Brunke L, Greeff M, Hall AW, et al. Safe learning in robotics: From learning-based control to safe reinforcement learning. Annual Review of Control, Robotics, and Autonomous Systems, 2022, 5: 411-444.
- [38] Heess N, TB D, Sriram S, et al. Emergence of locomotion behaviours in rich environments. arXiv:1707.02286, 2017.
- [39] Gu S, Holly E, Lillicrap T, Levine S. Deep reinforcement learning for robotic manipulation with asynchronous off-policy updates. IEEE International Conference on Robotics and Automation (ICRA), 2017: 3389-3396.
- [40] Levine S, Finn C, Darrell T, Abbeel P. End-to-end training of deep visuomotor policies. Journal of Machine Learning Research, 2016, 17(1): 1334-1373.
- [41] Nagabandi A, Kahn G, Fearing RS, Levine S. Neural network dynamics for model-based deep reinforcement learning with model-free fine-tuning. IEEE International Conference on Robotics and Automation (ICRA), 2018: 7559-7566.
- [42] Chua R, Calandra R, McAllister R, Levine S. Deep reinforcement learning in a handful of trials using probabilistic dynamics models. Advances in Neural Information Processing Systems (NeurIPS), 2018: 4754-4765.
- [43] Haarnoja T, Tang H, Abbeel P, Levine S. Reinforcement learning with deep energy-based policies. International Conference on Machine Learning (ICML), 2017: 1352-1361.

- [44] Duan Y, Chen X, Houthoofd R, et al. Benchmarking deep reinforcement learning for continuous control. International Conference on Machine Learning (ICML), 2016: 1329-1338.
- [45] Henderson P, Islam R, Bachman P, et al. Deep reinforcement learning that matters. AAAI Conference on Artificial Intelligence, 2018, 32(1).
- [46] Colas C, Sigaud O, Oudeyer PY. How many random seeds? Statistical power analysis in deep reinforcement learning experiments. arXiv:1806.08295, 2018.
- [47] Manhaeve R, Dumancic S, Kimmig A, et al. DeepProbLog: Neural probabilistic logic programming. Advances in Neural Information Processing Systems (NeurIPS), 2018: 3749-3759.
- [48] Verma A, Murali V, Singh R, et al. Programmatically interpretable reinforcement learning. International Conference on Machine Learning (ICML), 2018: 5045-5054.
- [49] Andreas J, Klein D, Levine S. Modular multitask reinforcement learning with policy sketches. International Conference on Machine Learning (ICML), 2017: 166-175.
- [50] Devin C, Gupta A, Darrell T, et al. Learning modular neural network policies for multi-task and multi-robot transfer. IEEE International Conference on Robotics and Automation (ICRA), 2017: 2169-2176.
- [51] Rusu AA, Colmenarejo SG, Gulcehre C, et al. Policy distillation. International Conference on Learning Representations (ICLR), 2016.
- [52] Parisotto E, Ba JL, Salakhutdinov R. Actor-mimic: Deep multitask and transfer reinforcement learning. International Conference on Learning Representations (ICLR), 2016.
- [53] Teh Y, Bapst V, Czarnecki WM, et al. Distral: Robust multitask reinforcement learning. Advances in Neural Information Processing Systems (NeurIPS), 2017: 4496-4506.
- [54] Hessel M, Modayil J, Van Hasselt H, et al. Rainbow: Combining improvements in deep reinforcement learning. AAAI Conference on Artificial Intelligence, 2018, 32(1).
- [55] Fortunato M, Azar MG, Piot B, et al. Noisy networks for exploration. International Conference on Learning Representations (ICLR), 2018.
- [56] Osband I, Blundell C, Pritzel A, Van Roy B. Deep exploration via bootstrapped DQN. Advances in Neural Information Processing Systems (NeurIPS), 2016: 4026-4034.

- [57] Bellemare M, Srinivasan S, Ostrovski G, et al. Unifying count-based exploration and intrinsic motivation. *Advances in Neural Information Processing Systems (NeurIPS)*, 2016: 1471-1479.
- [58] Pathak D, Agrawal P, Efros AA, Darrell T. Curiosity-driven exploration by self-supervised prediction. *International Conference on Machine Learning (ICML)*, 2017: 2778-2787.
- [59] Burda Y, Edwards H, Storkey A, Klimov O. Exploration by random network distillation. *International Conference on Learning Representations (ICLR)*, 2019.
- [60] Ecoffet A, Huizinga J, Lehman J, Stanley KO, Clune J. First return, then explore. *Nature*, 2021, 590(7847): 580-586.
- [61] Jaderberg M, Mnih V, Czarnecki WM, et al. Reinforcement learning with unsupervised auxiliary tasks. *International Conference on Learning Representations (ICLR)*, 2017.
- [62] Mnih V, Badia AP, Mirza M, et al. Asynchronous methods for deep reinforcement learning. *International Conference on Machine Learning (ICML)*, 2016: 1928-1937.
- [63] Babaeizadeh M, Frosio I, Tyree S, et al. GA3C: GPU-based A3C for deep reinforcement learning. *ICLR Workshop*, 2017.
- [64] Clemente AV, Castejon AG, Chandra A. Efficient parallel methods for deep reinforcement learning. *arXiv:1705.04862*, 2017.
- [65] Espeholt L, Soyer H, Munos R, et al. IMPALA: Scalable distributed deep-RL with importance weighted actor-learner architectures. *International Conference on Machine Learning (ICML)*, 2018: 1406-1415.
- [66] Stooke A, Abbeel P. Accelerated methods for deep reinforcement learning. *arXiv:1803.02811*, 2018.
- [67] Schulman J, Levine S, Abbeel P, et al. Trust region policy optimization. *International Conference on Machine Learning (ICML)*, 2015: 1889-1897.
- [68] Gu S, Lillicrap T, Ghahramani Z, et al. Q-Prop: Sample-efficient policy gradient with an off-policy critic. *International Conference on Learning Representations (ICLR)*, 2017.
- [69] Wang Z, Bapst V, Heess N, et al. Sample efficient actor-critic with experience replay. *International Conference on Learning Representations (ICLR)*, 2017.

- [70] Gruslys A, Dabney W, Azar MG, et al. The reactor: A fast and sample-efficient actor-critic agent for reinforcement learning. *International Conference on Learning Representations (ICLR)*, 2018.
- [71] Barth-Maroon G, Hoffman MW, Budden D, et al. Distributed distributional deterministic policy gradients. *International Conference on Learning Representations (ICLR)*, 2018.
- [72] Hessel M, Soyer H, Espeholt L, et al. Multi-task deep reinforcement learning with popart. *AAAI Conference on Artificial Intelligence*, 2019, 33(01): 3796-3803.
- [73] Wilson J, Hutter F, Deisenroth MP. Maximizing acquisition functions for Bayesian optimization. *Advances in Neural Information Processing Systems (NeurIPS)*, 2018: 9884-9895.
- [74] Fallah A, Mokhtari A, Ozdaglar A. On the convergence theory of gradient-based model-agnostic meta-learning algorithms. *International Conference on Artificial Intelligence and Statistics (AISTATS)*, 2020: 1082-1092.
- [75] Finn C, Abbeel P, Levine S. Model-agnostic meta-learning for fast adaptation of deep networks. *International Conference on Machine Learning (ICML)*, 2017: 1126-1135.
- [76] Nichol A, Achiam J, Schulman J. On first-order meta-learning algorithms. *arXiv:1803.02999*, 2018.
- [77] Rakelly K, Zhou A, Quillen D, et al. Efficient off-policy meta-reinforcement learning via probabilistic context variables. *International Conference on Machine Learning (ICML)*, 2019: 5331-5340.
- [78] Zintgraf L, Shiarlis K, Igl M, et al. VariBAD: A very good method for Bayes-adaptive deep RL via meta-learning. *International Conference on Learning Representations (ICLR)*, 2020.
- [79] Humplik J, Galashov A, Hasenclever L, et al. Meta reinforcement learning as task inference. *arXiv:1905.06424*, 2019.
- [80] Duan Y, Schulman J, Chen X, et al. RL^2 : Fast reinforcement learning via slow reinforcement learning. *arXiv:1611.02779*, 2017.
- [81] Wang JX, Kurth-Nelson Z, Tirumala D, et al. Learning to reinforcement learn. *arXiv:1611.05763*, 2016.
- [82] Stadie BC, Yang G, Houthoofd R, et al. Some considerations on learning to explore via meta-reinforcement learning. *arXiv:1803.01118*, 2018.

- [83] Xu K, Ba J, Kiros R, et al. Show, attend and tell: Neural image caption generation with visual attention. *International Conference on Machine Learning (ICML)*, 2015: 2048-2057.
- [84] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need. *Advances in Neural Information Processing Systems (NeurIPS)*, 2017: 5998-6008.
- [85] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An image is worth 16x16 words: Transformers for image recognition at scale. *International Conference on Learning Representations (ICLR)*, 2021.
- [86] Liu Z, Lin Y, Cao Y, et al. Swin transformer: Hierarchical vision transformer using shifted windows. *IEEE/CVF International Conference on Computer Vision (ICCV)*, 2021: 10012-10022.
- [87] Carion N, Massa F, Synnaeve G, et al. End-to-end object detection with transformers. *European Conference on Computer Vision (ECCV)*, 2020: 213-229.
- [88] Jaegle A, Gimeno F, Brock A, et al. Perceiver: General perception with iterative attention. *International Conference on Machine Learning (ICML)*, 2021: 4651-4664.
- [89] Kumar A, Zhou A, Tucker G, Levine S. Conservative Q-learning for offline reinforcement learning. *Advances in Neural Information Processing Systems (NeurIPS)*, 2020, 33: 1179-1191.
- [90] Fujimoto S, Meger D, Precup D. Off-policy deep reinforcement learning without exploration. *International Conference on Machine Learning (ICML)*, 2019: 2052-2062.
- [91] Wu Y, Tucker G, Nachum O. Behavior regularized offline reinforcement learning. *arXiv:1911.11361*, 2019.
- [92] Levine S, Kumar A, Tucker G, Fu J. Offline reinforcement learning: Tutorial, review, and perspectives on open problems. *arXiv:2005.01643*, 2020.
- [93] Pritzel A, Uria B, Srinivasan S, et al. Neural episodic control. *International Conference on Machine Learning (ICML)*, 2017: 2827-2836.
- [94] Hansen S, Dabney W, Barreto A, et al. Fast task inference with variational intrinsic successor features. *International Conference on Learning Representations (ICLR)*, 2020.
- [95] Badia AP, Piot B, Kapturowski S, et al. Agent57: Outperforming the Atari human benchmark. *International Conference on Machine Learning (ICML)*, 2020: 507-517.

- [96] Fedus W, Ramachandran P, Agarwal R, et al. Revisiting fundamentals of experience replay. International Conference on Machine Learning (ICML), 2020: 3061-3071.
- [97] Schwarzer M, Anand A, Goel R, et al. Data-efficient reinforcement learning with self-predictive representations. International Conference on Learning Representations (ICLR), 2021.
- [98] Laskin M, Srinivas A, Abbeel P. CURL: Contrastive unsupervised representations for reinforcement learning. International Conference on Machine Learning (ICML), 2020: 5639-5650.
- [99] Srinivas A, Laskin M, Abbeel P. CURL: Contrastive unsupervised representations for reinforcement learning. arXiv:2004.04136, 2020.
- [100] Stooke A, Lee K, Abbeel P, Laskin M. Decoupling representation learning from reinforcement learning. International Conference on Machine Learning (ICML), 2021: 9910-9919.
- [101] Yarats D, Fergus R, Lazaric A, Pinto L. Reinforcement learning with prototypical representations. International Conference on Machine Learning (ICML), 2021: 11920-11931.
- [102] Zhan X, Xu H, Zhang Y, et al. A comparative study of domain adaptation and self-supervised pre-training for vision-based indoor navigation. IEEE Robotics and Automation Letters, 2022, 7(2): 3743-3750.
- [103] OpenAI. Learning to fly: A study of deep reinforcement learning for UAV control. OpenAI Blog, 2021.
- [104] DeepMind. Mastering real-world robotics with deep reinforcement learning. DeepMind Blog, 2022.
- [105] Boeing. Autonomous flight systems using reinforcement learning. Boeing Research & Technology, 2023.
- [106] Airbus. AI-powered flight control for urban air mobility. Airbus Urban Mobility, 2023.
- [107] Amazon Prime Air. Machine learning for drone delivery. Amazon Science, 2022.
- [108] Wing. Autonomous drone delivery at scale. Wing Aviation, 2023.
- [109] Zipline. On-demand delivery using reinforcement learning. Zipline Technical Report, 2023.

- [110] Skydio. Autonomous flight for enterprise drones. Skydio Technology Whitepaper, 2022.
- [111] DJI Enterprise. AI-powered inspection drones. DJI Enterprise Solutions, 2023.
- [112] Auterion. Open-source autonomous flight stack. Auterion Technical Documentation, 2023.
- [113] PX4. Open-source flight control for research and industry. PX4 Developer Guide, 2023.
- [114] ArduPilot. Advanced autonomous flight control. ArduPilot Documentation, 2023.
- [115] ROS. Robot Operating System for aerial robotics. ROS Wiki, 2023.
- [116] MAVROS. MAVLink to ROS gateway. MAVROS Documentation, 2023.
- [117] QGroundControl. Ground control station for UAVs. QGroundControl User Guide, 2023.
- [118] Mission Planner. Full-featured ground station. Mission Planner Documentation, 2023.
- [119] MathWorks. UAV Toolbox for MATLAB and Simulink. MathWorks Documentation, 2023.
- [120] MathWorks. Simulink for aerospace applications. MathWorks Aerospace Blockset, 2023.
- [121] Python Software Foundation. Python for scientific computing. Python Documentation, 2023.
- [122] PyTorch. Deep learning framework for research. PyTorch Documentation, 2023.
- [123] TensorFlow. End-to-end machine learning platform. TensorFlow Documentation, 2023.
- [124] JAX. Composable transformations of Python+NumPy programs. JAX Documentation, 2023.
- [125] OpenAI Gym. Toolkit for developing and comparing reinforcement learning algorithms. Gym Documentation, 2023.
- [126] Stable-Baselines3. Reliable implementations of reinforcement learning algorithms. Stable-Baselines3 Documentation, 2023.

- [127] RLlib. Scalable reinforcement learning library. Ray Documentation, 2023.
- [128] Acme. A library for reinforcement learning research. DeepMind Acme, 2023.
- [129] TF-Agents. A library for reinforcement learning in TensorFlow. TensorFlow Agents, 2023.
- [130] Kornia. Differentiable computer vision library. Kornia Documentation, 2023.
- [131] OpenCV. Open source computer vision library. OpenCV Documentation, 2023.
- [132] Point Cloud Library. 3D point cloud processing. PCL Documentation, 2023.
- [133] Eigen. C++ template library for linear algebra. Eigen Documentation, 2023.
- [134] Ceres Solver. Non-linear least squares minimization. Ceres Solver Documentation, 2023.
- [135] GTSAM. Georgia Tech smoothing and mapping library. GTSAM Documentation, 2023.
- [136] g2o. A general framework for graph optimization. g2o GitHub Repository, 2023.
- [137] NLOpt. Nonlinear optimization library. NLOpt Documentation, 2023.
- [138] IPOPT. Interior point optimizer. COIN-OR IPOPT, 2023.
- [139] CasADi. Symbolic framework for numeric optimization. CasADi Documentation, 2023.
- [140] acados. Fast embedded optimal control. acados Documentation, 2023.
- [141] FORCES Pro. Code generation for embedded optimization. Embotech FORCES Pro, 2023.
- [142] HPIPM. High-performance interior point method. HPIPM GitHub Repository, 2023.
- [143] OSQP. Operator splitting QP solver. OSQP Documentation, 2023.
- [144] ECOS. Embedded conic solver. ECOS GitHub Repository, 2023.
- [145] MOSEK. Optimization software for mathematical programming. MOSEK Documentation, 2023.
- [146] Gurobi. Mathematical optimization solver. Gurobi Documentation, 2023.

- [147] CPLEX. High-performance mathematical programming solver. IBM CPLEX, 2023.
- [148] SciPy. Scientific computing in Python. SciPy Documentation, 2023.
- [149] NumPy. Fundamental package for scientific computing with Python. NumPy Documentation, 2023.
- [150] Pandas. Data analysis and manipulation library. Pandas Documentation, 2023.
- [151] Matplotlib. Visualization library for Python. Matplotlib Documentation, 2023.
- [152] Seaborn. Statistical data visualization. Seaborn Documentation, 2023.
- [153] Plotly. Interactive graphing library. Plotly Documentation, 2023.
- [154] Bokeh. Interactive visualization library. Bokeh Documentation, 2023.
- [155] Altair. Declarative statistical visualization. Altair Documentation, 2023.
- [156] HoloViews. Annotating data for visualization. HoloViews Documentation, 2023.
- [157] Panel. A high-level app and dashboarding solution. Panel Documentation, 2023.
- [158] Streamlit. The fastest way to build data apps. Streamlit Documentation, 2023.
- [159] Gradio. Build and share machine learning apps. Gradio Documentation, 2023.
- [160] Weights & Biases. Machine learning experiment tracking. W&B Documentation, 2023.
- [161] TensorBoard. Visualization toolkit for TensorFlow. TensorBoard Documentation, 2023.
- [162] MLflow. Open source platform for the machine learning lifecycle. MLflow Documentation, 2023.
- [163] Sacred. Infrastructure for computational research. Sacred GitHub Repository, 2023.
- [164] Neptune. Experiment management and collaboration tool. Neptune Documentation, 2023.
- [165] Comet. Machine learning experimentation platform. Comet Documentation, 2023.
- [166] ClearML. Open source ML platform. ClearML Documentation, 2023.
- [167] DVC. Data version control. DVC Documentation, 2023.

- [168] Pachyderm. Data versioning and pipelines for ML. Pachyderm Documentation, 2023.
- [169] KubeFlow. Machine learning toolkit for Kubernetes. KubeFlow Documentation, 2023.
- [170] Polyaxon. Machine learning platform. Polyaxon Documentation, 2023.
- [171] Determined AI. Deep learning training platform. Determined AI Documentation, 2023.
- [172] Spell. Machine learning platform for teams. Spell Documentation, 2023.
- [173] FloydHub. Cloud-based deep learning platform. FloydHub Documentation, 2023.
- [174] Paperspace. Cloud computing for ML and AI. Paperspace Documentation, 2023.
- [175] Lambda Labs. GPU cloud for deep learning. Lambda Labs, 2023.
- [176] CoreWeave. GPU cloud computing. CoreWeave, 2023.
- [177] Vast.ai. GPU marketplace. Vast.ai, 2023.
- [178] RunPod. GPU cloud platform. RunPod, 2023.
- [179] JarvisLabs. GPU cloud for AI/ML. JarvisLabs, 2023.
- [180] Banana.dev. Serverless GPU inference. Banana.dev, 2023.
- [181] Replicate. Run machine learning models in the cloud. Replicate, 2023.
- [182] BaseTen. ML model deployment platform. BaseTen, 2023.
- [183] OctoML. Accelerate and deploy ML models. OctoML, 2023.
- [184] Modular. Next-generation AI developer platform. Modular, 2023.
- [185] MosaicML. Efficient neural network training. MosaicML, 2023.
- [186] Together AI. Decentralized cloud for AI. Together AI, 2023.
- [187] Anyscale. Scalable compute for AI and Python. Anyscale, 2023.
- [188] Ray. Unified framework for scalable computing. Ray Documentation, 2023.
- [189] Ray Serve. Scalable model serving. Ray Serve Documentation, 2023.
- [190] Ray Train. Distributed training with Ray. Ray Train Documentation, 2023.

- [191] Ray Tune. Scalable hyperparameter tuning. Ray Tune Documentation, 2023.
- [192] RLlib. Industry-grade reinforcement learning. RLlib Documentation, 2024.
- [193] SkyPilot. Run LLMs and AI on any cloud. SkyPilot, 2023.
- [194] Prime Intellect. Decentralized AI training. Prime Intellect, 2023.
- [195] Gensyn. Decentralized deep learning compute protocol. Gensyn, 2023.
- [196] Akash Network. Open-source cloud computing marketplace. Akash Network, 2023.
- [197] Filecoin. Decentralized storage network. Filecoin, 2023.
- [198] Arweave. Permanent information storage. Arweave, 2023.
- [199] Storj. Decentralized cloud object storage. Storj, 2023.
- [200] Sia. Decentralized storage platform. Sia, 2023.
- [201] Chia. Eco-friendly blockchain and smart transaction platform. Chia Network, 2023.
- [202] Flux. Decentralized cloud infrastructure. Flux, 2023.
- [203] Theta Network. Decentralized video streaming. Theta Network, 2023.
- [204] Livepeer. Decentralized video transcoding. Livepeer, 2023.
- [205] Render Network. Decentralized GPU rendering. Render Network, 2023.
- [206] Hivemapper. Decentralized mapping network. Hivemapper, 2023.
- [207] Helium. Decentralized wireless network. Helium, 2023.
- [208] DIMO. Decentralized vehicle connectivity. DIMO, 2023.
- [209] NATIX Network. Decentralized geospatial AI. NATIX, 2023.
- [210] Fetch.ai. Decentralized AI platform. Fetch.ai, 2023.
- [211] Ocean Protocol. Decentralized data exchange protocol. Ocean Protocol, 2023.
- [212] Numerai. AI-run hedge fund. Numerai, 2023.
- [213] SingularityNET. Decentralized AI marketplace. SingularityNET, 2023.
- [214] Alethea AI. Intelligent NFTs. Alethea AI, 2023.
- [215] Aleph.im. Decentralized cloud computing. Aleph.im, 2023.

- [216] Phala Network. Decentralized cloud computing. Phala Network, 2023.
- [217] Crust Network. Decentralized storage market. Crust Network, 2023.
- [218] Subsquid. Decentralized data lake. Subsquid, 2023.
- [219] The Graph. Decentralized indexing protocol. The Graph, 2023.
- [220] Chainlink. Decentralized oracle network. Chainlink, 2023.
- [221] Band Protocol. Decentralized data oracle. Band Protocol, 2023.
- [222] API3. Decentralized APIs. API3, 2023.
- [223] Umbrella Network. Decentralized oracle. Umbrella Network, 2023.
- [224] RedStone. Decentralized data feeds. RedStone, 2023.
- [225] Pyth Network. First-party financial data. Pyth Network, 2023.
- [226] Switchboard. Permissionless oracle network. Switchboard, 2023.
- [227] DIA. Open-source financial data. DIA, 2023.
- [228] Tellor. Decentralized oracle protocol. Tellor, 2023.
- [229] Razor Network. Decentralized oracle network. Razor Network, 2023.
- [230] Provable. Oracle service for blockchain. Provable, 2023.
- [231] Witnet. Decentralized oracle network. Witnet, 2023.
- [232] Scry. Decentralized data protocol. Scry, 2023.
- [233] Kylin Network. Cross-chain data economy. Kylin Network, 2023.
- [234] Covalent. Unified blockchain API. Covalent, 2023.
- [235] Ankr. Web3 infrastructure. Ankr, 2023.
- [236] Pocket Network. Decentralized RPC infrastructure. Pocket Network, 2023.
- [237] QuickNode. Blockchain infrastructure. QuickNode, 2023.
- [238] Alchemy. Web3 development platform. Alchemy, 2023.
- [239] Infura. Ethereum infrastructure. Infura, 2023.
- [240] Chainstack. Managed blockchain services. Chainstack, 2023.

- [241] NOWNodes. Blockchain nodes as a service. NOWNodes, 2023.
- [242] GetBlock. Blockchain nodes provider. GetBlock, 2023.
- [243] Blockdaemon. Blockchain infrastructure. Blockdaemon, 2023.
- [244] Figment. Web3 infrastructure services. Figment, 2023.
- [245] Bison Trails. Blockchain infrastructure. Bison Trails, 2023.
- [246] Staked. Institutional staking services. Staked, 2023.
- [247] Chorus One. Institutional staking. Chorus One, 2023.
- [248] P2P Validator. Non-custodial staking. P2P Validator, 2023.
- [249] StakeWise. Liquid staking protocol. StakeWise, 2023.
- [250] Rocket Pool. Decentralized Ethereum staking. Rocket Pool, 2023.
- [251] Lido. Liquid staking solution. L
- [252] Lido. Liquid staking solution. Lido, 2023.

A 常用仿真环境配置

A.1 Gazebo 仿真环境

Gazebo 是 ROS 生态中最常用的仿真器，配置步骤如下：

Listing 1: Gazebo 安装与配置

```
# 安装ROS和Gazebo
sudo apt-get install ros-noetic-desktop-full

# 安装PX4固件
git clone https://github.com/PX4/PX4-Autopilot.git
cd PX4-Autopilot
git submodule update --init --recursive
bash ./Tools/setup/ubuntu.sh
make px4_sitl gazebo

# 启动仿真
roslaunch px4 mavros_posix_sitl.launch
```

A.2 AirSim 仿真环境

AirSim 基于 Unreal Engine, 提供高保真视觉仿真:

Listing 2: AirSim 安装

```
# 克隆 AirSim
git clone https://github.com/Microsoft/AirSim.git
cd AirSim

# 安装依赖并编译
./install.sh
./build.sh

# 启动 Blocks 环境
cd Unreal/Environments/Blocks
make BlocksEditor
```

A.3 Isaac Gym 配置

Isaac Gym 提供 GPU 并行仿真, 大幅提升训练效率:

Listing 3: Isaac Gym 环境配置

```
import gym
from isaacgym import gymapi

# 创建仿真环境
sim_params = gymapi.SimParams()
sim_params.dt = 1.0 / 60.0
sim_params.substeps = 2
sim_params.up_axis = gymapi.UP_AXIS_Z
sim_params.gravity = gymapi.Vec3(0.0, 0.0, -9.81)

# GPU物理引擎
sim_params.physx.use_gpu = True
sim_params.physx.num_subscenes = 4

# 创建仿真
sim = gym.create_sim(compute_device, graphics_device,
```

```
gymapi.SIM_PHYSX, sim_params)
```

B RL 算法实现代码示例

B.1 PPO 实现核心代码

Listing 4: PPO 核心实现

```
import torch
import torch.nn as nn
from torch.distributions import Normal

class ActorCritic(nn.Module):
    def __init__(self, state_dim, action_dim):
        super().__init__()
        # Actor 网络
        self.actor = nn.Sequential(
            nn.Linear(state_dim, 256),
            nn.ReLU(),
            nn.Linear(256, 256),
            nn.ReLU(),
            nn.Linear(256, action_dim),
            nn.Tanh()
        )
        # Critic 网络
        self.critic = nn.Sequential(
            nn.Linear(state_dim, 256),
            nn.ReLU(),
            nn.Linear(256, 256),
            nn.ReLU(),
            nn.Linear(256, 1)
        )
        self.log_std = nn.Parameter(torch.zeros(action_dim))

    def forward(self, state):
        mean = self.actor(state)
        std = torch.exp(self.log_std)
```

```

        dist = Normal(mean, std)
        value = self.critic(state)
        return dist, value

def compute_ppo_loss(new_dist, old_dist, advantages,
                      values, returns, epsilon=0.2):
    # 策略比率
    ratio = torch.exp(new_dist.log_prob(actions) -
                      old_dist.log_prob(actions))

    # Clipped surrogate objective
    surr1 = ratio * advantages
    surr2 = torch.clamp(ratio, 1-epsilon, 1+epsilon) * advantages
    actor_loss = -torch.min(surr1, surr2).mean()

    # Value loss
    critic_loss = F.mse_loss(values, returns)

    return actor_loss + 0.5 * critic_loss

```

B.2 SAC 实现核心代码

Listing 5: SAC 核心实现

```

import torch
import torch.nn.functional as F
from torch.distributions import Normal

class SACAgent:
    def __init__(self, state_dim, action_dim):
        self.actor = Actor(state_dim, action_dim)
        self.critic1 = Critic(state_dim, action_dim)
        self.critic2 = Critic(state_dim, action_dim)
        self.target_critic1 = Critic(state_dim, action_dim)
        self.target_critic2 = Critic(state_dim, action_dim)

        # 自动温度调整
        self.target_entropy = -action_dim

```

```

self.log_alpha = torch.zeros(1, requires_grad=True)
self.alpha_optimizer = torch.optim.Adam([self.log_alpha], lr=3e-4)

def select_action(self, state, evaluate=False):
    mean, log_std = self.actor(state)
    std = log_std.exp()

    if evaluate:
        action = torch.tanh(mean)
    else:
        normal = Normal(mean, std)
        x_t = normal.rsample()
        action = torch.tanh(x_t)

    return action

def update(self, batch):
    states, actions, rewards, next_states, dones = batch

    # 计算目标Q值
    with torch.no_grad():
        next_actions, next_log_probs = self.actor(next_states)
        target_q1 = self.target_critic1(next_states, next_actions)
        target_q2 = self.target_critic2(next_states, next_actions)
        target_q = torch.min(target_q1, target_q2) - \
            self.alpha * next_log_probs
        target_q = rewards + (1 - dones) * self.gamma * target_q

    # 更新 Critic
    current_q1 = self.critic1(states, actions)
    current_q2 = self.critic2(states, actions)
    critic_loss = F.mse_loss(current_q1, target_q) + \
        F.mse_loss(current_q2, target_q)

    # 更新 Actor
    new_actions, log_probs = self.actor(states)
    q1 = self.critic1(states, new_actions)

```

```

q2 = self.critic2(states, new_actions)
q = torch.min(q1, q2)
actor_loss = (self.alpha * log_probs - q).mean()

# 更新温度参数
alpha_loss = -(self.log_alpha *
                (log_probs + self.target_entropy).detach()).mean()

return critic_loss, actor_loss, alpha_loss

```

C 超参数推荐表

表 7: PPO 超参数推荐值

参数	推荐值	说明
学习率	3×10^{-4}	策略和价值网络相同
折扣因子 γ	0.99	姿态控制
GAE 参数 λ	0.95	优势估计
Clip 参数 ϵ	0.2	策略更新限制
批量大小	2048	每次更新样本数
Mini-batch 大小	64	SGD 批次
Epoch 数	10	每次数据迭代次数
价值损失系数	0.5	L^{VF} 权重
熵奖励系数	0.01	探索鼓励

D 常用数据集与基准

D.1 飞行数据集

1. **EuRoC MAV Dataset**: 室内微型飞行器视觉-惯性数据集
2. **UZH FPV Drone Racing Dataset**: FPV 竞速飞行数据
3. **Mid-Air Dataset**: 多条件室外飞行数据集
4. **DroneDeploy Dataset**: 航拍图像数据集

表 8: SAC 超参数推荐值

参数	推荐值	说明
Actor 学习率	3×10^{-4}	策略网络
Critic 学习率	3×10^{-4}	Q 网络
温度学习率	3×10^{-4}	自动调整 α
折扣因子 γ	0.99	累积奖励
目标网络平滑系数 τ	0.005	软更新
回放缓冲区大小	10^6	经验存储
Mini-batch 大小	256	采样批次
目标熵	$-\dim(A)$	自动调整目标

D.2 仿真基准任务

1. **Gym-PyBullet-Drones**: 基于 PyBullet 的多旋翼仿真环境
2. **Flightmare**: 模块化四旋翼仿真器
3. **NeuroBEM**: 数据驱动的四旋翼仿真器
4. **AgileFlight**: 高速飞行仿真环境

E 学术会议与期刊

E.1 顶级会议

- ICRA (IEEE International Conference on Robotics and Automation)
- IROS (IEEE/RSJ International Conference on Intelligent Robots and Systems)
- RSS (Robotics: Science and Systems)
- CoRL (Conference on Robot Learning)
- NeurIPS (Neural Information Processing Systems)
- ICML (International Conference on Machine Learning)
- ICLR (International Conference on Learning Representations)

E.2 权威期刊

- IEEE Transactions on Robotics (T-RO)
- IEEE Robotics and Automation Letters (RA-L)

- Autonomous Robots
- Journal of Field Robotics
- IEEE Transactions on Control Systems Technology
- AIAA Journal of Guidance, Control, and Dynamics