

强化学习在飞行控制中的应用：综述

目录

1	引言	4
1.1	研究背景与意义	4
1.2	问题定义与挑战	5
1.3	研究现状概述	5
1.4	本文组织结构	6
2	强化学习与飞行控制基础	6
2.1	强化学习基础	6
2.1.1	马尔可夫决策过程	7
2.1.2	值函数方法	7
2.1.3	策略梯度方法	7
2.1.4	近端策略优化 (PPO)	8
2.1.5	软 Actor-Critic(SAC)	8
2.2	飞行器动力学建模	8
2.2.1	多旋翼动力学	8
2.2.2	固定翼动力学	9
2.2.3	VTOL 动力学	10
2.3	仿真环境与基准测试	10
3	多旋翼无人机强化学习控制	11
3.1	姿态控制	11
3.1.1	基于深度 Q 网络的姿态控制	11
3.1.2	基于策略梯度的姿态控制	11
3.1.3	基于 Transformer 的姿态控制	11
3.2	位置与轨迹跟踪	12
3.2.1	端到端位置控制	12
3.2.2	轨迹跟踪的强化学习方法	12
3.2.3	多智能体协同轨迹规划	13

3.3	避障与路径规划	13
3.3.1	基于视觉的避障	13
3.3.2	基于激光雷达的避障	13
3.4	故障容错控制	14
3.4.1	电机失效的容错控制	14
4	固定翼飞行器强化学习控制	14
4.1	巡航与机动控制	14
4.1.1	连续空间 RL 评估	14
4.1.2	注意力机制增强的 RL 框架	15
4.2	失速恢复与边界保护	15
4.2.1	深度强化学习失速恢复	15
4.2.2	飞行包线边界保护	16
4.3	路径跟踪与制导	16
4.3.1	基于 RL 的制导律学习	16
4.3.2	风扰动下的路径跟踪	16
4.4	对抗不确定性的鲁棒控制	17
4.4.1	对抗强化学习	17
4.4.2	域随机化与鲁棒性	17
5	垂直起降飞行器强化学习控制	17
5.1	过渡飞行控制	17
5.1.1	基于学习的过渡控制	17
5.1.2	离线强化学习在过渡控制中的应用	18
5.2	倾转旋翼控制	18
5.2.1	模型基奖励设计的 MARL	18
5.3	尾座式无人机控制	19
5.3.1	姿态过渡控制	19
5.4	多模态切换策略	19
5.4.1	基于强化学习的模态切换	19
6	实验验证与应用	20
6.1	仿真平台与工具	20
6.1.1	高保真仿真环境	20
6.1.2	RL 训练框架	20
6.2	Sim-to-Real 迁移	20
6.2.1	域随机化	20
6.2.2	系统辨识	21

目录	3
6.2.3 自适应策略	21
6.3 实飞验证案例	21
6.3.1 多旋翼实飞验证	21
6.3.2 固定翼实飞验证	21
6.4 性能对比分析	21
7 未来研究方向	22
7.1 技术挑战	22
7.2 研究趋势	22
7.3 展望	22

1 引言

1.1 研究背景与意义

无人机技术的快速发展正在深刻改变现代航空领域的格局。从消费级航拍设备到工业级物流运输，从农业植保到应急救援，无人机系统已渗透到人类生产和生活的各个角落。据统计，全球无人机市场规模预计将在 2030 年突破 500 亿美元，年复合增长率超过 15%。在这一背景下，飞行控制作为无人机系统的核心技术，其智能化水平直接决定了无人机的性能边界和应用范围。

传统的飞行控制方法主要依赖于经典控制理论，如 PID 控制、线性二次调节器 (LQR) 和模型预测控制 (MPC) 等。这些方法在结构化环境中表现良好，但面临以下根本性挑战：

- 模型依赖性：**传统控制器需要精确的飞行器动力学模型，而实际系统中存在大量难以建模的不确定性因素，如气动参数变化、执行器老化、外部扰动等。
- 适应性不足：**固定参数的控制器难以适应飞行包线内的全状态变化，特别是在极端飞行条件下（如大迎角、高动态机动）性能急剧下降。
- 扩展性受限：**针对特定任务设计的控制器难以迁移到新的场景，需要大量的人工调参和重新设计。

强化学习 (Reinforcement Learning, RL) 作为机器学习的重要分支，为解决上述问题提供了新的范式。与传统方法不同，强化学习通过与环境的交互学习最优控制策略，无需显式的系统模型，具有天然的自适应能力和端到端优化特性。近年来，随着深度学习的兴起，深度强化学习 (Deep Reinforcement Learning, DRL) 在处理高维状态空间和非线性控制问题方面展现出巨大潜力。

在飞行控制领域，强化学习的应用价值体现在以下几个方面：

第一，强化学习能够学习复杂的非线性控制策略，克服传统线性化方法的局限性。飞行器在大机动飞行时呈现强非线性特性，而深度神经网络可以近似任意复杂的非线性映射。

第二，强化学习支持端到端学习，可以直接从原始传感器数据映射到控制指令，减少中间环节的信息损失。这种“感知-决策-执行”的一体化架构更符合生物智能的运作模式。

第三，强化学习具备在线适应能力，可以通过持续交互更新策略，应对环境变化和系统退化。这一特性对于长航时任务和复杂环境下的自主飞行至关重要。

第四，强化学习为多智能体协同控制提供了统一框架，支持分布式决策和群体智能涌现，契合未来无人机集群作战和协同作业的需求。

1.2 问题定义与挑战

将强化学习应用于飞行控制领域，本质上是一个连续状态-动作空间中的马尔可夫决策过程 (Markov Decision Process, MDP) 求解问题。标准 MDP 由五元组 $\mathcal{M} = (\mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R}, \gamma)$ 定义，其中：

- $\mathcal{S} \subseteq \mathbb{R}^n$ ：状态空间，包括飞行器的位置、速度、姿态、角速度等状态量
- $\mathcal{A} \subseteq \mathbb{R}^m$ ：动作空间，通常为控制面偏转、油门指令或电机转速
- $\mathcal{P} : \mathcal{S} \times \mathcal{A} \times \mathcal{S} \rightarrow [0, 1]$ ：状态转移概率，描述动力学的不确定性
- $\mathcal{R} : \mathcal{S} \times \mathcal{A} \rightarrow \mathbb{R}$ ：奖励函数，量化控制性能
- $\gamma \in [0, 1)$ ：折扣因子，平衡即时与长期回报

控制目标为寻找最优策略 $\pi^* : \mathcal{S} \rightarrow \mathcal{A}$ ，最大化期望累积奖励：

$$\pi^* = \arg \max_{\pi} \mathbb{E}_{\tau \sim \pi} \left[\sum_{t=0}^T \gamma^t r(s_t, a_t) \right] \quad (1)$$

然而，将这一理论框架应用于实际飞行控制面临诸多挑战：

安全性挑战：飞行控制系统对安全性要求极高，任何控制失误都可能导致灾难性后果。强化学习在探索过程中不可避免地会尝试危险动作，如何在保证安全的前提下进行有效学习是首要难题。

样本效率挑战：飞行器动力学复杂，状态空间维度高，而实际飞行试验成本高昂。传统无模型强化学习算法通常需要数百万次交互才能收敛，这在实际应用中难以接受。

Sim-to-Real 鸿沟：仿真环境与真实环境之间存在动力学差异、传感器噪声差异和未建模动态。在仿真中训练的策略往往难以直接迁移到真实飞行器。

可解释性挑战：深度神经网络策略本质上是黑箱模型，其决策逻辑难以解释。这在需要通过适航认证的民用航空领域构成重大障碍。

实时性挑战：机载计算资源有限，而深度网络推理需要较高的计算开销。如何在嵌入式平台上实现毫秒级控制周期是工程实现的关键。

1.3 研究现状概述

近年来，强化学习在飞行控制领域的研究呈现出爆发式增长态势。从研究对象看，涵盖了多旋翼无人机、固定翼飞行器、垂直起降 (VTOL) 飞行器以及直升机等多种平台；从算法类型看，涵盖了值函数方法、策略梯度方法、Actor-Critic 架构以及模型-based 方法等多种范式。

多旋翼无人机作为研究最深入的平台，受益于其相对简单的动力学特性和广泛的应用场景。从早期的深度 Q 网络 (DQN) 应用到近期的近端策略优化 (PPO)、软 Actor-Critic(SAC) 等算法，控制性能不断提升。特别是 2023 年以来，基于 Transformer 的架构开始应用于多旋翼控制，展现出更强的序列建模能力。

固定翼飞行器的控制更具挑战性，涉及失速、螺旋等复杂气动现象。近期研究聚焦于失速恢复、边界保护和对抗不确定性控制等难题。对抗强化学习 (Adversarial RL) 和元学习 (Meta-Learning) 等新兴方法开始应用于固定翼控制。

VTOL 飞行器结合了多旋翼的垂直起降能力和固定翼的高效巡航能力，但其过渡飞行控制是公认的难题。强化学习为处理模态切换和过渡轨迹优化提供了新的工具。

Sim-to-Real 迁移是当前研究的热点方向。领域随机化 (Domain Randomization)、系统辨识 (System Identification) 和元强化学习 (Meta-RL) 等技术被广泛用于缩小仿真与现实的差距。

1.4 本文组织结构

本文系统综述强化学习在飞行控制领域的研究进展，全文组织结构如下：

第2章介绍强化学习与飞行控制的基础理论，包括 MDP 框架、主流算法原理、飞行器动力学建模和仿真环境。

第3章聚焦多旋翼无人机的强化学习控制，涵盖姿态控制、轨迹跟踪、避障规划和故障容错等核心问题。

第4章讨论固定翼飞行器的强化学习控制，重点分析巡航机动、失速恢复、路径跟踪和鲁棒控制等挑战。

第5章探讨垂直起降飞行器的强化学习控制，包括过渡飞行、倾转旋翼、尾座式无人机和多模态切换策略。

第6章综述实验验证与应用，介绍主流仿真平台、Sim-to-Real 迁移技术、实飞验证案例和性能对比分析。

第7章展望未来研究方向，分析技术挑战、研究趋势和发展前景。

2 强化学习与飞行控制基础

2.1 强化学习基础

强化学习是一种通过与环境交互来学习最优行为策略的机器学习方法。与监督学习不同，强化学习不需要标注数据，而是通过试错 (Trial-and-Error) 机制从延迟奖励信号中学习。

2.1.1 马尔可夫决策过程

马尔可夫决策过程是强化学习的数学基础。MDP 的核心假设是马尔可夫性质：下一状态仅依赖于当前状态和动作，与历史无关：

$$P(s_{t+1}|s_t, a_t, s_{t-1}, a_{t-1}, \dots) = P(s_{t+1}|s_t, a_t) \quad (2)$$

对于连续控制问题，通常采用确定性或随机性策略：

- 确定性策略： $a = \mu(s; \theta)$ ，直接映射状态到动作
- 随机性策略： $a \sim \pi(\cdot|s; \theta)$ ，输出动作的概率分布

状态值函数 $V^\pi(s)$ 和动作值函数 $Q^\pi(s, a)$ 定义为：

$$V^\pi(s) = \mathbb{E}_\pi \left[\sum_{t=0}^{\infty} \gamma^t r_{t+1} | s_0 = s \right] \quad (3)$$

$$Q^\pi(s, a) = \mathbb{E}_\pi \left[\sum_{t=0}^{\infty} \gamma^t r_{t+1} | s_0 = s, a_0 = a \right] \quad (4)$$

两者满足贝尔曼方程：

$$Q^\pi(s, a) = \mathbb{E}_{s' \sim P}[r(s, a) + \gamma \mathbb{E}_{a' \sim \pi} Q^\pi(s', a')] \quad (5)$$

2.1.2 值函数方法

值函数方法通过学习值函数来间接得到策略。Q 学习 (Q-Learning) 是最具代表性的算法，其更新规则为：

$$Q(s, a) \leftarrow Q(s, a) + \alpha [r + \gamma \max_{a'} Q(s', a') - Q(s, a)] \quad (6)$$

对于连续动作空间，深度 Q 网络 (DQN) 使用神经网络近似 Q 函数：

$$L(\theta) = \mathbb{E}_{(s, a, r, s') \sim \mathcal{D}} [(r + \gamma \max_{a'} Q(s', a'; \theta^-) - Q(s, a; \theta))^2] \quad (7)$$

其中 θ^- 为目标网络参数，定期从主网络复制，以提高稳定性。

然而，DQN 在处理连续动作空间时面临最大化操作难以求解的问题。为此，研究者提出了多种改进方案，如 NAF(Normalized Advantage Functions) 和 C51 等分布型方法。

2.1.3 策略梯度方法

策略梯度方法直接参数化策略并沿性能梯度方向优化。REINFORCE 算法的基本形式为：

$$\nabla_\theta J(\theta) = \mathbb{E}_{\pi_\theta} [\nabla_\theta \log \pi_\theta(a|s) \cdot G_t] \quad (8)$$

其中 $G_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k+1}$ 为累积回报。

为了减少方差，Actor-Critic 架构引入值函数作为基线：

$$\nabla_{\theta} J(\theta) = \mathbb{E}_{\pi_{\theta}} [\nabla_{\theta} \log \pi_{\theta}(a|s) \cdot (Q(s, a) - V(s))] \quad (9)$$

优势函数 $A(s, a) = Q(s, a) - V(s)$ 的引入显著降低了梯度估计的方差。

2.1.4 近端策略优化 (PPO)

PPO 是当前应用最广泛的策略优化算法，其核心思想是通过裁剪目标函数来限制策略更新的幅度：

$$L^{CLIP}(\theta) = \mathbb{E}_t \left[\min \left(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \epsilon, 1 + \epsilon) \hat{A}_t \right) \right] \quad (10)$$

其中 $r_t(\theta) = \frac{\pi_{\theta}(a_t|s_t)}{\pi_{\theta_{old}}(a_t|s_t)}$ 为重要性采样比率， ϵ 通常为 0.1 或 0.2。

PPO 的优势在于：

1. 实现简单，超参数敏感度低
2. 样本效率较高，适合中等规模问题
3. 训练稳定性好，不易出现灾难性遗忘

2.1.5 软 Actor-Critic(SAC)

SAC 是一种基于最大熵框架的 Off-Policy 算法，其目标函数为：

$$J(\pi) = \mathbb{E}_{\pi} \left[\sum_t r(s_t, a_t) + \alpha \mathcal{H}(\pi(\cdot|s_t)) \right] \quad (11)$$

其中 $\mathcal{H}$ 为策略熵， α 为温度参数，平衡奖励与探索。

SAC 使用两个 Q 网络来减轻过估计问题，并通过自动调整温度参数来保持合理的探索水平。实验表明，SAC 在连续控制任务上通常优于 PPO，但实现复杂度更高。

2.2 飞行器动力学建模

准确的动力学模型是飞行控制的基础。本节介绍三种主要飞行器平台的动力学特性。

2.2.1 多旋翼动力学

多旋翼无人机通常采用四旋翼、六旋翼或八旋翼构型。以四旋翼为例，其动力学方程可表示为：

$$m\ddot{\mathbf{p}} = -mg\mathbf{e}_3 + R\mathbf{T}_b \quad (12)$$

$$I\dot{\boldsymbol{\omega}} = -\boldsymbol{\omega} \times I\boldsymbol{\omega} + \boldsymbol{\tau} \quad (13)$$

其中 m 为质量, $\mathbf{p}$ 为位置, R 为旋转矩阵, $\mathbf{T}_b = [0, 0, T]^T$ 为机体坐标系下的总推力, I 为惯性矩阵, $\boldsymbol{\omega}$ 为角速度, $\boldsymbol{\tau}$ 为力矩。

四个电机的转速 ω_i 产生推力和力矩:

$$T = \sum_{i=1}^4 k_T \omega_i^2 \quad (14)$$

$$\tau_x = dk_T(\omega_4^2 - \omega_2^2) \quad (15)$$

$$\tau_y = dk_T(\omega_3^2 - \omega_1^2) \quad (16)$$

$$\tau_z = k_M(\omega_1^2 - \omega_2^2 + \omega_3^2 - \omega_4^2) \quad (17)$$

其中 k_T 和 k_M 分别为推力系数和力矩系数, d 为机臂长度。

多旋翼具有欠驱动特性: 虽然可以独立控制滚转、俯仰和偏航力矩, 但水平运动必须通过姿态倾斜产生水平推力分量来实现。这一特性增加了控制设计的复杂性。

2.2.2 固定翼动力学

固定翼飞行器的动力学更为复杂, 涉及气动升力、阻力和力矩。六自由度刚体运动方程为:

$$m\dot{\mathbf{V}} = \mathbf{F}_a + \mathbf{F}_g + \mathbf{F}_t \quad (18)$$

$$I\dot{\boldsymbol{\omega}} = \mathbf{M}_a + \mathbf{M}_t - \boldsymbol{\omega} \times I\boldsymbol{\omega} \quad (19)$$

气动力和力矩是飞行状态 (速度、迎角、侧滑角) 和控制输入 (舵面偏转) 的复杂函数:

$$F_a = \frac{1}{2}\rho V^2 S C_F(\alpha, \beta, \delta_e, \delta_a, \delta_r) \quad (20)$$

$$M_a = \frac{1}{2}\rho V^2 S \bar{c} C_M(\alpha, \beta, \delta_e, \delta_a, \delta_r) \quad (21)$$

其中 ρ 为空气密度, S 为机翼面积, $\bar{c}$ 为平均气动弦长, α 为迎角, β 为侧滑角, $\delta_e, \delta_a, \delta_r$ 分别为升降舵、副翼和方向舵偏角。

固定翼飞行器的特殊挑战包括:

- 失速现象: 当迎角超过临界值时, 升力急剧下降, 阻力骤增
- 螺旋模态: 小阻尼的滚转-偏航耦合运动
- 飞行包线限制: 速度、高度、载荷因子的约束

2.2.3 VTOL 动力学

VTOL 飞行器结合了多旋翼和固定翼的特点，其动力学呈现明显的模态依赖特性。以倾转旋翼为例，当旋翼倾角为 θ_t 时，推力和力矩为：

$$\mathbf{T} = R_t(\theta_t) \sum_i \mathbf{T}_i \quad (22)$$

$$\boldsymbol{\tau} = \sum_i \mathbf{r}_i \times \mathbf{T}_i + \mathbf{Q}_i \quad (23)$$

其中 R_t 为倾转旋转矩阵， $\mathbf{r}_i$ 为旋翼位置， $\mathbf{Q}_i$ 为反扭矩。

过渡飞行是 VTOL 的核心挑战。在悬停模态 ($\theta_t \approx 0^\circ$)，飞行器表现为多旋翼特性；在巡航模态 ($\theta_t \approx 90^\circ$)，则表现为固定翼特性。过渡过程中，气动特性剧烈变化，控制系统必须在不同模态间平滑切换。

2.3 仿真环境与基准测试

仿真环境是强化学习训练的基础设施。当前主流的无人机仿真平台包括：

表 1: 主流无人机仿真平台对比

平台	物理引擎	传感器	RL 接口	开源
Gazebo	ODE/Bullet/DART	丰富	ROS/Gym	是
AirSim	UE4	高保真	Gym	是
FlightGear	JSBSim	专业级	有限	是
PyBullet	Bullet	基础	原生	是
MATLAB/Simulink	自定义	中等	有限	否

Gazebo 是 ROS 生态的默认仿真器，支持多种物理引擎和传感器模型。其优势在于与 ROS 的无缝集成，便于算法验证和实机迁移。

AirSim 基于虚幻引擎 4 开发，提供高保真的视觉渲染和物理仿真。特别适用于需要视觉感知的任务，如避障和目标跟踪。

FlightGear 是一款开源飞行模拟器，内置专业的飞行动力学模型 (JSBSim)，适合固定翼和直升机的仿真研究。

基准测试任务 方面，常用的包括：

- **姿态控制**：将飞行器从初始姿态稳定到目标姿态
- **轨迹跟踪**：跟踪预定义的参考轨迹
- **定点悬停**：在存在扰动的情況下保持位置
- **着陆**：安全降落在指定区域
- **避障**：在未知环境中导航并避开障碍物

3 多旋翼无人机强化学习控制

多旋翼无人机是强化学习在飞行控制领域应用最广泛的平台。其相对简单的动力学特性、丰富的应用场景和较低的研发成本，使其成为验证新算法的理想载体。

3.1 姿态控制

姿态控制是多旋翼飞行控制的基础，负责维持或改变飞行器的滚转、俯仰和偏航角。传统 PID 控制器虽然广泛使用，但在大角度机动和存在外部扰动时性能有限。

3.1.1 基于深度 Q 网络的姿态控制

早期研究尝试将 DQN 应用于姿态控制。Koch 等人 (2019) 提出使用 DQN 学习四旋翼的姿态稳定策略，将连续状态空间离散化后训练。然而，离散化动作空间导致控制精度受限，且在高频控制场景下计算开销较大。

3.1.2 基于策略梯度的姿态控制

策略梯度方法更适合连续控制问题。Zhang 等人 (2023) 在 ICRA 发表的“Learning a single near-hover controller”工作中，提出了一种基于 PPO 的悬停姿态控制器。其核心创新在于：

1. 设计了考虑控制平滑性的复合奖励函数：

$$r = -\|\mathbf{q}_e\|^2 - \lambda_1 \|\boldsymbol{\omega}\|^2 - \lambda_2 \|\dot{\mathbf{u}}\|^2 \quad (24)$$

其中 $\mathbf{q}_e$ 为姿态误差四元数， $\boldsymbol{\omega}$ 为角速度， $\dot{\mathbf{u}}$ 为控制变化率。

2. 采用课程学习 (Curriculum Learning) 策略，逐步增加初始姿态偏差，提高控制器鲁棒性。
3. 在真实 Crazyflie 2.1 微型四旋翼上验证了 Sim-to-Real 迁移效果。

实验结果表明，学习得到的控制器在悬停稳定性上超越了手工调参的 PID，且对质量变化和外部扰动表现出更好的适应性。

3.1.3 基于 Transformer 的姿态控制

近年来，Transformer 架构开始应用于姿态控制。RL-based Fault-Tolerant Control with Transformer(arXiv 2025) 提出使用自注意力机制建模传感器序列的时间依赖性：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (25)$$

其中 Q, K, V 分别为查询、键和值矩阵，由历史状态序列投影得到。该方法能够有效融合 IMU、磁力计和 GPS 等多源传感器信息，在传感器故障时仍能保持控制性能。

批判性分析： 尽管基于 RL 的姿态控制取得了显著进展，但仍存在以下局限：

- 训练过程需要大量仿真样本，实机训练风险高
- 学习策略的泛化能力受限于训练分布，极端姿态下的表现难以保证
- 控制延迟和传感器噪声的影响在仿真中难以完全复现

3.2 位置与轨迹跟踪

位置控制负责跟踪期望的 3D 轨迹，是多旋翼执行复杂任务的基础。级联控制架构通常将位置控制和姿态控制解耦：外环位置控制器生成期望姿态，内环姿态控制器跟踪期望姿态。

3.2.1 端到端位置控制

传统方法将位置控制和姿态控制分离设计，而强化学习支持端到端学习。”RL for UAV Control: From Algorithms to Deployment”(MDPI 2026) 综述了端到端位置控制的研究进展：

表 2: 端到端位置控制方法对比

方法	算法	输入	输出
Modular RL	PPO	位置误差	期望姿态 + 推力
End-to-End RL	SAC	状态向量	电机指令
Hierarchical RL	TD3	目标位置	航点序列
Meta-RL	MAML	状态 + 任务	自适应策略

端到端方法的优势在于可以优化整体性能，避免级联控制中的次优问题。然而，端到端策略的可解释性较差，调试困难。

3.2.2 轨迹跟踪的强化学习方法

轨迹跟踪要求飞行器沿预定义路径飞行。”Learning uncertainties online for quadrotor”(Springer JIRS 2025) 提出了一种在线学习不确定性的轨迹跟踪方法：

1. 使用高斯过程 (GP) 建模动力学不确定性：

$$\mathbf{f}(\mathbf{x}, \mathbf{u}) \sim \mathcal{GP}(\mathbf{m}(\mathbf{x}, \mathbf{u}), \mathbf{k}(\mathbf{x}, \mathbf{u}, \mathbf{x}', \mathbf{u}')) \quad (26)$$

2. 基于模型不确定性自适应调整控制增益

3. 结合 MPC 的约束处理能力和 RL 的自适应能力

该方法在存在质量变化和外部风扰的情况下，轨迹跟踪误差比传统 MPC 降低了 40% 以上。

3.2.3 多智能体协同轨迹规划

”A Survey on UAV Control with Multi-Agent RL”(MDPI Drones 2025) 系统综述了多智能体强化学习 (MARL) 在多旋翼协同控制中的应用。MARL 的两种主要范式为：

- **完全分布式**：每个无人机独立决策，通过局部通信协调
- **集中训练分布式执行 (CTDE)**：训练时使用全局信息，执行时仅使用局部观测

CTDE 架构在保持分布式执行优势的同时，提高了训练效率和协作性能。QMIX 和 MAPPO 是 CTDE 架构下最常用的算法。

3.3 避障与路径规划

避障是无人机自主飞行的核心能力。强化学习为未知环境下的在线避障提供了有效工具。

3.3.1 基于视觉的避障

”Deep RL for Robotics: Real-World Successes”(Annual Reviews 2025) 总结了深度强化学习在视觉避障中的成功应用。典型架构包括：

1. 感知模块：使用 CNN 或 ViT 处理相机图像，提取环境特征
2. 决策模块：基于特征和本体状态输出控制指令
3. 安全模块：监控碰撞风险，必要时触发紧急制动

奖励函数设计是关键挑战。简单的稀疏奖励（碰撞时惩罚）导致样本效率低下，而密集奖励设计需要领域知识。好奇心驱动 (Curiosity-Driven) 和内在激励 (Intrinsic Motivation) 方法通过探索奖励来缓解这一问题。

3.3.2 基于激光雷达的避障

激光雷达提供精确的距离测量，适合结构化环境下的避障。RL 方法可以直接处理点云数据或降维后的距离扫描：

$$\mathbf{o} = [d_1, d_2, \dots, d_n, v_x, v_y, v_z, \dot{\psi}] \quad (27)$$

其中 d_i 为第 i 个方向的距离测量， v_x, v_y, v_z 为速度， $\dot{\psi}$ 为偏航角速度。

3.4 故障容错控制

多旋翼的故障容错能力对于安全关键应用至关重要。常见故障类型包括电机失效、螺旋桨损坏、传感器故障等。

3.4.1 电机失效的容错控制

四旋翼在单个电机完全失效时，剩余三个电机无法产生任意方向的力矩，系统变为不可控。然而，通过高速切换或倾斜旋翼，可以实现可控的紧急降落。

RL-based Fault-Tolerant Control with Transformer 提出了一种基于注意力机制的故障检测和重构方法：

1. 使用自编码器检测异常：重构误差超过阈值时判定故障
2. 基于注意力权重定位故障源
3. 切换到预训练的容错策略或使用在线适应

批判性分析：故障容错 RL 控制面临以下挑战：

- 故障数据稀缺，难以覆盖所有故障模式
- 故障发生后的适应时间窗口有限
- 安全关键应用要求可证明的容错能力，而神经网络难以提供形式化保证

4 固定翼飞行器强化学习控制

固定翼飞行器的控制比多旋翼更具挑战性，涉及复杂的气动现象、更宽的速度范围和更严格的飞行包线约束。

4.1 巡航与机动控制

巡航控制是固定翼飞行器的基本任务，要求在给定高度和速度下稳定飞行。机动控制则涉及大动态飞行，如盘旋、筋斗、横滚等。

4.1.1 连续空间 RL 评估

”Evaluating continuous space RL for fixed-wing UAVs”(PLOS One 2025) 系统评估了多种连续空间 RL 算法在固定翼控制中的性能。研究在 JSBSim 仿真环境中测试了 PPO、SAC、TD3 和 A3C 等算法，主要发现包括：

研究表明，PPO 在固定翼控制中表现最为均衡，而 SAC 虽然样本效率更高，但对超参数更敏感。

表 3: RL 算法在固定翼巡航控制中的性能对比

算法	收敛速度	最终性能	稳定性	样本效率
PPO	中	高	高	中
SAC	快	高	中	高
TD3	中	高	中	高
A3C	慢	中	低	低

4.1.2 注意力机制增强的 RL 框架

”Novel RL framework with attention + PPO”(ScienceDirect 2025) 提出了一种结合注意力机制和 PPO 的控制框架。其核心思想是使用注意力机制动态加权不同状态特征的重要性:

$$h_i = \text{Attention}(W_q s, W_k s_i, W_v s_i) \quad (28)$$

其中 s 为当前状态, s_i 为历史状态序列中的第 i 个状态。这种架构能够捕捉飞行状态的时间依赖性, 对于处理气动滞后效应特别有效。

实验表明, 在存在湍流的情况下, 注意力增强的 PPO 比标准 PPO 的高度保持精度提高了 25%。

4.2 失速恢复与边界保护

失速是固定翼飞行器最危险的状态之一。当迎角超过临界值时, 机翼上表面气流分离, 升力急剧下降, 可能导致失控坠毁。

4.2.1 深度强化学习失速恢复

”DRL for Aircraft Recovery from Loss-of-Control”(arXiv 2026) 研究了深度强化学习在失速恢复中的应用。研究将失速恢复建模为有限时间最优控制问题:

$$\min_{\pi} \mathbb{E} \left[\sum_{t=0}^{T_{\text{recovery}}} (\alpha_t - \alpha_{\text{safe}})^2 + \lambda h_t^2 \right] \quad (29)$$

其中 α 为迎角, α_{safe} 为安全迎角, h 为高度损失。

研究发现, 学习得到的恢复策略比传统规则-based 方法更快地将飞行器恢复到安全状态, 平均高度损失减少 30%。

批判性分析: 尽管 RL 在失速恢复中显示出潜力, 但实际应用面临重大障碍:

- 失速动力学高度非线性且与机型强相关, 难以建立通用模型
- 实机验证风险极高, 难以收集真实失速数据
- 适航认证要求可解释的安全保证, 而神经网络策略难以满足

4.2.2 飞行包线边界保护

飞行包线定义了飞行器安全运行的边界，包括速度、高度、迎角、载荷因子等约束。”PPO with Nonlinear Attitude Constraints”(MDPI Aerospace 2025) 提出了一种结合 PPO 和非线性约束处理的方法：

1. 使用障碍函数 (Barrier Function) 将硬约束转化为软惩罚：

$$r_{constraint} = - \sum_i \frac{1}{d_i} \quad (30)$$

其中 d_i 为到第 i 个约束边界的距离。

2. 在奖励函数中平衡跟踪性能和约束满足
3. 使用拉格朗日乘子法处理等式约束

4.3 路径跟踪与制导

路径跟踪要求飞行器沿预定义路径飞行，是自主导航的基础任务。

4.3.1 基于 RL 的制导律学习

传统制导律如纯追踪 (Pure Pursuit) 和视线 (Line-of-Sight) 制导在特定场景下表现良好，但难以适应复杂环境。强化学习可以学习自适应制导律：

$$\chi_{cmd} = \pi_{\theta}(\mathbf{p}, \mathbf{p}_{path}, \mathbf{V}, \psi_{wind}) \quad (31)$$

其中 χ_{cmd} 为指令航向角， $\mathbf{p}$ 为当前位置， $\mathbf{p}_{path}$ 为路径信息， $\mathbf{V}$ 为空速， ψ_{wind} 为风向。

4.3.2 风扰动下的路径跟踪

”TD-MPC for Fixed-Wing UAVs under Wind”(Springer 2026) 研究了时变风扰动下的路径跟踪问题。TD-MPC(Temporal Difference Model Predictive Control) 结合了模型预测控制和强化学习的优势：

1. 使用学习得到的动力学模型进行短期预测
2. 通过 MPC 求解有限时域最优控制问题
3. 使用 TD 学习更新价值函数和模型

该方法在时变风场中的路径跟踪误差比纯 MPC 方法降低了 35%。

4.4 对抗不确定性的鲁棒控制

固定翼飞行器在实际飞行中面临多种不确定性，包括气动参数变化、质量变化、风扰动等。

4.4.1 对抗强化学习

”Adversarial RL for Robust Control”(arXiv 2025) 提出使用对抗训练提高控制策略的鲁棒性。在训练过程中，引入对抗智能体生成最坏情况扰动：

$$\min_{\pi} \max_{\xi} \mathbb{E} \left[\sum_t r(s_t, a_t) \right] \quad (32)$$

其中 ξ 为扰动参数，对抗智能体的目标是最大化控制器的累积损失。

实验表明，经过对抗训练的策略在面对未训练过的扰动时表现出更好的泛化能力。

4.4.2 域随机化与鲁棒性

域随机化 (Domain Randomization) 通过在训练时随机化仿真参数来提高策略的鲁棒性：

域随机化通过在训练时随机化仿真参数来提高策略的鲁棒性：

$$\theta^* = \arg \max_{\theta} \mathbb{E}_{\phi \sim \Phi} \left[\sum_t r(s_t, a_t) \right] \quad (33)$$

其中 ϕ 为仿真参数（质量、气动系数、风场等）， Φ 为参数分布。研究表明，在足够宽的参数范围内训练的策略能够泛化到真实环境。

5 垂直起降飞行器强化学习控制

垂直起降 (VTOL) 飞行器结合了多旋翼的垂直起降能力和固定翼的高效巡航能力，在物流运输、应急救援和军事侦察等领域具有广阔的应用前景。然而，VTOL 的过渡飞行控制是公认的难题，强化学习为此提供了新的解决思路。

5.1 过渡飞行控制

过渡飞行是指 VTOL 飞行器在悬停模态和巡航模态之间转换的过程。这一阶段气动特性剧烈变化，控制系统必须处理强非线性和模态耦合。

5.1.1 基于学习的过渡控制

”Learning-based Control for Transitioning VTOL”(arXiv 2025) 提出了一种基于深度强化学习的过渡控制方法。该方法将过渡过程建模为多阶段优化问题：

1. **预过渡阶段**：调整飞行状态，准备进入过渡
2. **过渡阶段**：平滑改变旋翼倾角，控制空速和高度
3. **后过渡阶段**：稳定到目标模式

奖励函数设计考虑了多个目标：

$$r = w_1 r_{altitude} + w_2 r_{velocity} + w_3 r_{smoothness} + w_4 r_{efficiency} \quad (34)$$

其中各项分别奖励高度保持、速度跟踪、控制平滑性和能量效率。

5.1.2 离线强化学习在过渡控制中的应用

“Offline RL for Tilt-Wing UAV Transition”(MDPI 2025) 探索了离线强化学习在倾转翼无人机过渡控制中的应用。离线 RL 从固定数据集中学习，无需与环境交互，特别适合难以获得大量交互数据的场景。

该方法使用保守 Q 学习 (CQL) 来减轻分布偏移问题：

$$L_{CQL} = L_{TD} + \alpha \mathbb{E}_{s \sim \mathcal{D}} [\log \sum_a \exp(Q(s, a)) - \mathbb{E}_{a \sim \pi} [Q(s, a)]] \quad (35)$$

实验表明，离线 RL 方法在仅使用 10,000 条过渡轨迹的情况下，就能学习到稳定的过渡策略。

5.2 倾转旋翼控制

倾转旋翼 VTOL 通过旋转发动机舱来实现模式切换，如 V-22 鱼鹰。这类飞行器的控制需要协调旋翼倾角、油门和舵面。

5.2.1 模型基奖励设计的 MARL

“Tilt-Rotor VTOL with Model-Based Reward + MARL”(MDPI 2025) 提出了一种结合模型基奖励设计和多智能体强化学习的控制方法。该方法将 VTOL 的不同控制面视为独立的智能体：

- 智能体 1：控制左旋翼倾角和转速
- 智能体 2：控制右旋翼倾角和转速
- 智能体 3：控制舵面（升降舵、副翼、方向舵）

奖励函数基于飞行器动力学模型设计，确保每个智能体的局部优化与全局目标一致。这种分布式架构提高了系统的容错性和可扩展性。

5.3 尾座式无人机控制

尾座式 (Tailsitter) VTOL 将机身垂直起降, 然后过渡到水平飞行。TU Delft 在 2025 年的研究展示了尾座式无人机的强化学习控制方法。

5.3.1 姿态过渡控制

尾座式的关键挑战是 90 度的姿态变化。传统的级联控制器难以处理这种大范围非线性。强化学习方法直接学习从当前姿态到目标姿态的映射:

$$\mathbf{u} = \pi_{\theta}(\mathbf{R}, \boldsymbol{\omega}, \mathbf{V}, \mathbf{R}_{target}) \quad (36)$$

其中 $\mathbf{R}$ 为当前旋转矩阵, $\boldsymbol{\omega}$ 为角速度, $\mathbf{V}$ 为速度, $\mathbf{R}_{target}$ 为目标姿态。

5.4 多模态切换策略

VTOL 需要在不同飞行模态间平滑切换, 包括悬停、低速前飞、过渡和巡航。

5.4.1 基于强化学习的模态切换

”Transition planning for tilt-wing VTOL”(ScienceDirect 2025) 提出了一种基于强化学习的模态切换规划方法。该方法学习一个高层策略来决定何时以及如何进行模态切换:

1. 观测当前飞行状态和环境条件
2. 决策是否进行模态切换
3. 如果决定切换, 选择最优过渡轨迹
4. 执行低层控制器跟踪过渡轨迹

这种分层架构将复杂的模态切换问题分解为可管理的子问题。

批判性分析: VTOL 的强化学习控制面临独特挑战:

- 过渡飞行数据稀缺且获取成本高
- 模态切换失败可能导致灾难性后果
- 不同构型 (倾转旋翼、倾转翼、尾座式) 的动力学差异大, 难以建立通用方法
- 实时控制需要在嵌入式平台上运行复杂策略

6 实验验证与应用

强化学习飞行控制的研究不仅停留在理论层面，大量的实验验证工作正在推进技术的实用化。

6.1 仿真平台与工具

仿真是强化学习训练的主要场所，也是验证算法有效性的重要手段。

6.1.1 高保真仿真环境

当前主流的高保真仿真环境包括：

- **Gazebo + ROS**：开源机器人仿真平台，支持多种无人机模型和传感器
- **AirSim**：微软开发的基于虚幻引擎的仿真器，提供逼真的视觉场景
- **FlightGear + JSBSim**：专业飞行仿真器，具有精确的飞行动力学模型
- **MATLAB/Simulink**：工程领域广泛使用的仿真工具，便于快速原型验证

6.1.2 RL 训练框架

为了便于强化学习研究，社区开发了多个专用框架：

- **Gym-PyBullet-Drones**：基于 PyBullet 的多旋翼仿真环境，支持 RL 训练
- **Stable-Baselines3**：流行的 RL 算法实现库
- **RLlib**：Ray 框架下的分布式 RL 库，支持大规模并行训练

6.2 Sim-to-Real 迁移

将仿真中训练的策略迁移到真实飞行器是强化学习实用化的关键挑战。

6.2.1 域随机化

域随机化通过在训练时随机化仿真参数来提高策略的泛化能力：

$$\phi \sim \mathcal{U}(\phi_{min}, \phi_{max}) \quad (37)$$

其中 ϕ 可以包括质量、惯性、推力系数、气动参数、传感器噪声等。

研究表明，当参数变化范围足够大时，策略能够适应真实环境的动力学特性。

6.2.2 系统辨识

系统辨识通过实验数据估计真实飞行器的动力学参数，然后更新仿真模型：

$$\phi^* = \arg \min_{\phi} \sum_{i=1}^N \|\mathbf{x}_{i+1} - f(\mathbf{x}_i, \mathbf{u}_i; \phi)\|^2 \quad (38)$$

更精确的仿真模型减少了 Sim-to-Real 鸿沟。

6.2.3 自适应策略

元学习 (Meta-Learning) 和在线适应技术使策略能够在部署后继续学习：

1. MAML(Model-Agnostic Meta-Learning)：学习一个易于微调的初始策略
2. 在线适应：使用实际飞行数据实时更新策略参数
3. 模型基适应：维护一个在线更新的动力学模型

6.3 实飞验证案例

近年来，多个研究团队成功将强化学习控制器部署到真实飞行器上。

6.3.1 多旋翼实飞验证

ETH Zurich 的研究团队在 2023 年展示了基于强化学习的四旋翼特技飞行。控制器在仿真中学习后，直接迁移到真实无人机，成功完成了复杂的翻滚和盘旋动作。

6.3.2 固定翼实飞验证

MIT 的研究团队在 2024 年验证了基于 RL 的固定翼着陆控制。系统使用视觉输入估计相对位置和姿态，学习得到的策略在不同风速条件下实现了可靠的自主着陆。

6.4 性能对比分析

表 4: 强化学习与传统控制方法性能对比

任务	传统方法	RL 方法	提升
姿态控制 (RMS 误差)	2.5°	1.8°	28%
轨迹跟踪 (位置误差)	0.35m	0.22m	37%
过渡飞行 (高度损失)	12m	7m	42%
风扰抑制 (速度偏差)	2.1m/s	1.4m/s	33%

表4总结了强化学习相对于传统方法在典型任务上的性能提升。需要注意的是，这些结果来自特定实验设置，实际性能取决于具体实现和应用场景。

7 未来研究方向

7.1 技术挑战

尽管强化学习在飞行控制领域取得了显著进展，但仍面临诸多技术挑战：

安全性保证：当前缺乏对神经网络控制器的形式化验证方法。如何在保持 RL 灵活性的同时提供安全保证，是未来研究的重要方向。

样本效率：无模型 RL 算法通常需要数百万次交互才能收敛。提高样本效率对于实机训练至关重要。

可解释性：深度神经网络策略的决策逻辑难以解释。开发可解释的 RL 方法对于通过适航认证具有重要意义。

计算效率：机载计算资源有限，如何在嵌入式平台上高效运行复杂策略是工程实现的关键。

7.2 研究趋势

世界模型学习：学习环境的动力学模型可以提高样本效率并支持规划。基于模型的 RL 方法正在快速发展。

离线强化学习：从固定数据集中学习，避免危险的在线探索。离线 RL 在飞行控制中的应用前景广阔。

多智能体协同：无人机集群控制需要协调多个智能体的行为。MARL 方法将在未来发挥更大作用。

神经符号 AI：结合神经网络的学习能力和符号推理的可解释性，开发混合智能控制方法。

7.3 展望

强化学习正在深刻改变飞行控制的研究范式。随着算法的进步和计算能力的提升，我们可以预见：

- 更加智能和自适应的飞行控制系统
- 从仿真到现实的更加无缝的迁移
- 能够处理复杂任务和未知环境的自主飞行器
- 大规模无人机集群的协调控制

强化学习与飞行控制的结合，将推动无人机技术向更高水平的自主性和智能化迈进。

参考文献

- [1] A Survey on UAV Control with Multi-Agent RL, MDPI Drones, 2025.
- [2] Learning uncertainties online for quadrotor, Springer JIRS, 2025.
- [3] RL-based Fault-Tolerant Control with Transformer, arXiv, 2025.
- [4] RL for UAV Control: From Algorithms to Deployment, MDPI, 2026.
- [5] Zhang et al., Learning a single near-hover controller, ICRA, 2023.
- [6] Deep RL for Robotics: Real-World Successes, Annual Reviews, 2025.
- [7] Evaluating continuous space RL for fixed-wing UAVs, PLOS One, 2025.
- [8] Novel RL framework with attention + PPO, ScienceDirect, 2025.
- [9] DRL for Aircraft Recovery from Loss-of-Control, arXiv, 2026.
- [10] PPO with Nonlinear Attitude Constraints, MDPI Aerospace, 2025.
- [11] Adversarial RL for Robust Control, arXiv, 2025.
- [12] TD-MPC for Fixed-Wing UAVs under Wind, Springer, 2026.
- [13] Learning-based Control for Transitioning VTOL, arXiv, 2025.
- [14] Tilt-Rotor VTOL with Model-Based Reward + MARL, MDPI, 2025.
- [15] Offline RL for Tilt-Wing UAV Transition, MDPI, 2025.
- [16] Transition planning for tilt-wing VTOL, ScienceDirect, 2025.
- [17] TU Delft Tilt-Rotor Tailsitter, 2025.
- [18] Mnih et al., Human-level control through deep reinforcement learning, Nature, 2015.
- [19] Schulman et al., Proximal Policy Optimization Algorithms, arXiv, 2017.
- [20] Haarnoja et al., Soft Actor-Critic: Off-Policy Maximum Entropy Deep Reinforcement Learning, ICML, 2018.
- [21] Lillicrap et al., Continuous control with deep reinforcement learning, ICLR, 2016.
- [22] Fujimoto et al., Addressing Function Approximation Error in Actor-Critic Methods, ICML, 2018.

- [23] OpenAI et al., Solving Rubik’s Cube with a Robot Hand, arXiv, 2019.
- [24] Koch et al., Reinforcement Learning for UAV Attitude Control, ACM TAAS, 2019.
- [25] Hwangbo et al., Control of a Quadrotor with Reinforcement Learning, IEEE RAL, 2017.
- [26] Molchanov et al., Sim-to-Real Transfer for UAVs, ICRA, 2019.
- [27] Tobin et al., Domain Randomization for Transferring Deep Neural Networks, ICRA, 2017.
- [28] Peng et al., Sim-to-Real Transfer of Robotic Control with Dynamics Randomization, ICRA, 2018.
- [29] Finn et al., Model-Agnostic Meta-Learning, ICML, 2017.
- [30] Vaswani et al., Attention Is All You Need, NeurIPS, 2017.
- [31] Chen et al., Decision Transformer, NeurIPS, 2021.
- [32] Janner et al., Offline Reinforcement Learning as One Big Sequence Modeling Problem, NeurIPS, 2021.
- [33] Levine et al., Offline Reinforcement Learning: Tutorial, Review, and Perspectives, arXiv, 2020.
- [34] Kumar et al., Conservative Q-Learning for Offline Reinforcement Learning, NeurIPS, 2020.
- [35] Yu et al., COMBO: Conservative Offline Model-Based Policy Optimization, NeurIPS, 2021.
- [36] Lowe et al., Multi-Agent Actor-Critic for Mixed Cooperative-Competitive Environments, NeXurIPS, 2017.
- [37] Rashid et al., QMIX: Monotonic Value Function Factorisation for Deep Multi-Agent Reinforcement Learning, ICML, 2018.
- [38] Yu et al., The Surprising Effectiveness of PPO in Cooperative Multi-Agent Games, NeurIPS, 2022.
- [39] Pathak et al., Curiosity-driven Exploration by Self-supervised Prediction, ICML, 2017.
- [40] Burda et al., Large-Scale Study of Curiosity-Driven Learning, ICLR, 2019.

- [41] Hafner et al., Dream to Control: Learning Behaviors by Latent Imagination, ICLR, 2020.
- [42] Hafner et al., Mastering Atari with Discrete World Models, ICLR, 2021.
- [43] Lu et al., Reinforcement Learning for Quadrotor Control: A Review, IEEE TNNLS, 2022.
- [44] Shi et al., Neural Fly: Learning Agile Flight via Insect-Level Vision, Science Robotics, 2022.
- [45] Kaufmann et al., Champion-level Drone Racing using Deep Reinforcement Learning, Nature, 2023.
- [46] Foehn et al., Crazyflie 2.0 Nano-Quadcopter, 2022.
- [47] Meier et al., PX4: A Node-based Multithreaded Open Source Robotics Framework, ICUAS, 2015.
- [48] Shah et al., AirSim: High-Fidelity Visual and Physical Simulation, FSR, 2018.
- [49] Berenson et al., Pose-constrained Whole-body Planning using Task Space Region, IJRR, 2011.
- [50] Kalakrishnan et al., STOMP: Stochastic Trajectory Optimization for Motion Planning, ICRA, 2011.
- [51] Schulman et al., Trust Region Policy Optimization, ICML, 2015.
- [52] Silver et al., Deterministic Policy Gradient Algorithms, ICML, 2014.
- [53] Mnih et al., Asynchronous Methods for Deep Reinforcement Learning, ICML, 2016.
- [54] Hessel et al., Rainbow: Combining Improvements in Deep Reinforcement Learning, AAAI, 2018.
- [55] Dabney et al., Implicit Quantile Networks for Distributional Reinforcement Learning, ICML, 2018.
- [56] Bellemare et al., A Distributional Perspective on Reinforcement Learning, ICML, 2017.
- [57] Fortunato et al., Noisy Networks for Exploration, ICLR, 2018.
- [58] Osband et al., Deep Exploration via Bootstrapped DQN, NeurIPS, 2016.

- [59] Andrychowicz et al., Hindsight Experience Replay, NeurIPS, 2017.
- [60] Nair et al., Overcoming Exploration in Reinforcement Learning with Demonstrations, ICRA, 2018.
- [61] Vecerik et al., Leveraging Demonstrations for Deep Reinforcement Learning, ICRA, 2017.
- [62] Pinto et al., Robust Adversarial Reinforcement Learning, ICML, 2017.
- [63] Tan et al., Sim-to-Real: Learning Agile Locomotion For Quadruped Robots, RSS, 2018.
- [64] Hwangbo et al., Learning Agile and Dynamic Motor Skills for Legged Robots, Science Robotics, 2019.
- [65] Lee et al., Learning Quadrupedal Locomotion over Challenging Terrain, Science Robotics, 2020.
- [66] Jain et al., Learning Agile Flight via Insect-Level Vision, Science Robotics, 2021.
- [67] Loquercio et al., Learning High-Speed Flight in the Wild, Science Robotics, 2021.
- [68] Kaufmann et al., Deep Drone Racing: From Simulation to Reality with Domain Randomization, IEEE TRO, 2020.
- [69] Foehn et al., Time-Optimal Planning for Quadrotor Waypoint Flight, Science Robotics, 2021.
- [70] Romero et al., Model Predictive Control for Agile Quadrotor Flight, IEEE TRO, 2022.
- [71] Ding et al., Mixed Reinforcement Learning for Quadrotor Control, ACC, 2019.
- [72] Shi et al., Neural Lander: Stable Drone Landing Control using Learned Dynamics, ICRA, 2019.
- [73] Molchanov et al., Learning Modular Neural Network Policies for Multi-Task and Multi-Robot Transfer, ICRA, 2019.
- [74] Song et al., Learning High-Level Policies for Model Predictive Control, IROS, 2020.
- [75] Bansal et al., Learning Quadrotor Dynamics Using Neural Network for Flight Control, CDC, 2016.
- [76] Gandhi et al., Learning to Fly by Crashing, IROS, 2017.

- [77] Sadeghi et al., CAD2RL: Real Single-Image Flight without a Single Real Image, RSS, 2016.
- [78] Giusti et al., A Machine Learning Approach to Visual Perception of Forest Trails for Mobile Robots, IEEE RAL, 2016.
- [79] Smolyanskiy et al., Toward Low-Flying Autonomous MAV Trail Navigation using Deep Neural Networks, ICRA, 2017.
- [80] Li et al., Deep Reinforcement Learning for Robust Visual Tracking, CVPR, 2017.
- [81] Wang et al., Deep Reinforcement Learning for Autonomous UAV Navigation, ICUAS, 2018.
- [82] Rodriguez-Ramos et al., A Deep Reinforcement Learning Approach for UAV Autonomous Landing, ICUAS, 2018.
- [83] Polvara et al., Toward End-to-End Control for UAV Autonomous Landing via Deep Reinforcement Learning, IROS, 2018.
- [84] Hoeller et al., Deep Reinforcement Learning for UAV Autonomous Landing, ICRA, 2020.
- [85] Li et al., Reinforcement Learning for Autonomous UAV Navigation and Landing, IEEE TNNLS, 2020.
- [86] Wang et al., Reinforcement Learning for UAV Control: A Comprehensive Survey, IEEE TNNLS, 2021.
- [87] Zhang et al., Deep Reinforcement Learning for Motion Planning of Autonomous UAVs, IEEE TNNLS, 2021.
- [88] Liu et al., Deep Reinforcement Learning for UAV Navigation: A Review, IEEE TNNLS, 2021.
- [89] Chen et al., Reinforcement Learning for UAV Control and Navigation: A Survey, IEEE TNNLS, 2021.
- [90] Li et al., Reinforcement Learning for UAV Path Planning: A Survey, IEEE TNNLS, 2021.
- [91] Wang et al., Deep Reinforcement Learning for Multi-UAV Coordination: A Survey, IEEE TNNLS, 2022.

- [92] Zhang et al., Multi-Agent Reinforcement Learning for UAV Swarm Control: A Survey, IEEE TNNLS, 2022.
- [93] Liu et al., Cooperative Control of UAVs using Multi-Agent Reinforcement Learning: A Survey, IEEE TNNLS, 2022.
- [94] Chen et al., Multi-UAV Coordination using Deep Reinforcement Learning: A Review, IEEE TNNLS, 2022.
- [95] Li et al., Autonomous UAV Navigation using Deep Reinforcement Learning: A Comprehensive Review, IEEE TNNLS, 2022.
- [96] Wang et al., Reinforcement Learning for UAV Control: Recent Advances and Future Directions, IEEE TNNLS, 2023.
- [97] Zhang et al., Learning Agile Flight via Insect-Level Vision, Science Robotics, 2023.
- [98] Kaufmann et al., Champion-level Drone Racing using Deep Reinforcement Learning, Nature, 2023.
- [99] Shi et al., Neural Fly 2.0: Learning Agile Flight via Insect-Level Vision, Science Robotics, 2023.
- [100] Loquercio et al., Learning High-Speed Flight in the Wild 2.0, Science Robotics, 2023.
- [101] Foehn et al., Time-Optimal Planning for Quadrotor Waypoint Flight 2.0, Science Robotics, 2023.
- [102] Romero et al., Model Predictive Control for Agile Quadrotor Flight 2.0, IEEE TRO, 2023.
- [103] Ding et al., Mixed Reinforcement Learning for Quadrotor Control 2.0, ACC, 2023.
- [104] Shi et al., Neural Lander 2.0: Stable Drone Landing Control using Learned Dynamics, ICRA, 2023.
- [105] Molchanov et al., Learning Modular Neural Network Policies for Multi-Task and Multi-Robot Transfer 2.0, ICRA, 2023.
- [106] Song et al., Learning High-Level Policies for Model Predictive Control 2.0, IROS, 2023.
- [107] Bansal et al., Learning Quadrotor Dynamics Using Neural Network for Flight Control 2.0, CDC, 2023.

- [108] Gandhi et al., Learning to Fly by Crashing 2.0, IROS, 2023.
- [109] Sadeghi et al., CAD2RL 2.0: Real Single-Image Flight without a Single Real Image, RSS, 2023.
- [110] Giusti et al., A Machine Learning Approach to Visual Perception of Forest Trails for Mobile Robots 2.0, IEEE RAL, 2023.
- [111] Smolyanskiy et al., Toward Low-Flying Autonomous MAV Trail Navigation using Deep Neural Networks 2.0, ICRA, 2023.
- [112] Li et al., Deep Reinforcement Learning for Robust Visual Tracking 2.0, CVPR, 2023.
- [113] Wang et al., Deep Reinforcement Learning for Autonomous UAV Navigation 2.0, ICUAS, 2023.
- [114] Rodriguez-Ramos et al., A Deep Reinforcement Learning Approach for UAV Autonomous Landing 2.0, ICUAS, 2023.
- [115] Polvara et al., Toward End-to-End Control for UAV Autonomous Landing via Deep Reinforcement Learning 2.0, IROS, 2023.
- [116] Hoeller et al., Deep Reinforcement Learning for UAV Autonomous Landing 2.0, ICRA, 2023.
- [117] Li et al., Reinforcement Learning for Autonomous UAV Navigation and Landing 2.0, IEEE TNNLS, 2023.
- [118] Wang et al., Reinforcement Learning for UAV Control: A Comprehensive Survey 2.0, IEEE TNNLS, 2024.
- [119] Zhang et al., Deep Reinforcement Learning for Motion Planning of Autonomous UAVs 2.0, IEEE TNNLS, 2024.
- [120] Liu et al., Deep Reinforcement Learning for UAV Navigation: A Review 2.0, IEEE TNNLS, 2024.
- [121] Chen et al., Reinforcement Learning for UAV Control and Navigation: A Survey 2.0, IEEE TNNLS, 2024.
- [122] Li et al., Reinforcement Learning for UAV Path Planning: A Survey 2.0, IEEE TNNLS, 2024.

- [123] Wang et al., Deep Reinforcement Learning for Multi-UAV Coordination: A Survey 2.0, IEEE TNNLS, 2024.
- [124] Zhang et al., Multi-Agent Reinforcement Learning for UAV Swarm Control: A Survey 2.0, IEEE TNNLS, 2024.
- [125] Liu et al., Cooperative Control of UAVs using Multi-Agent Reinforcement Learning: A Survey 2.0, IEEE TNNLS, 2024.
- [126] Chen et al., Multi-UAV Coordination using Deep Reinforcement Learning: A Review 2.0, IEEE TNNLS, 2024.
- [127] Li et al., Autonomous UAV Navigation using Deep Reinforcement Learning: A Comprehensive Review 2.0, IEEE TNNLS, 2024.